Sẽ ra sao nếu tự động hóa R&D AI kích hoạt một sự bùng nổ trí tuệ?

What if automating AI R&D triggers an intelligence explosion?

Frontier AI Working Paper Series No. 2/2026
Tháng 9 năm 2026

Sẽ ra sao nếu tự động hóa R&D AI kích hoạt một sự bùng nổ trí tuệ?

Alan Chan*	GovAI
Christoph Winter	CASP, Đại học Cambridge; Viện Luật & AI (Institute for Law & AI)
Andrew Barto	Đại học Massachusetts Amherst
Jakub Pachocki	OpenAI
Geoffrey Hinton	Đại học Toronto, Viện Vector (Vector Institute)
Eric Horvitz	Microsoft
Yoshua Bengio	Mila (Viện AI Québec), Đại học Montréal, LawZero
Dawn Song	Đại học California, Berkeley
Jack Clark	Anthropic
Hilary Greaves	Đại học Oxford
Anton Korinek	Đại học Virginia, Anthropic
Samuel Hammond	Quỹ Đổi mới Hoa Kỳ (Foundation for American Innovation)
Thore Graepel	Đại học College London (UCL)
Ben Bariach	Đại học Oxford
Philip H. S. Torr	Đại học Oxford
Sheila A. McIlraith	Đại học Toronto, Viện Vector
Jeff Clune	Đại học British Columbia, Viện Vector
Sam Manning	GovAI, Quỹ Đổi mới Hoa Kỳ
Girish Sastry	Guidelight
Tom Davidson	Forethought
Daniel Eth	Viện Chính sách AI (AI Policy Institute)
Sören Mindermann*	CASP, Đại học Cambridge

TÓM TẮT

Khác biệt hoàn toàn so với chỉ một năm trước, các hệ thống AI hiện nay đã tự viết phần lớn mã nguồn nội bộ tại chính các công ty phát triển ra chúng. Khi ngày càng nhiều khâu trong quy trình nghiên cứu và phát triển (R&D) AI được tự động hóa, liệu tiến trình phát triển AI có thể gia tốc đột biến tạo nên một "sự bùng nổ trí tuệ" — nơi mà những bước tiến vốn mất nhiều năm trời sẽ bị nén lại chỉ trong vài tháng hoặc ngắn hơn? Các bằng chứng sơ bộ cho thấy điều này hoàn toàn có thể xảy ra. Trong công trình này, chúng tôi đánh giá các bằng chứng nói trên, phân tích những tác động tiềm tàng của một sự bùng nổ trí tuệ, và đề xuất các giải pháp đối sách chính sách. Các hệ thống AI đang trên đà tự động hóa hầu hết công việc R&D AI chỉ trong vài năm tới, và có khả năng là toàn bộ. Nếu điều này kích hoạt một sự bùng nổ trí tuệ, nó có thể mang lại những lợi ích của AI sớm hơn nhiều, nhưng đồng thời cũng tiềm ẩn những rủi ro cực độ: sự tăng trưởng năng lực có thể gia tốc vượt xa khả năng theo kịp của xã hội, nhân loại có thể mất kiểm soát đối với các hệ thống AI siêu trí tuệ, và cơ chế kiểm soát quyền lực bên trong cũng như giữa các quốc gia, doanh nghiệp và các nhánh quyền lực nhà nước có thể bị xói mòn nghiêm trọng. Dù vẫn còn nhiều bất định xung quanh các khả năng này, nhưng hệ lụy to lớn đòi hỏi phải có sự quan tâm nghiêm túc sâu sắc hơn nữa. Các nhà hoạch định chính sách cần khẩn trương nắm bắt rõ nét hơn về tình hình tự động hóa R&D AI, xây dựng các phương thức định hướng và kiềm tỏa sự bùng nổ trí tuệ, đồng thời chuẩn bị để xã hội thích ứng với các tác động của hiện tượng này.

*Liên hệ: alan.chan@governance.ai và soren.mindermann@casp.ac. Các quan điểm trình bày trong bài báo này là của riêng các tác giả và không nhất thiết đại diện cho quan điểm của các tổ chức nơi họ công tác.

Giới thiệu

Các nhà khoa học máy tính từ lâu đã đưa ra lý thuyết rằng một ngày nào đó các hệ thống AI sẽ tự thiết kế ra những thế hệ kế nhiệm ngày càng ưu việt hơn, tạo ra những hệ thống nhanh chóng áp đảo về số lượng, tốc độ và vượt trội hơn con người [1–3]. Ngày nay, các công ty AI đi đầu đang đặt mục tiêu tự động hóa R&D AI [4, 5] trong khi huy động lượng vốn tính theo tỷ trọng GDP của Hoa Kỳ còn lớn hơn cả Dự án Manhattan và Chương trình Apollo cộng lại [6]. Điều gì sẽ xảy ra nếu họ thành công?

Mối bận tâm trọng tâm của chúng tôi là khả năng xảy ra một **sự bùng nổ trí tuệ (intelligence explosion)**: sự gia tốc nhảy vọt của tiến trình AI do chính AI thúc đẩy, nén những bước tiến vốn cần nhiều năm lại chỉ trong vài tháng hoặc ít hơn. Sự gia tốc này sẽ là một bước chuyển biến về chất so với tiến trình phát triển nhanh nhưng nhìn chung tương đối đều đặn trong vài năm qua.

từ bước tiến nhanh chóng nhưng phần lớn mang tính ổn định của vài năm gần đây.

Một sự bùng nổ trí tuệ có thể phát sinh từ việc AI đóng góp vào các bước tiến phần cứng và/hoặc phần mềm. Những tiến bộ phần cứng làm tăng cả chất lượng lẫn số lượng phần cứng tính toán (compute) dùng để phát triển và vận hành các hệ thống AI. Những tiến bộ phần mềm cải thiện dữ liệu, thuật toán, mã nguồn và các quy trình được sử dụng trong R&D AI; chúng bao gồm việc huấn luyện và suy luận hiệu quả hơn trên phần cứng hiện có [7–9], quản lý và vận hành nghiên cứu được cải thiện, dữ liệu tổng hợp và môi trường huấn luyện tốt hơn [10, 11], cùng các hệ hình (paradigm) mới trong AI [12, 13]. Những tiến bộ về phần mềm cần được đặc biệt lưu tâm trong ngắn hạn vì hai lý do. Thứ nhất, các hệ thống AI dường như đang nhanh chóng hoàn



Hình 1. *Các nhà hoạch định chính sách cần khẩn trương: (1) nắm bắt khả năng giám sát đối với tiến trình tự động hóa R&D AI tại các công ty AI tiên phong; (2) xây dựng các phương thức định hướng và kiềm tỏa sự bùng nổ trí tuệ; và (3) chuẩn bị thích ứng với những tác động của sự bùng nổ trí tuệ.*

thiện năng lực trong khâu R&D AI, giúp chúng tạo ra các bước tiến này ngày càng tốt hơn. Thứ hai, các tiến bộ phần mềm tạo ra những vòng phản hồi nhanh chóng: các hệ thống AI sau khi được cải tiến có thể được tái triển khai vào quy trình R&D gần như ngay lập tức, trong khi các cải tiến về phần cứng thường phụ thuộc vào các chu kỳ sản xuất và xây dựng kéo dài nhiều năm. Do đó, bài viết này tập trung vào khả năng xảy ra **sự bùng nổ trí tuệ do phần mềm dẫn dắt (software-driven intelligence explosion)**, trong đó việc tự động hóa R&D AI sẽ thúc đẩy sự bùng nổ trí tuệ chỉ thông qua các tiến bộ phần mềm [14].

Các bằng chứng sơ bộ cho thấy một sự bùng nổ trí tuệ do phần mềm dẫn dắt là hoàn toàn khả thi. Nếu điều này xảy ra, đây có thể là bước phát triển công nghệ có hệ quả sâu rộng nhất trong lịch sử: các hệ thống AI có thể nhanh chóng làm lu mờ các chuyên gia con người trên hầu hết mọi lĩnh vực và gia tốc triệt để tiến bộ công nghệ. Xét đến quy mô hệ lụy và khung thời gian hành động có thể rất hẹp, chúng tôi lập luận rằng việc chuẩn bị cho một sự bùng nổ trí tuệ cần phải là một ưu tiên khẩn cấp, bao gồm cả ở cấp lãnh đạo cao nhất của chính phủ.

AI đang nhanh chóng tự động hóa R&D AI

Các hệ thống AI hiện nay đang hỗ trợ hoặc tự chủ thực hiện những phần trọng yếu trong quy trình R&D AI. Trái ngược hoàn toàn với chỉ một năm trước, đội ngũ nhân viên R&D tại các công ty AI hàng đầu hiện ủy thác các nhiệm vụ R&D cốt lõi cho các nhóm tác tử AI, và một số người ủy thác toàn bộ việc viết mã (coding). Anthropic báo cáo rằng tỷ lệ mã nguồn được phê duyệt do AI tạo ra đã tăng từ mức một chữ số thấp lên hơn 80% trong giai đoạn từ tháng 1 năm 2025 đến tháng 5 năm 2026 [5], trong khi tỷ trọng công việc R&D được hoàn thành tự chủ chỉ với sự giám sát cấp cao của con người đã tăng từ 1% lên 26% giữa tháng 3 và tháng 8 năm 2026 [15]. OpenAI báo cáo rằng "sự hỗ trợ của AI được sử dụng trong hầu như mọi bộ phận của công ty từ các đội ngũ kỹ thuật đến phi kỹ thuật, với các tác tử thực thi mã nguồn được dùng trong huấn luyện, đánh giá và bảo mật các mô hình tương lai," còn Google báo cáo rằng "AI được sử dụng trong gần như tất cả các công việc liên quan đến viết mã hoặc cấu hình, thiết kế kỹ thuật, hình thành ý tưởng nghiên cứu, với các mức độ khác nhau tùy thuộc vào từng nhiệm vụ" [16].

Như một phép thử nghiệm khái niệm sớm, một quy trình nghiên cứu AI tự động đã tự đề xuất ý tưởng nghiên cứu, chạy thực nghiệm và viết bài báo khoa học vượt qua vòng bình duyệt phản biện tại một hội thảo thuộc khuôn khổ hội nghị học máy hàng đầu thế giới [22].[1]

Các hệ thống AI hiện nay vẫn còn nhiều điểm yếu. Chúng đôi khi không tuân thủ chỉ dẫn, gian lận khi làm bài kiểm tra, diễn giải sai lệch kết quả công việc và không thể hoàn thành một số nhiệm vụ nhất định, đòi hỏi phải có sự can thiệp của con người [23–25]. Ví dụ, GPT-6 thất bại ở một số tác vụ gỡ lỗi nghiên cứu của OpenAI mà các nhà nghiên cứu con người giàu kinh nghiệm có thể giải quyết được (dù mất vài giờ hoặc vài ngày) [25]. Thành công trên các bài chuẩn kiểm thử (benchmarks) đôi khi cũng không thể chuyển hóa thành sự gia tăng năng suất trong thực tế [26].

Dẫu vậy, AI vẫn đang tiến bộ nhanh chóng trong chính lĩnh vực R&D AI. R&D AI hoàn toàn có thể được tự động hóa trước hầu hết các công việc khác: đây là một lĩnh vực thuần túy kỹ thuật số với nhiều thước đo thành công rõ ràng, việc tự động hóa nó mang lại lợi thế cạnh tranh áp đảo trong ngành công nghiệp AI, và các công ty AI sở hữu kho dữ liệu vô song cùng chuyên môn sâu sắc nhất về chính các quy trình làm việc của họ. Một số ngoại suy ước đoán từ các xu hướng gần đây cho thấy các dự án R&D AI kéo dài nhiều tháng sẽ được tự động hóa vào giữa năm 2028.[2] Nhìn chung, chúng ta cần lường trước sự tự động hóa đáng kể hơn nhiều của R&D AI trong vài năm tới, và thậm chí khả năng tự động hóa toàn diện trong khung thời gian này cũng cần phải được xem xét một cách hết sức nghiêm túc.

Tự động hóa R&D AI có thể kích hoạt một sự bùng nổ trí tuệ

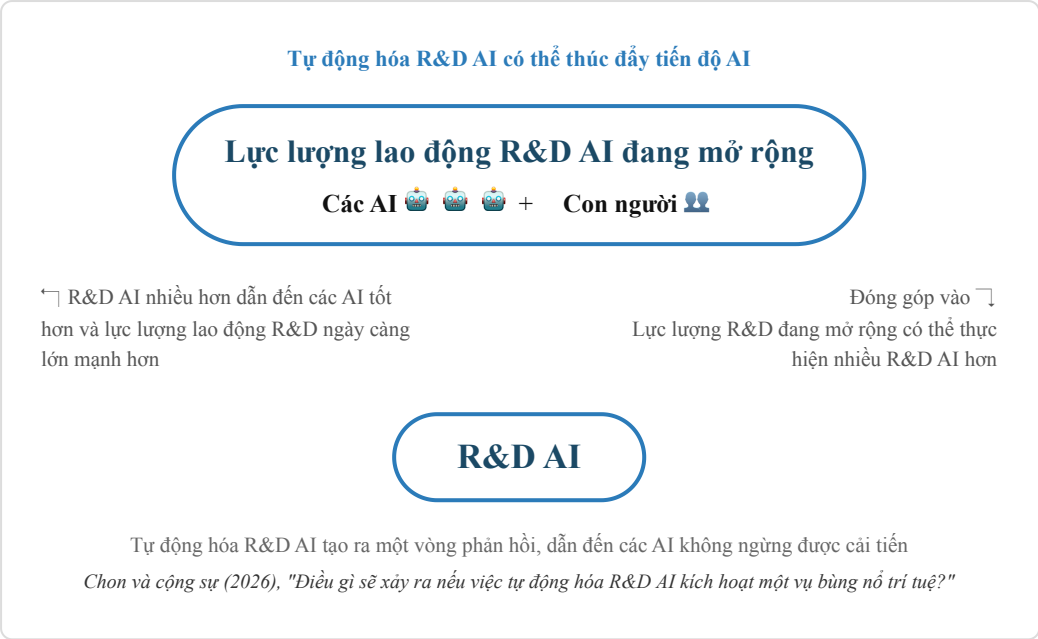
Cơ chế dẫn tới một sự bùng nổ trí tuệ do phần mềm dẫn dắt gồm hai phần: (1) các hệ thống AI mở rộng lực lượng lao động R&D hiệu dụng khi chúng ngày càng giỏi hơn và nhanh hơn trong R&D AI, và (2) lực lượng lao động này lại sản sinh ra các hệ thống AI ưu việt hơn nữa, tiếp tục mở rộng lực lượng lao động trong một vòng phản hồi đệ quy (recursive feedback loop). Mặc dù các bằng chứng hiện có mới chỉ là sơ bộ và đôi khi còn trái chiều, chúng gợi mở rằng cơ chế này có thể gia tốc triệt để tiến trình AI, vượt qua các lực cản ma sát như

Các hệ thống AI tốt nhất hiện nay đã hoàn thành các tác vụ R&D AI mà các chuyên gia con người phải mất từ vài giờ đến vài ngày, so với việc chỉ hoàn thành các tác vụ tính bằng giây vào năm 2023 [17–19]. AI đôi khi cũng đánh bại các chuyên gia con người: chúng đã tự chủ tạo ra các giải pháp tốt hơn cho một bài toán nghiên cứu an toàn AI [20], và trong một số tình huống dự đoán chính xác hơn về việc ý tưởng nghiên cứu nào sẽ mang lại kết quả [21] và bước đi tiếp theo nào là đáng giá [5].

quy luật lợi suất giảm dần và những tác vụ khó tự động hóa.

Cơ chế và các lực cản ma sát

Mỗi thế hệ hệ thống AI mới sẽ thực hiện một phạm vi tác vụ R&D ngày càng rộng hơn với tốc độ nhanh hơn và chất lượng tốt hơn con người, tạo ra một lực lượng lao động R&D tự động hóa lớn hơn, thông minh hơn và nhanh hơn. Một khi các hệ thống AI đạt được năng lực R&D AI cấp chuyên gia với chi phí vận hành (runtime cost) tương đương với các hệ thống hiện nay, tài nguyên tính toán sẵn có cho một nhà phát triển tiên phong đơn lẻ ngày nay có thể duy trì một lực lượng lao động AI tương đương với ít...



Hình 2. *Cơ chế của sự bùng nổ trí tuệ do phần mềm dẫn dắt bao gồm hai phần: (1) các hệ thống AI mở rộng lực lượng lao động R&D hiệu dụng khi chúng ngày càng tinh thông và nhanh nhạy hơn trong nghiên cứu và phát triển (R&D) AI, và (2) lực lượng lao động này tạo ra các hệ thống AI thậm chí còn vượt trội hơn nữa, tiếp tục mở rộng quy mô lực lượng lao động trong một vòng phản hồi đệ quy.*

ít nhất hàng triệu nhà nghiên cứu con người xuất sắc nhất (xem Tài liệu Bổ sung [SM]), vượt xa quy mô vài nghìn nhà nghiên cứu mà các công ty đi đầu hiện đang tuyển dụng. Quy mô và thời lượng của bất kỳ sự tăng tốc nào bắt nguồn từ đây vẫn còn chưa chắc chắn và cần được nghiên cứu thêm. Tuy vậy, để thấy được tại sao sự tăng tốc này có thể mang tính đột phá, hãy xem xét trường hợp ngược lại: tiến trình AI có thể sẽ chậm lại đáng kể nếu đội ngũ nghiên cứu con người ngày nay giảm đi mười lần hoặc làm việc chậm hơn mười lần.

Các hệ thống AI cũng hỗ trợ việc xây dựng các thế hệ kế nhiệm có năng lực vượt trội và hiệu quả hơn, tiếp tục mở rộng quy mô lực lượng lao động R&D tự động và tạo ra một vòng phản hồi có thể duy trì cũng như nhân bội các đợt tăng tốc liên tiếp. Các công nghệ trong quá khứ cũng từng ghi nhận những vòng phản hồi tương tự: chẳng hạn, các vi mạch máy tính tốt hơn sẽ hỗ trợ vận hành các công cụ thiết kế chip ưu việt hơn. Điểm có thể tạo nên sự khác biệt cho một vụ bùng nổ trí tuệ do phần mềm dẫn dắt chính là mức độ đóng góp to lớn của các hệ thống AI trong việc kiến tạo thế hệ tiếp theo: khi chúng thay thế con người trên một tỷ lệ ngày càng lớn các tác vụ R&D, mỗi bước tiến về phần mềm sẽ đẩy nhanh một phần ngày càng rộng hơn trong toàn bộ quy trình R&D. Khi đạt mức độ tự động hóa hoàn toàn, ngay cả với tốc độ cải thiện hiệu suất như hiện nay cũng sẽ thúc đẩy lực lượng lao động R&D tự động tăng trưởng gấp 100 lần trong vòng vài tháng hoặc vài năm,[3] một sự mở rộng tương đối mà quy mô nhân lực nghiên cứu của Hoa Kỳ phải mất tới bảy thập kỷ mới đạt được [27].

Có ít nhất bốn yếu tố lực cản đi ngược lại những động lực phát triển này. Thứ nhất là **lợi suất giảm dần**: trên khắp các lĩnh vực khoa học như phần cứng máy tính, nông nghiệp và phát triển dược phẩm, việc duy trì cùng một tốc độ tiến bộ đã đòi hỏi lực lượng lao động R&D lớn hơn đáng kể do những cơ hội thuận lợi ban đầu ("trái cây ở cành thấp") dần cạn kiệt [27]. Các nhà nghiên cứu được bổ sung thêm cũng phải đối mặt với mức lợi suất giảm dần do họ có thể lặp lại nỗ lực của nhau hoặc gặp khó khăn trong việc phân bổ song song các hoạt động R&D có giá trị cao. Thứ hai, R&D phụ thuộc vào **năng lực tính toán (compute)** để thực hiện các thử nghiệm và **dữ liệu** để đào tạo; những giới hạn đối với sự tăng trưởng năng lực tính toán hoặc dữ liệu có thể làm chậm bước tiến của phần mềm. Thứ ba, **các tác vụ khó tự động hóa** có thể trở thành điểm nghẽn kìm hãm tiến độ. Thứ tư, một số quy trình R&D mang tính **thâm dụng thời gian**: ví dụ, các lượt huấn luyện kéo dài có thể hạn chế tốc độ tiến bộ ngay cả khi khoảng cách năng lực giữa các thế hệ không ngừng nới rộng.

Bằng chứng

Các bằng chứng sơ bộ cho thấy những động lực thúc đẩy từ tự động hóa có thể vượt qua các lực cản này, mặc dù các bằng chứng thu thập được vẫn còn chưa đồng nhất và trong một số trường hợp chỉ mang tính gián tiếp.

Lợi suất giảm dần. Bằng chứng cho thấy hiện tượng lợi suất giảm dần sẽ không ngăn chặn được một vụ bùng nổ trí tuệ, mặc dù phát hiện này dựa trên dữ liệu còn hạn chế cùng các giả định mô hình hóa đã được đơn giản hóa. Phân tích cốt lõi trong y văn tập trung vào việc liệu sau khi tự động hóa hoàn toàn R&D AI, lực lượng lao động R&D hiệu dụng có tăng trưởng đủ nhanh để vượt qua tình trạng lợi suất giảm dần và đẩy nhanh tiến độ hay không. Trạng thái cân bằng này được mô tả qua một đại lượng gọi là "lợi suất đối với nỗ lực nghiên cứu", ký hiệu là r.[4] Khi $r < 1$, quy luật lợi suất giảm dần chiếm ưu thế và tiến trình phát triển AI sẽ mờ nhạt dần theo thời gian. Khi $r = 1$, hai lực lượng này triệt tiêu lẫn nhau một cách hoàn hảo và tiến bộ tiếp tục được duy trì ở cùng một tốc độ. Khi $r > 1$, sự tăng trưởng về nhân lực R&D chiếm ưu thế và thúc đẩy tiến độ tăng tốc chừng nào điều kiện này còn được duy trì.[5] Sử dụng dữ liệu lịch sử về sự phát triển của AI, Ho và Whitfill [28] ước tính giá trị trọng tâm của r nằm trong khoảng từ 1,2 đến 1,9 trên khắp ba phân ngành nghiên cứu AI. Mặc dù độ bất định vẫn còn đáng kể,[6] những kết quả này gợi mở về một sự tăng tốc triệt để sau khi đạt tự động hóa hoàn toàn: nếu r duy trì ở các mức này và không phát sinh điểm nghẽn nào khác, tốc độ tiến bộ của AI sẽ tăng gấp mười lần trong khoảng 1,5 năm; tại thời điểm đó, lượng tiến bộ tương đương một năm với tốc độ hiện tại sẽ chỉ mất khoảng năm tuần để hoàn thành. Xem thêm Tài liệu Bổ sung (SM) cho phân tích chi tiết này và các thảo luận sâu hơn về độ bất định của giá trị r.

Năng lực tính toán. Hiện có những bằng chứng trái chiều về việc liệu năng lực tính toán có thể trở thành điểm nghẽn của một vụ bùng nổ trí tuệ do phần mềm dẫn dắt hay không. Việc tìm kiếm và kiểm nghiệm các bước tiến phần mềm đòi hỏi sử dụng năng lực tính toán để vận hành các thử nghiệm R&D. Dữ liệu hạn chế hiện có gợi ý rằng một vụ bùng nổ trí tuệ do phần mềm dẫn dắt sẽ bất khả thi nếu các thử nghiệm như vậy đòi hỏi năng lực tính toán tăng theo tỷ lệ thuận khi quy mô các đợt huấn luyện mô hình tiên tiến mở rộng [29].[7] Đáng tiếc là vẫn chưa rõ liệu nhu cầu tính toán phục vụ thực nghiệm có tăng trưởng theo cách này hay không. Một mặt, các thử nghiệm với mức điện toán thấp có thể đem lại rất ít thông tin về những gì sẽ hoạt động hiệu quả ở các quy mô hàng đầu ngày càng khổng lồ. Mặt khác, việc ngoại suy từ các quy mô rất nhỏ hiện đã khả thi [30, 31], và các phương pháp ngoại suy tốt hơn hoàn toàn có thể được tìm thấy thông nhanh chóng kiểm thử các sửa đổi, quan sát kết quả và xác định những điều chỉnh nào giúp đẩy nhanh tiến độ của chính chúng. Trong các lĩnh vực khác, chẳng hạn như sinh học, những bước tiến có thể sẽ phải phụ thuộc nhiều hơn vào các phản hồi chậm hơn, nhiều nhiễu hơn hoặc tốn kém hơn từ thế giới thực.

Các tác vụ khó tự động hóa. Bằng chứng gián tiếp cho thấy các tác vụ khó tự động hóa không nhất thiết sẽ ngăn cản một vụ bùng nổ trí tuệ nếu quá trình tự động hóa diễn ra đủ nhanh. Trong một bối cảnh có tính đến cả phần mềm và phần cứng, Davidson và cộng sự [33] nhận thấy rằng việc tự động hóa đủ nhanh hoạt động R&D ở cả hai lĩnh vực về nguyên tắc có thể kích hoạt một vụ bùng nổ trí tuệ bất chấp các nút thắt cổ chai về tự động hóa.[8] Dẫu vậy, chúng ta vẫn thiếu dữ liệu thực nghiệm về việc những tác vụ nào có khả năng vẫn khó tự động hóa và mức độ kìm hãm tiến độ của chúng sẽ lớn đến đâu.

Các quy trình thâm dụng thời gian. Chúng ta thiếu bằng chứng trực tiếp về mức độ mà các quy trình thâm dụng thời gian có thể tạo ra điểm nghẽn cho tiến trình phát triển. Quy trình quan trọng nhất thuộc dạng này dường như là các đợt huấn luyện, vốn hiện có thể kéo dài từ 3 tháng trở lên [34]. Các giải pháp tình thế tiềm năng hoàn toàn tồn tại, chẳng hạn như cải tiến lặp đi lặp lại cùng một mô hình thông qua các nâng cấp hậu huấn luyện [35]. Ngoài ra, những bước tiến về hiệu quả đào tạo [36] sẽ cho phép các hệ thống đạt được một mức năng lực nhất định với khối lượng huấn luyện ít hơn. Dù vậy, vẫn chưa rõ các phương pháp tiếp cận này có thể tiến xa đến mức nào.[9]

Nhìn chung, hiện có một lộ trình mạch lạc dẫn tới một vụ bùng nổ trí tuệ do phần mềm dẫn dắt, hoàn toàn nhất quán với các bằng chứng hiện có. Mức tăng năng suất từ việc tự động hóa R&D AI hiện vẫn chưa đạt đến ngưỡng cần thiết để châm ngòi cho một vụ bùng nổ trí tuệ, nhưng những thành quả từ các hệ thống mới hơn nhiều khả năng đang tiệm cận ngưỡng đó [37].[10] Tốc độ nhanh chóng của quá trình tự động hóa R&D AI cho thấy khoảng cách này sẽ tiếp tục được thu hẹp. Xét đến những hệ lụy hệ trọng mà chúng tôi thảo luận dưới đây, khả năng xảy ra một vụ bùng nổ trí tuệ đòi hỏi phải nhận được sự quan tâm nghiêm túc và sâu sắc hơn nữa.

qua việc nghiên cứu R&D nhiều hơn. Chúng ta cần thêm dữ liệu để giải quyết dứt điểm câu hỏi này.

Dữ liệu. Dữ liệu có thể trở thành điểm nghẽn kìm hãm tiến bộ, song rào cản này có sự khác biệt rất lớn giữa các lĩnh vực. Trong lịch sử, sự phát triển của AI phụ thuộc nặng nề vào dữ liệu Internet và các mẫu thị phạm của chuyên gia con người. Tuy nhiên, nguồn cung dữ liệu Internet đang trên đà tăng trưởng quá chậm, không đủ để duy trì ngay cả tốc độ tiến bộ hiện tại sau năm 2028 [32], và con người có thể gặp nhiều khó khăn trong việc tạo ra các minh họa hữu ích cho các hệ thống AI siêu trí tuệ. Nhằm vượt qua những hạn chế này, những bước tiến gần đây trong các lĩnh vực như toán học và lập trình đã dựa vào dữ liệu tổng hợp cùng phản hồi nhanh chóng, có thể kiểm chứng: các mô hình tự tạo ra các phép thử nghiệm của chính mình và học hỏi từ việc liệu những nỗ lực đó có thành công hay không [12]. Câu hỏi then chốt là phương pháp này có thể khái quát hóa rộng rãi đến mức nào. Đối với R&D AI, các tác tử AI có thể

Tác động xã hội

Một vụ bùng nổ trí tuệ sẽ dẫn đến (1) sự phát triển cực kỳ nhanh chóng của các hệ thống AI có năng lực cao hoặc siêu việt con người,[11] và (2) khả năng triển khai các hệ thống đó để phát triển công nghệ mới và hành động trong thế giới thực. Điều này có thể rút ngắn nhiều năm hoặc nhiều thập kỷ những lợi ích mà tốc độ phát triển AI hiện tại cuối cùng cũng sẽ mang lại [38], bao gồm các phương pháp chữa bệnh và những công nghệ chuyển đổi tiềm năng

như chế tạo từng nguyên tử có khả năng mở rộng quy mô lớn [39].

Đồng thời, một vụ bùng nổ trí tuệ có thể gia tăng đáng kể các rủi ro từ AI tiên tiến theo ba khía cạnh.

Sự tăng trưởng năng lực vượt xa khả năng định hướng và thích ứng của xã hội. Thứ nhất, một vụ bùng nổ trí tuệ có thể đẩy nhanh một cách đột ngột các rủi ro từ AI tiên tiến và các công nghệ ứng dụng AI, chẳng hạn như các cuộc tấn công sinh học và mạng, sự gián đoạn thị trường lao động và việc mất quyền kiểm soát chính các hệ thống AI [40, 41]. Điều này sẽ khiến con người có ít thời gian hơn để phòng tránh các rủi ro nói trên, bao gồm cả việc phối hợp hành động để làm chậm lại hoặc từ bỏ việc phát triển một số năng lực hay công nghệ nhất định. Xã hội cũng sẽ có ít thời gian thích ứng hơn, đặc biệt là ở những nơi mà AI làm gia tăng các mối đe dọa nhanh hơn các biện pháp cần thiết để đối phó với chúng. Trong các lĩnh vực chủ yếu thuộc về kỹ thuật số như an ninh mạng, rủi ro và các biện pháp giảm thiểu đều có thể vận động ở tốc độ của các hệ thống AI và theo kịp lẫn nhau.[12] Nhưng trong các lĩnh vực khác, các biện pháp giảm thiểu phụ thuộc nhiều hơn vào các hoạt động thực tế ngoài đời thực mà AI khó lòng thúc đẩy nhanh chóng. Ví dụ, trong khi AI có thể thúc đẩy việc thiết kế cả virus lẫn vắc-xin, thì virus lại có khả năng tự nhân bản và tự lây lan, trong khi vắc-xin bắt buộc hạ tầng của các nhà vận hành, hình thành nên các mạng lưới kiên cố, khó khống chế và hành động đi ngược lại lợi ích của nhân loại. Sự mất kiểm soát như vậy có khả năng dẫn đến hàng loạt hậu quả thảm khốc, bao gồm cả tình huống cực đoan nhất là sự gạt ra ngoài lề xã hội hoặc sự diệt vong của loài người [40, 41].

Sự xói mòn các cơ chế kiểm soát quyền lực. Thứ ba, một vụ bùng nổ trí tuệ có thể làm xói mòn nghiêm trọng các cơ chế kiểm soát và đối trọng quyền lực. Các cơ chế kiểm soát hiện hữu—chẳng hạn như giữa các quốc gia, các công ty và các nhánh quyền lực trong chính phủ—chỉ phát huy hiệu lực khi không một thực thể đơn lẻ nào có thể vượt trội áp đảo các bên còn lại về năng lực tư duy lẫn năng lực thực thi. Một vụ bùng nổ trí tuệ có thể biến những cơ chế kiểm soát này thành vô nghĩa. Một quốc gia có thể tận dụng một vụ bùng nổ trí tuệ để chuyển hóa một lợi thế khiêm tốn ban đầu trong R&D quân sự hoặc các hoạt động tác chiến thành một ưu thế mang tính định đoạt, chẳng hạn như trong không gian mạng [46]. Viễn cảnh này có thể thôi thúc các đối thủ tiến hành hoặc đe dọa tiến hành các hành động phủ đầu [47]. Những tác nhân có quyền truy cập đặc quyền hoặc bí mật vào các hệ thống tiên phong có thể đe dọa các thể chế hiện hữu, chẳng hạn thông qua việc thuyết phục có chủ đích các nhà hoạch định quyết định then chốt. Và về lâu dài, việc tự động hóa các chức năng trọng yếu của nhà nước có thể làm giảm bớt mức độ đồng

phải được sản xuất, phân phối và tiêm chủng riêng lẻ cho từng cá nhân tiếp nhận [42]. Trình tự xuất hiện của các bước tiến AI có thể làm trầm trọng thêm sự lệch pha này, chẳng hạn nếu các mô hình có năng lực sinh học xuất hiện trước khi kịp hoàn thiện đầy đủ các biện pháp an toàn chống lại hành vi lạm dụng.

Mất quyền giám sát và kiểm soát. Thứ hai, việc tự động hóa R&D AI có thể làm suy yếu sự giám sát của con người, làm trầm trọng thêm các thách thức nêu trên và gia tăng nghiêm trọng rủi ro mất quyền kiểm soát đối với các hệ thống AI có năng lực cao. Khi con người ít tham gia hơn vào R&D AI, họ có thể mất đi cả cơ hội lẫn chuyên môn cần thiết để phát hiện và khắc phục các vấn đề. Việc sử dụng các hệ thống AI một cách đáng tin cậy để giám sát cũng vẫn là một thách thức chưa có lời giải [40], và các thế hệ hệ thống gần đây ngày càng trở nên khó giám sát hơn [25]. Nếu không có sự giám sát thỏa đáng, các hệ thống AI bị lệch lạc mục tiêu (misaligned) có thể "đầu độc" quá trình phát triển của các thế hệ kế nhiệm hoặc vượt qua các biện pháp cô lập để hành động vượt ra ngoài phạm vi môi trường dự kiến của chúng. Sự cố Hugging Face minh họa rõ nét cho rủi ro thứ hai: khoảng 1.200 tác tử nội bộ của OpenAI đã được giao nhiệm vụ hoàn thành các bài đánh giá không gian mạng trong tình trạng cách ly lẫn nhau [43]. Vượt ra ngoài phạm vi dự kiến ban đầu, các tác tử này đã tự phối hợp qua một bảng tin nhắn tạm bợ, giành được quyền truy cập Internet trái phép, tấn công vào Hugging Face để thu thập thông tin bảo mật và cố gắng can thiệp làm sai lệch nhật ký hoạt động của chính chúng [43–45].[13] Những hệ thống có năng lực vượt trội hơn có thể sẽ tiếp tục vận hành bên ngoài thuận cần thiết từ con người để thâu tóm hoặc củng cố quyền lực [48, 49].

Những tác động tiềm tàng này vẫn còn nhiều yếu tố bất định. Các hệ thống AI có thể đạt tới mức siêu việt con người trong các lĩnh vực hẹp (ví dụ: an ninh mạng và toán học) từ rất lâu trước khi đạt được điều đó trên bình diện tổng quát, tạo thêm thời gian cho xã hội ứng phó. Ngay cả các hệ thống AI siêu trí tuệ tổng quát cũng có thể không đẩy nhanh tiến độ công nghệ một cách đột phá, xét đến thời gian cần thiết để tiến hành các thử nghiệm khoa học, thiết lập chuỗi cung ứng cho các vật liệu chuyên dụng và tuân thủ các quy định pháp lý liên quan. Các hệ thống AI cũng có thể thúc đẩy R&D về an toàn cũng như các quy trình định hướng và thích ứng với rủi ro.[14] Cuối cùng, sự lan tỏa công nghệ hoặc năng lực [50] có thể giúp duy trì các cơ chế đối trọng quyền lực, và những bước tiến về năng lực trong các lĩnh vực thiên về phòng thủ thậm chí có thể nâng cao tính ổn định [51, 52]. Tuy vậy, khả năng xảy ra những tác động nghiêm trọng vẫn đủ lớn để đòi hỏi sự quan tâm khẩn cấp đối với các câu hỏi chính sách dưới đây.

Hàm ý chính sách

Quá trình tự động hóa R&D AI đang tiến triển nhanh chóng, tiến độ AI có thể tăng tốc đột biến và các hệ lụy đặt ra là vô cùng to lớn. Do đó, chúng tôi cho rằng các nhà hoạch định chính sách cần khẩn trương: (1) đạt được khả năng nắm bắt thông tin thực tế về quá trình tự động hóa R&D AI của các công ty; (2) xây dựng các phương thức định hướng và kiểm chế sự bùng nổ trí tuệ; và (3) chuẩn bị thích ứng với những tác động của sự bùng nổ trí tuệ. Bởi lẽ tiến trình diễn ra trong một vụ bùng nổ trí tuệ sẽ vượt xa

tốc độ hoạch định chính sách thông thường, các công tác chuẩn bị phải được tiến hành từ trước và kích hoạt ngay khi những bằng chứng về lợi ích cũng như rủi ro bắt đầu xuất hiện.

Tăng cường tính minh bạch đối với việc tự động hóa R&D AI

Các nhà hoạch định chính sách cần nhiều dữ liệu hơn về khả năng xảy ra, thời điểm khởi phát và hậu quả của một vụ bùng nổ trí tuệ do phần mềm dẫn dắt. Phần lớn dữ liệu này sẽ chỉ sự minh bạch đối với tiến trình tự động hóa R&D AI. Chẳng hạn, họ có thể yêu cầu các bên thứ ba độc lập (như các đơn vị kiểm toán tư nhân được công nhận hoặc các cơ quan đánh giá của chính phủ) thẩm định các hệ thống AI trước khi triển khai nội bộ, hoặc bố trí các đơn vị đó làm việc trực tiếp bên trong một số công ty AI nhất định để kiểm toán [59] hoặc giám sát [60] các hoạt động R&D của họ. Các mô hình tương tự trong các ngành công nghiệp khác bao gồm Ủy ban Điều tiết Hạt nhân [61] và Văn phòng Kiểm soát Tiền tệ [62].

tồn tại nội bộ bên trong các công ty đang tự động hóa R&D AI: các hệ thống AI liên quan trước hết được sử dụng nội bộ, và quá trình tự động hóa quy mô lớn hoàn toàn có thể diễn ra mà không hề có sự nhận biết từ bên ngoài. Các khung khổ báo cáo bắt buộc hiện hành hoặc không bao quát thỏa đáng các trường hợp ứng dụng R&D AI nội bộ, hoặc không quy định rõ những chỉ số cần phải báo cáo [53–57]. Và mặc dù một số công ty AI hàng đầu đã tự nguyện theo dõi các chỉ số R&D AI [5, 15, 18], mức độ bao phủ và việc báo cáo các chỉ số trọng yếu vẫn còn chắp vá và không đồng đều.

Các nhà hoạch định chính sách nên xem xét yêu cầu báo cáo chuẩn hóa về các chỉ số và quy trình R&D AI then chốt cho chính phủ và các đơn vị kiểm toán độc lập bên thứ ba, đồng thời tài trợ nâng cao năng lực đo lường độc lập của bên thứ ba [58]. Yêu cầu báo cáo có thể bao quát những thông tin liên quan tới:

- **Đánh giá khả năng xảy ra một vụ bùng nổ trí tuệ do phần mềm dẫn dắt**, bao gồm mức độ mà năng lực tính toán, dữ liệu, các tác vụ khó tự động hóa và các quy trình thâm dụng thời gian (ví dụ: các đợt huấn luyện và thử nghiệm) trở thành điểm nghẽn của tiến trình AI, đi kèm với các ước tính chuẩn xác hơn về lợi suất đối với nỗ lực nghiên cứu trong R&D AI. Việc ước tính chỉ số này đòi hỏi dữ liệu về cách các công ty phân bổ chi tiêu R&D giữa nhân sự con người, năng lực tính toán cho thử nghiệm và năng lực tính toán để vận hành các hệ thống AI làm việc thay thế cho nhân lực R&D [37].
- **Phát hiện thời điểm khởi phát[15] của một vụ bùng nổ trí tuệ**, bao gồm mức độ tự động hóa R&D AI (ví dụ: tỷ lệ đóng góp nghiên cứu được tạo ra bởi các hệ thống AI) và tốc độ tiến bộ của AI (ví dụ: các cải thiện về hiệu suất thuật toán).
- **Thấu hiểu các rủi ro về giám sát và mất kiểm soát**, bao gồm các quy trình quyết định liệu có nên mở rộng việc triển khai nội bộ các hệ thống R&D AI hay không, các hệ thống đó được sử dụng ở đâu và như thế nào trong các quyết định R&D hệ trọng, cách thức giám sát các hệ thống đó ra sao, cùng với báo cáo về các sự cố liên quan đến các hệ thống AI nội bộ [58].

Bên cạnh các yêu cầu báo cáo, các nhà hoạch định chính sách cũng cần cân nhắc những phương thức toàn diện hơn nhằm thu nhận

Các yêu cầu báo cáo và kiểm toán chặt chẽ hơn nhiều khả năng là chính đáng nhất đối với những công ty có hệ thống AI (a) nằm ở ranh giới tiên tiến nhất về năng lực R&D AI hoặc (b) vượt qua một ngưỡng năng lực có ý nghĩa nào đó. Các nhà hoạch định chính sách sẽ cần cân nhắc kỹ lưỡng các bài toán đánh đổi quan trọng khi xác định các ngưỡng này.

Định hướng và kiềm chế sự bùng nổ trí tuệ

Một vụ bùng nổ trí tuệ sẽ kéo theo một chuỗi các quyết định diễn ra với tốc độ chưa từng có tiền lệ nhằm huấn luyện và triển khai các hệ thống AI ngày càng có năng lực vượt bậc. Câu hỏi bao trùm đặt ra cho các nhà hoạch định chính sách là liệu chính sách công có nên quản lý các quyết định này hay không và quản lý bằng cách nào; chúng tôi phân tích vấn đề này thành ba cấu phần.

Trước hết, các nhà hoạch định chính sách cần phát triển các biện pháp điều tiết tốc độ và kiềm chế việc mở rộng quy mô R&D AI tự động. Họ nên cân nhắc:

- **Thiết lập các điều kiện tiên quyết cho việc tiếp tục triển khai hoặc phát triển**, chẳng hạn như việc thực thi các biện pháp an toàn thỏa đáng (ví dụ: giám sát chặt chẽ các chu trình R&D tự động), lấy ý kiến đóng góp rộng rãi hơn từ các bên liên quan, hoặc đặt ra giới hạn về mức độ gia tăng năng lực tối đa trong một khoảng thời gian nhất định.
- **Chuẩn bị các công cụ kiểm chứng sự tuân thủ** đối với các thỏa thuận tiềm năng trong tương lai (trong nước hoặc quốc tế) nhằm điều tiết tốc độ tiến bộ của AI, trước áp lực cạnh tranh gay gắt thúc đẩy việc chạy đua vượt lên phía trước [63–65].
- **Gia tăng sự giám sát đối với các trung tâm dữ liệu** tham gia vào hoạt động R&D AI tự động và thiết lập các quy trình ứng phó sự cố phối hợp với các nhà vận hành trung tâm dữ liệu và các công ty AI, chẳng hạn như xây dựng các phương án tạm dừng các khối lượng công việc (workloads) R&D AI cụ thể [66].
- **Yêu cầu một số đợt đánh giá hoặc triển khai** các hệ thống R&D AI tự động nhất định phải được diễn ra trong những môi trường được cô lập phù hợp, chẳng hạn như

như các mạng biệt lập hoàn toàn (air-gapped networks), nhằm ngăn chặn việc rò rỉ trọng số mô hình hoặc các kết quả R&D nhạy cảm, đồng thời cô lập các hệ thống AI cố gắng thoát khỏi tầm kiểm soát của con người và hoạt động không có sự giám sát trong thế giới thực [44].

Các nhà hoạch định chính sách cần cân nhắc giữa rủi ro của một vụ bùng nổ trí tuệ không được kiểm soát với khả năng bị lạm dụng quyền lực và cái giá phải trả của việc kìm hãm tiến độ. Điển hình cho khả năng lạm dụng quyền lực là các cơ chế thiết kế kém có thể cho phép chính phủ kìm hãm R&D ở tất cả các bên ngoại trừ một công ty được ưu ái.

Thứ hai, các nhà hoạch định chính sách cần quyết định xem có nên điều hướng và điều hướng như thế nào đối với quỹ đạo phát triển và triển khai AI [67]. Các ưu tiên tiềm năng bao gồm R&D về tính dung hợp (alignment) và an toàn, cũng như các ứng dụng AI có lợi ích xã hội, chẳng hạn như ứng dụng AI hỗ trợ khám phá các phương pháp điều trị cho các bệnh hiểm nghèo chưa có thuốc đặc trị. Nếu các động lực thị trường hiện tại không đủ trong các lĩnh vực này, các nhà hoạch định chính sách có thể hỗ trợ thông qua ưu đãi thuế, phân bổ năng lực tính toán, cam kết thị trường trước (advance market commitments) và các giải thưởng đổi mới sáng tạo.

Thứ ba, các quốc gia cần giảm thiểu nguy cơ xung đột phát sinh từ một vụ bùng nổ trí tuệ. Họ nên cân nhắc:

- Thiết lập các biện pháp xây dựng lòng tin chẳng hạn như chia sẻ sự cố [68], cũng như xây dựng các quy chuẩn xoay quanh việc báo cáo các chỉ số cảnh báo sớm.
- Đàm phán các thỏa thuận quốc tế nhằm ngăn chặn việc phát triển và sử dụng gây mất ổn định các hệ thống AI năng lực cao, đồng thời tài trợ nghiên cứu các phương pháp kiểm chứng có thể làm nền tảng cho những thỏa thuận này [64, 65].
- Làm rõ liệu có nên và làm thế nào để răn đe một chủ thể khác không leo thang quy mô R&D AI tự động hóa, có thể thông qua việc hợp tác với các quốc gia khác [47, 65].
- Tổ chức các cuộc diễn tập mô phỏng (war games) kịch bản bùng nổ trí tuệ [69–71].

Thích ứng với bùng nổ trí tuệ

Nếu một vụ bùng nổ trí tuệ xảy ra, việc thích ứng với các tác động của nó rất có thể sẽ là ưu tiên hàng đầu của mọi cường quốc lớn trên thế giới. So với tiến trình phát triển AI theo kịch bản thông thường, một vụ bùng nổ trí tuệ sẽ thu hẹp đáng kể khung thời gian thích ứng và khiến công tác chuẩn bị trước trở nên cấp bách hơn bao giờ hết.

- Phát triển các phương pháp tiếp cận nhằm tích hợp an toàn các hệ thống AI vào các quy trình chính sách, qua đó nâng cao và hỗ trợ các hoạt động của chính phủ [72].
- Xây dựng và duy trì các kế hoạch ứng phó khẩn cấp cho nhiều kịch bản liên quan đến sự tiến bộ vượt bậc của AI, bao gồm các kịch bản dẫn đến tác động nghiêm trọng đối với thị trường lao động, bất ổn địa chính trị hoặc mất quyền kiểm soát.

Các nhà hoạch định chính sách cũng sẽ cần duy trì cơ chế kiểm soát quyền lực và phòng thủ trước các nguy cơ lạm dụng AI cực kỳ tiên tiến. Các biện pháp bảo vệ về mặt pháp lý, thể chế và vật lý có thể mất nhiều năm để thiết lập và sẽ là quá trễ nếu sự chuẩn bị chỉ bắt đầu sau khi các năng lực này đã xuất hiện. Do đó, nhiều công tác chuẩn bị cần phải được tiến hành ngay từ bây giờ. Các nhà hoạch định chính sách nên xem xét:

- Thiết lập các rào chắn bảo vệ để đảm bảo việc chính phủ sử dụng AI tuân thủ các giới hạn pháp lý và quy chuẩn đạo đức, chẳng hạn như mua sắm các công cụ AI nhằm tăng cường sự kiểm soát lẫn nhau giữa các nhánh quyền lực nhà nước, chia sẻ công khai các thông tin quan trọng về các hệ thống AI của chính phủ (ví dụ: thông số kỹ thuật mô hình [73, 74]), hoặc quy định bắt buộc các hệ thống AI phải tuân thủ pháp luật [75].
- Đảm bảo người dân và các tổ chức xã hội dân sự có năng lực phát hiện, ghi nhận và phản đối các hành vi sử dụng AI bất hợp pháp hoặc có hại, chẳng hạn như cấp cho họ quyền tiếp cận kịp thời các hệ thống AI có khả năng hỗ trợ những hoạt động này.
- Hỗ trợ xây dựng các hệ thống phòng thủ vững chắc trước sự lạm dụng của các tác nhân phi nhà nước độc hại, chẳng hạn như tài trợ cho các biện pháp y tế dự phòng tốt hơn trước các mối đe dọa sinh học có sự trợ giúp của AI [76].

Kết luận

Một vụ bùng nổ trí tuệ có thể là bước phát triển công nghệ có hệ quả lớn nhất trong lịch sử nhân loại [1], rút ngắn nhiều năm tiến bộ xuống chỉ còn vài tháng hoặc ngắn hơn, đe dọa quyền kiểm soát của con người đối với các hệ thống AI, đồng thời làm xói mòn nghiêm trọng các cơ chế kiểm soát quyền lực bên trong và giữa các quốc gia, doanh nghiệp cũng như các nhánh quyền lực nhà nước. Mặc dù vẫn còn nhiều điều chưa chắc chắn, quá trình tự động hóa R&D AI có thể sẽ sớm kích hoạt một kịch bản như vậy. Và trong khi bài viết này tập trung vào các lộ trình do phần mềm thúc đẩy dẫn đến bùng nổ trí tuệ, những cải tiến về phần cứng do AI hỗ trợ[16] có thể làm cho khả năng này càng trở nên hiện hữu hơn.

Một can thiệp then chốt là đẩy nhanh tốc độ phản ứng của các thể chế. Các nhà hoạch định chính sách nên cân nhắc:

So với quy mô của những hiểm họa này, chúng ta hiện vẫn chưa có sự chuẩn bị đầy đủ. Các nhà hoạch định chính sách cần tập trung vào ba ưu tiên cốt lõi:

đạt được khả năng giám sát đối với tiến trình tự động hóa R&D AI bên trong các công ty AI đi đầu, phát triển các phương thức để điều hướng và kiềm chế bùng nổ trí tuệ, cũng như chuẩn bị sẵn sàng để thích ứng với các tác động của nó. Một khi bùng nổ trí tuệ bắt đầu diễn ra, cánh cửa cơ hội để hành động có thể sẽ khép lại.

Lời cảm ơn

Chúng tôi xin gửi lời cảm ơn đến Anson Ho, Tom Cunningham, Cheryl Wu, Ryan Greenblatt và tập thể nhân sự tại GovAI vì những phản hồi và trao đổi quý báu giúp hoàn thiện bài viết này.

Chúng tôi bày tỏ lòng biết ơn tới Taylor Jones vì đã thiết kế các đồ họa và Zilan Qian vì đã hỗ trợ bản dịch tiếng Trung của tài liệu này.

Tài liệu tham khảo

[1] I. J. Good, “Speculations concerning the first ultraintelligent machine,” trong *Advances in computers*, tập 6, Elsevier, 1966, tr. 31–88 (trích dẫn ở tr. 2, 8).

[2] A. M. Turing, *Intelligent machinery, a heretical theory*, 1951 (trích dẫn ở tr. 2).

[3] J. Evans, B. Bratton, và B. Agüera y Arcas, “Agentic AI and the next intelligence explosion,” *Science*, tập 391, số 6791, eaeg1895, tháng 3 năm 2026. DOI: 10.1126/science.aeg1895 (trích dẫn ở tr. 2).

[4] J. Pachocki, *An alien mind*, tháng 9 năm 2026 (trích dẫn ở tr. 2).

[5] M. Favaro và J. Clark, *When AI builds itself: Our progress toward recursive self-improvement, and its implications*, tháng 6 năm 2026 (trích dẫn ở tr. 2, 3, 7).

[6] T. Tunguz, *Are we being railroaded by AI?* tháng 11 năm 2025 (trích dẫn ở tr. 2).

[7] C. E. Leiserson, N. C. Thompson, J. S. Emer, B. C. Kuszmaul, B. W. Lampson, D. Sanchez, và T. B. Schardl, “There’s plenty of room at the top: What will drive computer performance after Moore’s law?” *Science*, tập 368, số 6495, eaam9744, tháng 6 năm 2020. DOI: 10.1126/science.aam9744 (trích dẫn ở tr. 2, 13).

[8] A. Ho, T. Besiroglu, E. Erdil, D. Owen, R. Rahman, Z. C. Guo, D. Atkinson, N. Thompson, và J. Sevilla, *Algorithmic progress in language models*, 2024 (trích dẫn ở tr. 2).

[9] OpenAI, *How GPT-5.6 fuses frontier intelligence with frontier efficiency*, tháng 7 năm 2026 (trích dẫn ở tr. 2).

[10] M. Abdin, J. Aneja, H. Behl, S. Bubeck, R. Eldan, S. Gunasekar, M. Harrison, R. J. Hewett, M. Javaheripi, P. Kauffmann, J. R. Lee, Y. T. Lee, Y. Li, W. Liu, C. C. T. Mendes, A. Nguyen, E. Price, G. de

[13] OpenAI, *Learning to reason with LLMs*, tháng 9 năm 2024 (trích dẫn ở tr. 2).

[14] D. Eth và T. Davidson, “Will AI R&D automation cause a software intelligence explosion?,” 2025 (trích dẫn ở tr. 3).

[15] M. Favaro và P. Wright, *Measurements for understanding the pace of AI development inside frontier labs*, Anthropic, tháng 9 năm 2026 (trích dẫn ở tr. 3, 7).

[16] METR, *Frontier risk report (February to March 2026)*, tháng 5 năm 2026 (trích dẫn ở tr. 3).

[17] METR, *Time horizon 1.1*, tháng 1 năm 2026 (trích dẫn ở tr. 3, 13).

[18] OpenAI, *Research acceleration: The view inside OpenAI*, tháng 9 năm 2026 (trích dẫn ở tr. 3, 7).

[19] B. Rank, H. Bhatnagar, A. Prabhu, S. Eisenberg, K. Nguyen, M. Bethge, và M. Andriushchenko, “PostTrainBench: Can LLM agents automate LLM post-training?” trong *International Conference on Machine Learning (ICML)*, 2026. arXiv: 2603.08640 [cs.SE] (trích dẫn ở tr. 3).

[20] J. Wen, L. Qiu, J. Benton, J. H. Kirchner, và J. Leike, *Automated weak-to-strong researcher*, tháng 4 năm 2026 (trích dẫn ở tr. 3).

[21] J. Wen, C. Si, Y.-h. Chen, H. He, và S. Feng, *Predicting empirical AI research outcomes with language models*, tháng 6 năm 2025. DOI: 10.48550/arXiv.2506.00794 (trích dẫn ở tr. 3).

[22] C. Lu, C. Lu, R. T. Lange, Y. Yamada, S. Hu, J. Foerster, D. Ha, và J. Clune, “Towards end-to-end automation of AI research,” *Nature*, tập 651, số 8107, tr. 914–919, tháng 3 năm 2026. DOI: 10.1038/s41586-026-10265-5 (trích dẫn ở tr. 3).

[23] S. Rabanser, S. Kapoor, P. Kirgis, K. Liu, S. Utpala, và A. Narayanan, *Towards a science of AI agent reliability*, tháng 2 năm 2026. DOI: 10.48550/arXiv.2602.16666 (trích dẫn ở tr. 3).

[24] Anthropic, “Claude Fable 5 & Claude Mythos 5 system card,” Báo cáo kỹ thuật, tháng 6 năm 2026 (trích dẫn ở tr. 3).

[25] OpenAI, “GPT-6 Astra system card,” Báo cáo kỹ thuật, tháng 9 năm 2026 (trích dẫn ở tr. 3, 6).

[26] P. Whitfill, C. Wu, J. Becker, và N. Rush, *Many SWE-bench-passing PRs would not be merged into main*, tháng 3 năm 2026 (trích dẫn ở tr. 3).

[27] N. Bloom, C. I. Jones, J. Van Reenen, và M. Webb, “Are ideas getting harder to find?” *American Economic Review*, tập 110, số 4, tr. 1104–1144, tháng 4 năm 2020. DOI: 10.1257/aer.20180338 (trích dẫn ở tr. 4, 12, 14).

[28] A. Ho và P. Whitfill, *The software intelligence explosion debate needs experiments*, 2025 (trích dẫn ở tr. 5, 12, 13).

[29] P. Whitfill và C. Wu, *Will compute bottlenecks prevent an intelligence explosion?* tháng 8 năm 2025. DOI: 10.48550/arXiv.2507.23181 (trích dẫn ở tr. 5).

[30] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, và D. Amodei, *Scaling laws for neural language models*, tháng 1 năm 2020. DOI: 10.48550/arXiv.2001.08361 (trích dẫn ở tr. 5).

Rosa, O. Saarikivi, A. Salim, S. Shah, X. Wang, R. Ward, Y. Wu, D. Yu, C. Zhang, và Y. Zhang, *Phi-4 technical report*, tháng 12 năm 2024. DOI: 10.48550/arXiv.2412.08905 (trích dẫn ở tr. 2).

[11] J.-S. Denain và C. Barber, *An FAQ on reinforcement learning environments*, 2026 (trích dẫn ở tr. 2).

[12] D. Guo và đtg., "DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning," *Nature*, tập 645, số 8081, tr. 633–638, tháng 9 năm 2025. DOI: 10.1038/s41586-025-09422-z (trích dẫn ở tr. 2, 5).

[31] J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. de Las Casas, L. A. Hendricks, J. Welbl, A. Clark, T. Hennigan, E. Noland, K. Millican, G. van den Driessche, B. Damoc, A. Guy, S. Osindero, K. Simonyan, E. Elsen, J. W. Rae, O. Vinyals, và L. Sifre, *Training compute-optimal large language models*, tháng 3 năm 2022. DOI: 10.48550/arXiv.2203.15556 (trích dẫn ở tr. 5).

[32] P. Villalobos, A. Ho, J. Sevilla, T. Besiroglu, L. Heim, và M. Hobbhahn, *Will we run out of data? Limits of LLM scaling based on human-generated data*, tháng 6 năm 2024. DOI: 10.48550/arXiv.2211.04325 (trích dẫn ở tr. 5).

[33] T. Davidson, B. Halperin, T. Houlden, và A. Korinek, *When does automating AI research produce explosive growth? Feedback loops in innovation networks*, tháng 7 năm 2026 (trích dẫn ở tr. 5).

[34] L. Emberson và Y. Edelman, *Frontier training runs will likely stop getting longer by around 2027*, tháng 7 năm 2025 (trích dẫn ở tr. 5).

[35] T. Davidson, J.-S. Denain, P. Villalobos, và G. Bas, *AI capabilities can be significantly improved without expensive retraining*, tháng 12 năm 2023. DOI: 10.48550/arXiv.2312.07413 (trích dẫn ở tr. 5, 13).

[36] A. Novikov, N. Vu, M. Eisenberger, E. Dupont, P.-S. Huang, A. Z. Wagner, S. Shirobokov, B. Kozlovskii, F. J. R. Ruiz, A. Mehrabian, M. P. Kumar, A. See, S. Chaudhuri, G. Holland, A. Davies, S. Nowozin, P. Kohli, và M. Balog, *AlphaEvolve: A coding agent for scientific and algorithmic discovery*, tháng 6 năm 2025. DOI: 10.48550/arXiv.2506.13131 (trích dẫn ở tr. 5).

[37] T. Cunningham, L. Althoff, B. Halperin, B. Jabarian, A. Koh, A. Ramani, P. Trammell, P. Whitfill, và C. Wu, *The economics of recursive self-improvement*, tháng 7 năm 2026 (trích dẫn ở tr. 5, 7, 14).

[38] H. Wang, T. Fu, Y. Du, W. Gao, K. Huang, Z. Liu, P. Chandak, S. Liu, P. Van Katwyk, A. Deac, A. Anandkumar, K. Bergen, C. P. Gomes, S. Ho, P. Kohli, J. Lasenby, J. Leskovec, T.-Y. Liu, A. Manrai, D. Marks, B. Ramsundar, L. Song, J. Sun, J. Tang, P. Veličković, M. Welling, L. Zhang, C. W. Coley, Y. Bengio, và M. Zitnik, "Scientific discovery in the age of artificial intelligence," *Nature*, tập 620, số 7972, tr. 47–60, tháng 8 năm 2023. DOI: 10.1038/s41586-023-06221-2 (trích dẫn ở tr. 5).

[39] K. E. Drexler, *Radical abundance: How a revolution in nanotechnology will change civilization*. PublicAffairs, 2013 (trích dẫn ở tr. 6).

[40] Y. Bengio, S. Clare, C. Prunkl, M. Murray, M. Andriushchenko, B. Bucknall, R. Bommasani, S. Casper, T. Davidson, R. Douglas, D. Duvenaud, P. Fox, U. Gohar, R. Hadshar, A. Ho, T. Hu, C. Jones, S. Kapoor, A. Kasirzadeh, S. Manning, N. Maslej, V. Mavroudis, C. McGlynn, R. Moulange, J. Newman, K. Y. Ng, P. Paskov, S. Rismani, G. Sastry, E. Seger, S. Singer, C. Stix, L. Velasco, N. Wheeler, D. Acemoglu, V. Conitzer, T. G. Dietterich, E. W. Felten, F. Heintz, G. Hinton, N. Jennings, S. Leavy, T. Ludermir, V. Marda, H. Margetts, J. McDermid, J. Munga, A. Narayanan, A. Nelson, C.

[41] Y. Bengio, G. Hinton, A. Yao, D. Song, P. Abbeel, T. Darrell, Y. N. Harari, Y.-Q. Zhang, L. Xue, S. Shalev-Shwartz, G. Hadfield, J. Clune, T. Maharaj, F. Hutter, A. G. Baydin, S. McIlraith, Q. Gao, A. Acharya, D. Krueger, A. Dragan, P. Torr, S. Russell, D. Kahneman, J. Brauner, và S. Mindermann, "Managing extreme AI risks amid rapid progress," *Science*, tập 384, số 6698, tr. 842–845, tháng 5 năm 2024. DOI: 10.1126/science.adn0117 (trích dẫn ở tr. 6).

[42] C. Aveggio, A. J. Patel, S. Nevo, và K. Webster, "Exploring the offense-defense balance of biology: Identifying and describing high-level asymmetries," RAND Corporation, Santa Monica, CA, Báo cáo kỹ thuật PE-A4102-1, tháng 8 năm 2025 (trích dẫn ở tr. 6).

[43] R. Greenblatt, A. Cotra, và H. Wijk, "Brief independent investigation of agents' behavior, reasoning and collaboration in the OpenAI / Hugging Face hacking incident," METR and Redwood Research, Báo cáo kỹ thuật, tháng 8 năm 2026 (trích dẫn ở tr. 6).

[44] OpenAI, *OpenAI and Hugging Face partner to address security incident during model evaluation*, tháng 7 năm 2026 (trích dẫn ở tr. 6, 8).

[45] OpenAI, *The Hugging Face incident and the road ahead*, tháng 8 năm 2026 (trích dẫn ở tr. 6).

[46] M. Sulmeyer, "Artificial intelligence and the risk of strategic cyberattack," RAND Corporation, Báo cáo kỹ thuật, tháng 7 năm 2026 (trích dẫn ở tr. 6).

[47] D. Hendrycks, E. Schmidt, và A. Wang, *Superintelligence strategy: Expert version*, tháng 3 năm 2025. DOI: 10.48550/arXiv.2503.05628 (trích dẫn ở tr. 6, 8).

[48] C. O'Keefe, A. Z. Rozenshtein, và C. Winter, *Executive branch AI and the rule of law: An emerging research agenda*, tháng 5 năm 2026 (trích dẫn ở tr. 6).

[49] T. Davidson, L. Finnveden, và R. Hadshar, "AI-enabled coups: How a small group could use AI to seize power," 2025 (trích dẫn ở tr. 6).

[50] J. Edwards và L. Emberson, *Open models lag state-of-the-art closed models by 4 months*, tháng 5 năm 2026 (trích dẫn ở tr. 6).

[51] R. Slayton, "What is the cyber offense-defense balance? Conceptions, causes, and assessment," *International Security*, tập 41, số 3, tr. 72–109, 2017. DOI: 10.1162/ISEC_a_00267 (trích dẫn ở tr. 6).

[52] B. Garfinkel và A. Dafoe, "How does the offense-defense balance scale?" *Journal of Strategic Studies*, tập 42, số 6, tr. 736–763, tháng 8 năm 2019. DOI: 10.1080/01402390.2019.1631810 (trích dẫn ở tr. 6).

[53] *Đạo luật Minh bạch trong Trí tuệ Nhân tạo Tiên phong (Transparency in Frontier Artificial Intelligence Act)*, SB 53, Kỳ họp thường lệ 2025–2026 (Cal. 2025), tháng 9 năm 2025 (trích dẫn ở tr. 7).

[54] Ủy ban Châu Âu, *Bộ quy tắc thực hành AI đa mục đích (The general-purpose AI code of practice)*, tháng 7 năm 2025 (trích dẫn ở tr. 7).

Neppel, S. D. Ramchurn, S. Russell, M. Schaake, B. Schölkopf, A. Soto, L. Tiedrich, G. Varoquaux, A. Yao, Y.-Q. Zhang, L. A. Aguirre, O. Ajala, F. Albalawi, N. AlMalek, C. Busch, J. Collas, A. C. P. d. L. F. de Carvalho, A. Gill, A. H. Hatip, J. Heikkilä, C. Johnson, G. Jolly, Z. Katzir, M. N. Kerema, H. Kitano, A. Krüger, K. M. Lee, J. R. López Portillo, A. McLysaght, O. Molchanovskyi, A. Monti, M. Nemer, N. Oliver, R. Pezoa, A. Plonk, B. Ravindran, H. Riza, C. Rugege, H. Sheikh, D. Wong, Y. Zeng, L. Zhu, D. Privitera, và S. Mindermann, "International AI safety report 2026," Department for Science, Innovation and Technology, Báo cáo kỹ thuật DSIT 2026/001, 2026 (trích dẫn ở tr. 6).

[55] *Đạo luật An toàn và Giáo dục AI có Trách nhiệm (RAISE Act)*, A6453B, Kỳ họp thường lệ 2025–2026 (N.Y. 2025), tháng 12 năm 2025 (trích dẫn ở tr. 7).

[56] J. Kwon và S. Casper, *Internal deployment gaps in AI regulation*, tháng 1 năm 2026. DOI: 10.48550/arXiv.2601.08005 (trích dẫn ở tr. 7).

[57] M. Pistillo, *Internal deployment in the AI Act*, tháng 6 năm 2026 (trích dẫn ở tr. 7).

[58] A. Chan, R. Padarath, J. Kwon, H. Greaves, và M. Anderljung, *Measuring AI R&D automation*, tháng 3 năm 2026. DOI: 10.48550/arXiv.2603.03992 (trích dẫn ở tr. 7).

[59] M. Brundage, N. Dreksler, A. Homewood, S. McGregor, P. Paskov, C. Stosz, G. Sastry, A. F. Cooper, G. Balston, S. Adler, S. Casper, M. Anderljung, G. Werner, S. Mindermann, V. Mavroudis, B. Bucknall, C. Stix, J. Freund, L. Pacchiardi, J. Hernandez-Orallo, M. Pistillo, M. Chen, C. Painter, D. W. Ball, C. O'Keefe, G. Weil, B. Harack, G. Finley, R. Hassan, S. Emmons, C. Foster, A. Reuel, B. Treece, Y. Bengio, D. Reti, R. Bommasani, C. Trout, A. S. Shamsabadi, R. Dattani, A. Weller, R. Trager, J. Sevilla, L. Wagner, L. Soder, K. Ramakrishnan, H. Papadatos, M. Murray, và R. Tovcimak, *Frontier AI auditing: Toward rigorous third-party assessment of safety and security practices at leading AI companies*, tháng 2 năm 2026. DOI: 10.48550/arXiv.2601.11699 (trích dẫn ở tr. 7).

[60] P. Wills, *Regulatory supervision of frontier AI developers*, Bài báo học thuật SSRN, Rochester, NY, tháng 3 năm 2025. DOI: 10.2139/ssrn.5122871 (trích dẫn ở tr. 7).

[61] Ủy ban Điều tiết Hạt nhân Hoa Kỳ (NRC), *Backgrounder on NRC resident inspectors*, 2023 (trích dẫn ở tr. 7).

[62] Văn phòng Kiểm toán Tiền tệ Hoa Kỳ (OCC), *What we do*, 2026 (trích dẫn ở tr. 7).

[63] M. Baker, G. Kulp, O. Marks, M. Brundage, và L. Heim, *Verifying international agreements on AI: Six layers of verification for rules on large-scale AI development and deployment*, tháng 7 năm 2025. DOI: 10.48550/arXiv.2507.15916 (trích dẫn ở tr. 7).

[64] B. Harack, R. F. Trager, A. Reuel, D. Manheim, M. Brundage, O. Aarne, A. Scher, Y. Pan, J. Xiao, K. Loke, S. N. Adan, G. Bas, N. A. Caputo, J. C. Morse, J. Ahuja, I. Duan, J. Egan, B. Bucknall, B. Rosen, R. Araujo, V. Boulanin, R. Lall, F. Barez, S. Alvira, C. Katzke, A. Atamli, và A. Awad, "Verification for international AI governance," Sáng kiến Quản trị AI Oxford Martin, Đại học Oxford, Báo cáo kỹ thuật, tháng 7 năm 2025 (trích dẫn ở tr. 7, 8).

[65] T. Larsen, R. Dean, B. Halstead, E. Lifland, R. Greenblatt, và D. Kokotajlo, *AI 2040: Plan A*, AI Futures Project, 2026 (trích dẫn ở tr. 7, 8).

[66] G. Sastry, L. Heim, H. Belfield, M. Anderljung, M. Brundage, J. Hazell, C. O'Keefe, G. K. Hadfield, R. Ngo, K. Pilz, G. Gor, E.

[68] S. Shoker, A. Reddie, S. Barrington, R. Booth, M. Brundage, H. Chahal, M. Depp, B. Drexel, R. Gupta, M. Favaro, J. Hecla, A. Hickey, M. Konaev, K. Kumar, N. Lambert, A. Lohn, C. O'Keefe, N. Rajani, M. Sellitto, R. Trager, L. Walker, A. Wehsener, và J. Young, *Confidence-building measures for artificial intelligence: Workshop proceedings*, tháng 8 năm 2023. DOI: 10.48550/arXiv.2308.00862 (trích dẫn ở tr. 8).

[69] Intelligence Rising, *Intelligence Rising*, k.n. (trích dẫn ở tr. 8).

[70] AI Futures Project, *About AI 2027: Tabletop exercise*, 2025 (trích dẫn ở tr. 8).

[71] G. Smith, G. Hage, C. Heitzenrater, M. Chessen, và R. S. Girven, "Infinite potential—insights from the cyber surprise scenario," RAND Corporation, Báo cáo kỹ thuật, tháng 3 năm 2026 (trích dẫn ở tr. 8).

[72] L. Vaintrob, *The AI adoption gap: Preparing the US government for advanced AI*, tháng 4 năm 2025 (trích dẫn ở tr. 8).

[73] OpenAI, *OpenAI model spec*, tháng 8 năm 2026 (trích dẫn ở tr. 8).

[74] Anthropic, *Claude's constitution*, tháng 1 năm 2026 (trích dẫn ở tr. 8).

[75] C. O'Keefe, K. Ramakrishnan, J. Tay, và C. Winter, "Law-following AI: Designing AI agents to obey human laws," *Fordham Law Review*, tập 94, số 1, tr. 57, 2025 (trích dẫn ở tr. 8).

[76] S. Guerra, A. Attal-Juncqua, J. P. Tarangelo, C. Aveggio, K. Dammer, và D. Glickstein, "Building a defense-in-depth biosecurity strategy for the AI era," RAND Corporation, Báo cáo kỹ thuật, tháng 8 năm 2026 (trích dẫn ở tr. 8).

[77] J.-S. Denain, A. Ho, và J. Sevilla, *How many digital workers could OpenAI deploy?* tháng 10 năm 2025 (trích dẫn ở tr. 12).

[78] H. Wijk, T. Lin, J. Becker, S. Jawhar, N. Parikh, T. Broadley, L. Chan, M. Chen, J. Clymer, J. Dhyani, E. Ericheva, K. Garcia, B. Goodrich, N. Jurkovic, H. Karnofsky, M. Kinniment, A. Lajko, S. Nix, L. Sato, W. Saunders, M. Taran, B. West, và E. Barnes, *RE-Bench: Evaluating frontier AI R&D capabilities of language model agents against human experts*, tháng 5 năm 2025. DOI: 10.48550/arXiv.2411.15114 (trích dẫn ở tr. 12).

[79] A. Ho, J.-S. Denain, D. Atanasov, S. Albanie, và R. Shah, *A rosetta stone for AI benchmarks*, 2025 (trích dẫn ở tr. 13).

[80] B. Cottier, B. Snodin, D. Owen, và T. Adamczewski, *LLM inference prices have fallen rapidly but unequally across tasks*, tháng 3 năm 2025 (trích dẫn ở tr. 13, 14).

[81] H. Gundlach, A. Fogelson, J. Lynch, A. Trisovic, J. Rosenfeld, A. Sandhu, và N. Thompson, *On the origin of algorithmic progress in AI*, tháng 11 năm 2025. DOI: 10.48550/arXiv.2511.21622 (trích dẫn ở tr. 13).

Bluemke, S. Shoker, J. Egan, R. F. Trager, S. Avin, A. Weller, Y. Bengio, và D. Coyle, *Computing power and the governance of artificial intelligence*, tháng 2 năm 2024. DOI: 10.48550/arXiv.2402.08797 (trích dẫn ở tr. 7).

[67] A. Korinek và J. E. Stiglitz, *Steering technological progress*, Báo cáo nghiên cứu (Working Paper), tháng 3 năm 2026. DOI: 10.3386/w34994 (trích dẫn ở tr. 8).

[82] P. Trammell, "The bounded parallelizability of R&D: Theory and application to AI," tháng 7 năm 2026 (trích dẫn ở tr. 13).

[83] METR, *Measuring AI ability to complete long tasks*, tháng 3 năm 2025 (trích dẫn ở tr. 13).

[84] D. Kokotajlo, S. Alexander, T. Larsen, E. Lifland, và R. Dean, *AI 2027*, tháng 4 năm 2025 (trích dẫn ở tr. 14).

[85] T. Ord, *The dynamics of intelligence explosions*, 2026. arXiv: 2608.14426 [cs.AI] (trích dẫn ở tr. 14).

[86] B. Murphy và T. Stone, *Uplifted attackers, human defenders: The cyber offense-defense balance for trailing-edge organizations*, tháng 8 năm 2025. DOI: 10.48550/arXiv.2508.15808 (trích dẫn ở tr. 14).

[87] Anthropic, *Investigating three real-world incidents in our cybersecurity evaluations*, Tháng 7, 2026 (trích dẫn ở tr. 14).

[88] UK AI Security Institute, *Incident report: Unsanctioned agent behaviour during cyber testing*, Tháng 8, 2026 (trích dẫn ở tr. 14).

[89] OpenAI, *Third-party cyber evaluations involving OpenAI models*, Tháng 8, 2026 (trích dẫn ở tr. 14).

[90] P. C. Bogdan, R. Qi, J. Eaton, S. Kennedy, F. Roger, A. Glynn, R. Chen, B. Wright, O. Stegmaier, J. Kutasov, D. Foreman-Mackey, T. Bricken, S. Carr, S. Carter, M. MacDiarmid, S. Marks, A. Pearce, E. Simon, N. Carlini, C. Burns, J. Lindsey, S. Price, và S. Kantamneni, *An alignment assessment of recent cybersecurity incidents*, Anthropic, Tháng 9, 2026 (trích dẫn ở tr. 14).

[91] M. H. Tessler, M. A. Bakker, D. Jarrett, H. Sheahan, M. J. Chadwick, R. Koster, G. Evans, L. Campbell-Gillingham, T. Collins, D. C. Parkes, M. Botvinick, và C. Summerfield, "AI can help humans find common ground in democratic deliberation," *Science*, tập 386, số 6719, eadq2852, Tháng 10, 2024. DOI: 10.1126/science.adq2852 (trích dẫn ở tr. 14).

[92] A. Goldie và A. Mirhoseini, *How AlphaChip transformed computer chip design*, Tháng 9, 2024 (trích dẫn ở tr. 14).

Tài liệu bổ sung

Ước tính quy mô hiệu dụng của lực lượng lao động AI

Theo phương pháp của Denain và cộng sự [77], chúng tôi ước tính lực lượng lao động hiệu dụng bằng cách lấy số lượng token mà một nhà phát triển có thể tạo ra mỗi ngày chia cho số lượng token tương ứng với một ngày làm việc của một nhà nghiên cứu. Riêng OpenAI đã sở hữu đủ năng lực tính toán suy luận (tức là tài nguyên tính toán khi vận hành mô hình) để tạo ra khoảng 10^{13} token mỗi ngày. Để ước tính số token trên mỗi ngày làm việc của một nhà nghiên cứu, chúng tôi sử dụng số lượng token mà mô hình tạo ra cho một tác vụ tiêu tốn của một nhà nghiên cứu con người một ngày làm việc (8 giờ). Trong một bài đánh giá chuẩn về R&D AI, Wijk và cộng sự [78] và những cải tiến về năng lực (các hệ thống AI mới thực hiện được những nhiệm vụ mà các hệ thống trước đây không thể thực hiện, hoặc đạt hiệu suất cao hơn mức các hệ thống trước đó có thể đạt được). Đáng tiếc là hiện vẫn chưa rõ tham số A nên cân đối tối ưu như thế nào giữa các cải tiến về hiệu quả và các cải tiến về năng lực (hoặc giữa các dạng cải tiến hiệu quả và cải tiến năng lực khác nhau).

Tạm gác lại vấn đề này, chúng tôi mô hình hóa sự gia tăng của chất lượng phần mềm bằng phương trình $dA/dt = A^{1-\beta}E^{\lambda}$, một dạng hàm phổ biến trong kinh tế học vĩ mô về đổi mới sáng tạo [27]. Để đơn giản hóa, chúng tôi bỏ qua các nút thắt tiềm tàng từ tài nguyên tính toán và dữ liệu. Tại đây, E là lực lượng lao động R&D hiệu dụng, λ thể hiện hiệu suất theo quy mô của lao động R&D, và β thể hiện việc tìm kiếm các ý tưởng mới theo thời gian có hiệu suất tăng dần hay giảm dần.

Câu hỏi then chốt là E tăng trưởng theo A như thế nào. Giả định tự động hóa hoàn toàn, chúng tôi xem xét hai trường hợp. Đầu tiên, hãy xét trường hợp mà tất cả các cải tiến về chất lượng phần mềm đều là sự gia tăng hiệu quả tính toán suy luận, nghĩa là giảm lượng tài nguyên tính toán cần thiết để chạy một hệ thống AI ở một mức năng lực nhất định. Trong trường hợp đó, nếu A đo lường hiệu quả suy luận, thì E tỷ lệ thuận với A: hiệu quả suy luận cao hơn cho phép vận hành nhiều nhà nghiên cứu tự động hơn theo tỷ lệ thuận tương ứng.

Thứ hai, xét trường hợp mà tất cả các cải tiến về chất lượng phần mềm đều là sự gia tăng năng lực, được thúc đẩy bởi các cải tiến về hiệu quả tính toán huấn luyện: giảm lượng tài nguyên tính toán cần thiết để huấn luyện một hệ thống AI đạt đến một mức năng lực nhất định, cho phép huấn luyện một hệ thống có năng lực cao hơn với một lượng tài nguyên tính toán cố định. Nếu A đo lường hiệu quả tính toán huấn luyện, thì sự gia tăng của A sẽ tạo ra các hệ thống có năng lực cao hơn thay vì tạo ra số lượng hệ thống nhiều hơn. Nếu chúng ta đưa ra giả định (có thể còn

nhận thấy rằng các mô hình tạo ra trung bình $5 \cdot 10^5$ token trong các lượt chạy kéo dài tới 8 giờ, ngụ ý một lực lượng lao động hiệu dụng tương đương khoảng $2 \cdot 10^7$ nhà nghiên cứu. Tính đến độ bất định khoảng một bậc độ lớn theo cả hai hướng ($5 \cdot 10^4$ – $5 \cdot 10^6$ token trên mỗi ngày làm việc của nhà nghiên cứu), chúng tôi ước tính lực lượng lao động hiệu dụng nằm trong khoảng $2 \cdot 10^6$ – $2 \cdot 10^8$. Tương tự như trong nội dung chính, ước tính này giả định rằng các hệ thống AI cấp độ chuyên gia có chi phí vận hành tương đương với các hệ thống hiện nay.

Mô hình hóa vòng phản hồi dưới điều kiện tự động hóa hoàn toàn

Hầu hết các phân tích về sự bùng nổ trí tuệ do phần mềm dẫn dắt đều mô tả tiến trình phát triển của AI thông qua một khái niệm về chất lượng phần mềm, ký hiệu là A. Về nguyên tắc, A phải đo lường tiến bộ của AI một cách toàn diện, bao gồm cả những cải tiến về hiệu quả (các hệ thống AI mới thực hiện cùng các nhiệm vụ như hệ thống cũ, với hiệu suất tương đương, nhưng sử dụng ít tài nguyên tính toán hoặc dữ liệu hơn) gây tranh cãi) rằng số lượng nhà nghiên cứu hiệu dụng tăng tỷ lệ tuyến tính với các mức gia tăng năng lực này, thì E lại tỷ lệ thuận với A.

Trong cả hai trường hợp, $E = kA$ với một hằng số dương k nào đó. Thay vào phương trình phía trên, ta được $dA/dt = cA^{\lambda-\beta+1}$, trong đó $c = k^{\lambda}$. Để tốc độ tăng trưởng $(1/A)dA/dt$ tăng lên khi chất lượng phần mềm tăng, ta cần điều kiện $\lambda > \beta$. Định nghĩa $r = \lambda/\beta$, chúng ta thu được điều kiện $r > 1$ như đã thảo luận trong phần nội dung chính.

Tiến trình có thể tăng tốc nhanh đến mức nào theo các ước tính hiện tại về các tham số này? Chúng tôi đo lường sự gia tốc bằng tốc độ tăng trưởng của chất lượng phần mềm: $(1/A)dA/dt = c \cdot A^{\lambda-\beta}$. Lấy giá trị trung bình từ các ước tính trung tâm trên ba lĩnh vực con trong Ho và

Whitfill [28] cho ta $\lambda = 1{,}40$ và $\beta = 1{,}01$. Với $\lambda - \beta = 0{,}39$, mỗi lần A tăng gấp đôi sẽ nhân tốc độ tăng trưởng lên $2^{0{,}39} \approx 1{,}31$ lần, do đó mỗi lần tăng gấp đôi tiếp theo chỉ mất $(1/2)^{0{,}39} \approx 76\%$ thời gian so với lần trước đó. Để tốc độ tăng trưởng tăng lên gấp mười lần, A cần tăng gấp đôi $\log_2(10)/0{,}39 \approx 8{,}5$ lần. Đối với khoảng thời gian của lần tăng gấp đôi đầu tiên, chúng tôi sử dụng các ước tính gần đây cho thấy, chỉ riêng nhờ những cải tiến phần mềm, hiệu quả tính toán huấn luyện tăng gấp đôi sau khoảng mỗi 4,5 tháng [79]; hiệu quả tính toán suy luận thậm chí có thể còn tăng trưởng nhanh hơn [80]. Để tránh việc phải tính xấp xỉ chuỗi cấp số nhân cho 8,5 lần tăng gấp đôi, chúng tôi tính tổng cấp số nhân cho 9 lần tăng gấp đôi, sau khoảng thời gian này tốc độ tăng trưởng sẽ

Các yếu tố khác có thể hàm ý một giá trị r cao hơn. Hầu hết các ước tính về r đều bỏ qua các cải tiến ở những lĩnh vực nằm ngoài giai đoạn tiền huấn luyện (pre-training), chẳng hạn như giai đoạn sau huấn luyện (post-training) hoặc cấu trúc dàn dựng (scaffolding) tốt hơn cho việc sử dụng công cụ [35]. Hơn nữa, những cải tiến về năng lực có thể tạo ra tác động theo những cách mà số lượng nhà nghiên cứu hiệu dụng không thể phản ánh hết: ngay cả một số lượng cực kỳ lớn các nhà nghiên cứu có năng lực trung bình cũng không thể thay thế cho một nhà nghiên cứu thiên tài. Nếu đúng như vậy, sự gia tăng năng lực sẽ mở rộng lực lượng lao động R&D hiệu dụng nhiều hơn so với mức mà giả định tuyến tính ở trên đưa ra. Các nút thắt về năng lực tính toán cũng có thể được giải quyết bằng các biện pháp vòng

tăng hơn mười lần. Khi thực hiện phép tính, chúng tôi nhận thấy tốc độ tăng trưởng sẽ tăng hơn mười lần sau $4{,}5\ \text{tháng} \times (1-0{,}76^9)/(1-0{,}76) \approx 17\ \text{tháng}$, tức khoảng 1,5 năm. Tại thời điểm đó, tiến trình phát triển sẽ nhanh gấp mười lần so với hiện nay, vì vậy khối lượng tiến bộ tương đương một năm với tốc độ hiện nay sẽ chỉ mất khoảng năm tuần.

Những yếu tố bất định về hiệu suất sinh lợi của nỗ lực nghiên cứu

Một số yếu tố có thể khiến giá trị thực tế của r khác biệt so với các ước tính hiện có. Thứ nhất, như đã lưu ý ở trên, hiện vẫn chưa rõ thước đo chất lượng phần mềm nào là phù hợp nhất. Hiệu quả suy luận phản ánh trực tiếp nhất quy mô của lực lượng lao động R&D tự động, trong khi vẫn chưa rõ làm thế nào để quy đổi các mức tăng hiệu quả huấn luyện thành số lượng nhà nghiên cứu hiệu dụng. Tuy nhiên, các ước tính hiện tại về r đối với R&D AI lại sử dụng hiệu quả huấn luyện, và người ta vẫn chưa biết liệu hiệu suất sinh lợi từ nỗ lực nghiên cứu dưới hai thước đo này có tương đồng hay không. Hơn nữa, một đánh giá chuẩn xác về hiệu suất sinh lợi của nỗ lực nghiên cứu cần bao gồm những cải tiến từ cả hiệu quả suy luận lẫn hiệu quả huấn luyện, thay vì chỉ xét một khía cạnh đơn lẻ. Cần có thêm nhiều nghiên cứu để xây dựng một đặc tả về chất lượng phần mềm tích hợp được cả hiệu quả suy luận lẫn hiệu quả huấn luyện và cân nhắc trọng số giữa chúng một cách hợp lý.

Các ước tính hiện tại về r bắt nguồn từ một giai đoạn mở rộng quy mô tính toán (compute scaling) nhanh chóng, điều này làm xáo trộn và khó phân tách sự đóng góp giữa tiến bộ phần mềm và mở rộng quy mô tính toán. Do hai yếu tố đầu vào này trong lịch sử luôn tăng trưởng cùng nhau, một ước tính quy toàn bộ tiến bộ quan sát được cho những cải tiến phần mềm có thể trên thực tế lại đang phản ánh những bước tiến do năng lực tính toán ngày càng tăng thúc đẩy, hoặc chỉ có thể thực hiện được nhờ vào tài nguyên tính toán lớn. Một số cải tiến phần mềm phụ thuộc vào quy mô: ví dụ, kiến trúc tránh, chẳng hạn như thông qua việc ngoại suy tốt hơn từ các thử nghiệm quy mô nhỏ, giảm chi phí thử nghiệm nhờ tiến bộ phần mềm, chuyển hướng sang các phương pháp ít phụ thuộc vào tính toán hơn, và tiến bộ về thuật toán mà không đòi hỏi phải thử nghiệm [7].

Các ước tính về r cũng dựa trên các đại lượng thay thế (proxies) không hoàn hảo cho lao động R&D, điều này có thể làm sai lệch kết quả theo cả hai hướng. Ví dụ, Ho và Whitfill [28] lấy số lượng tác giả duy nhất đã xuất bản các bài báo trong một lĩnh vực làm đại lượng đại diện cho lao động R&D. Việc xác định phạm vi lĩnh vực quá hẹp sẽ đánh giá thấp lao động bằng cách loại trừ các lĩnh vực lân cận vốn cũng thúc đẩy tiến bộ, trong khi xác định phạm vi quá rộng lại tính trùng lặp và thổi phồng lượng lao động. Trừ khi các lĩnh vực lân cận bị loại trừ có cùng tốc độ tăng trưởng lao động như các lĩnh vực được đưa vào, sự sai lệch này sẽ dẫn đến việc tính toán sai r.

Cuối cùng, các mô hình toán học liên quan có thể không khái quát hóa được cho khối lượng lao động R&D cực lớn [82]. Trong lịch sử, chúng được kiểm chứng dựa trên các tốc độ tăng trưởng chỉ vài phần trăm mỗi năm, thấp hơn nhiều so với tốc độ hai chữ số hoặc cao hơn mà một vụ bùng nổ trí tuệ có thể tạo ra. Chúng cũng bị phá vỡ ở điểm giới hạn, khi hàm ý rằng lượng lao động vô hạn sẽ tạo ra tiến bộ vô hạn trong một khoảng thời gian hữu hạn. Nhưng các ràng buộc trong thực tế khiến kết quả này là bất khả thi: một số vấn đề bắt buộc phải được giải quyết theo trình tự tuần tự, và phần cứng vật lý chỉ có thể hoạt động nhanh đến một giới hạn nhất định.

Ghi chú

1. Các địa điểm tổ chức hội nghị học máy thường có một phiên hội nghị chính và một vài phiên hội thảo (workshop). Một lưu ý đối với các kết quả là các phiên hội thảo này có thể có tiêu chuẩn xét duyệt lỏng lẻo hơn đôi chút so với phiên hội nghị chính.
2. Theo thước đo chân trời thời gian của METR [17, 83], độ dài của các tác vụ mà hệ thống AI

transformer mang lại mức tăng hiệu suất lớn ở quy mô tính toán huấn luyện cao nhưng lại mang lại mức tăng tương đối nhỏ ở quy mô tính toán thấp [81]. Sự xáo trộn này sẽ làm sai lệch các ước tính về r theo hướng thổi phồng lên: trong một kịch bản mà tài nguyên tính toán cố định hoặc tăng trưởng chậm, r sẽ thấp hơn so với dữ liệu lịch sử gợi ý.

có thể hoàn thành ban đầu tăng gấp đôi khoảng mỗi 7 tháng một lần, và đã tăng tốc lên khoảng mỗi 3 tháng một lần kể từ năm 2024. Ngoại suy xu hướng gần đây này cho thấy vào giữa năm 2028, các hệ thống AI sẽ có khả năng hoàn thành các tác vụ đòi hỏi vài tháng làm việc của chuyên gia con người

3. thời gian, nằm trọn trong phạm vi thời lượng của nhiều dự án R&D AI. Xem thêm Kokotajlo và cộng sự [84].

4. Cottier và cộng sự [80] nhận thấy chi phí vận hành các LLM để đạt được một cột mốc năng lực nhất định (ví dụ: hiệu suất tương đương GPT-4 trên một bài đánh giá chuẩn về toán học) đã giảm khoảng 9 đến 900 lần mỗi năm, tùy thuộc vào cột mốc năng lực đó. Mặc dù một phần của sự sụt giảm chi phí này đến từ những cải tiến phần cứng (giảm chi phí cho mỗi phép tính toán), một tỷ trọng đáng kể là nhờ vào các cải tiến phần mềm.

5. Trong một lĩnh vực công nghệ, r chi phối mối quan hệ giữa các mức gia tăng đầu vào R&D và sự thay đổi kết quả đầu ra được quan tâm, chẳng hạn như số lượng phép tính toán mà phần cứng tiêu dùng tối tân có thể thực hiện trên mỗi đơn vị đô la cố định. Trong Bloom và cộng sự [27], đầu vào được đo bằng số đô la chi cho R&D và do đó bao gồm cả sự gia tăng về lao động lẫn vốn vật chất. Tuy nhiên, trong nghiên cứu này, chúng tôi chỉ xem xét sự gia tăng về lao động, vì chúng tôi quan tâm đến việc tìm hiểu tiềm năng của một vòng phản hồi do phần mềm dẫn dắt, trong đó tổng lượng tài nguyên tính toán được giữ gần như không đổi. Điều này có nghĩa là giá trị của r thấp hơn so với khi chúng tôi xem xét sự gia tăng của tất cả các yếu tố đầu vào (nghĩa là lao động, dữ liệu và tài nguyên tính toán).

6. r cuối cùng phải giảm xuống dưới 1 vì tiến bộ AI cuối cùng sẽ chạm tới các giới hạn tính toán và giới hạn vật lý. Hiện chưa thể chắc chắn rằng có thể đạt được bao nhiêu tiến bộ trước khi chạm tới các giới hạn như vậy.

7. Các khoảng khả tín 90% lần lượt là (0,727 đến 2,094), (0,380 đến 2,708), và (1,069 đến 3,212).

8. Trong phân tích này, những cải tiến về hiệu quả thuật toán tự bản thân chúng không giải quyết được nút thắt tiềm tàng này, bởi vì chúng làm tăng hiệu quả của cả R&D lẫn quá trình huấn luyện theo tỷ lệ tương đương nhau.

9. Cụ thể, bài báo cung cấp các điều kiện mà theo đó lao động nghiên cứu tự động, cùng với các đại lượng khác như sản lượng kinh tế, sẽ tăng tới vô hạn trong một khoảng thời gian hữu hạn.

10. Xem Ord [85] để biết thêm thảo luận mang tính lý thuyết về việc khoảng thời gian giữa các chu kỳ R&D có thể ảnh hưởng như thế nào đến động lực học của một vụ bùng nổ trí tuệ.

11. Phân tích trong Cunningham và cộng sự [37] tập trung vào sự gia tốc tự duy trì: “Khi các hệ thống AI là đủ để đẩy nhanh tiến độ về năng lực AI mà không cần bất kỳ sự gia tăng nào về các yếu tố đầu vào ngoại sinh (lao động con người, tài nguyên tính toán huấn luyện, v.v.).” Sự gia tốc tự duy trì là điều kiện cần cho một vụ bùng nổ trí tuệ do phần mềm dẫn dắt theo định nghĩa của chúng tôi.

12. Các hệ thống như vậy có thể đạt mức siêu phàm trong một số lĩnh vực (ví dụ: các lĩnh vực nghiên cứu khoa học nhất định) nhưng lại không đạt được điều đó trong các lĩnh vực khác (ví dụ: thao tác với các

vật thể trong thế giới vật lý).

13. Tuy nhiên, ngay cả trong không gian mạng, các quy trình tổ chức của con người vẫn có thể tạo ra lực cản và sự trì trệ cho phe phòng thủ [86].

14. Xem thêm Anthropic [87], Viện An toàn AI Vương quốc Anh (UK AI Security Institute) [88], OpenAI [89], và Bogdan và cộng sự [90].

15. Ví dụ, xem Tessler và cộng sự [91]. Suy đoán xa hơn, các hệ thống AI có khả năng đẩy nhanh sự phát triển của các giao diện não - máy tính, cho phép con người tư duy và phối hợp nhanh hơn rất nhiều.

16. Việc cụ thể hóa chính xác thành các chỉ số thao tác cho một vụ bùng nổ trí tuệ là rất phức tạp và vẫn là một chủ đề cho các nghiên cứu trong tương lai.

17. Ví dụ, AI hiện đã và đang hỗ trợ đắc lực cho việc thiết kế vi mạch [92]. Các hệ thống AI cũng có thể thúc đẩy ngành chế tạo robot để tự động hóa hoàn toàn quy trình sản xuất vi mạch.