Điều gì sẽ xảy ra nếu việc tự động hóa nghiên cứu và phát triển AI kích hoạt một vụ bùng nổ trí tuệ?

Chuỗi Báo cáo Nghiên cứu AI Tiên phong Số 2/2026
Tháng 9 năm 2026

Điều gì sẽ xảy ra nếu việc tự động hóa R&D AI kích hoạt một vụ bùng nổ trí tuệ?

Alan Chan*
GovAI

Christoph Winter
CASP, Đại học Cambridge, Viện Luật & AI

Andrew Barto
Đại học Massachusetts Amherst

Jakub Pachocki
OpenAI

Geoffrey Hinton
Đại học Toronto, Viện Vector

Eric Horvitz
Microsoft

Yoshua Bengio
Mila (Viện AI Quebec), Đại học Montréal, LawZero

Dawn Song
Đại học California, Berkeley

Jack Clark
Anthropic

Hilary Greaves
Đại học Oxford

Anton Korinek
Đại học Virginia, Anthropic

Samuel Hammond
Quỹ Đổi mới Hoa Kỳ (Foundation for American Innovation)

Thore Graepel
University College London

Ben Bariach
Đại học Oxford

Philip H. S. Torr
Đại học Oxford

Sheila A. McIlraith
Đại học Toronto, Viện Vector

Jeff Clune
Đại học British Columbia, Viện Vector

Sam Manning
GovAI, Quỹ Đổi mới Hoa Kỳ

Girish Sastry
Guidelight

Tom Davidson
Forethought

Daniel Eth
Viện Chính sách AI (AI Policy Institute)

Sören Mindermann*
CASP, Đại học Cambridge

Tóm tắt

Trái ngược hoàn toàn với bối cảnh chỉ một năm trước, các hệ thống AI hiện nay đã tự viết phần lớn mã nguồn tại chính các công ty phát triển ra chúng. Khi ngày càng nhiều khâu trong chu trình nghiên cứu và phát triển (R&D) AI được tự động hóa, liệu tiến trình phát triển AI có thể tăng tốc đột phá thành một "vụ bùng nổ trí tuệ", nơi những bước tiến của cả nhiều năm bị nén lại chỉ trong vài tháng hoặc thậm chí ngắn hơn? Bằng chứng sơ bộ cho thấy điều này hoàn toàn có thể xảy ra. Trong công trình này, chúng tôi đánh giá các bằng chứng này, phân tích những tác động tiềm tàng của một vụ bùng nổ trí tuệ và đề xuất các phản ứng chính sách tương ứng. Các hệ thống AI hiện đang trên đà tự động hóa phần lớn công việc R&D AI trong vòng vài năm tới, và có khả năng là toàn bộ. Nếu điều này kích hoạt một vụ bùng nổ trí tuệ, nó có thể mang lại những lợi ích của AI sớm hơn đáng kể, nhưng đồng thời cũng đặt ra những rủi ro cực hạn: sự gia tăng năng lực có thể tăng tốc vượt xa ngưỡng xã hội có thể thích ứng kịp, nhân loại có thể mất quyền kiểm soát đối với các hệ thống AI siêu phàm, và các cơ chế kiểm soát quyền lực bên trong cũng như giữa các quốc gia, các tập đoàn và các nhánh của chính phủ có thể bị xói mòn nghiêm trọng. Mặc dù vẫn còn nhiều yếu tố bất định xoay quanh các kịch bản này, nhưng mức độ hệ trọng to lớn của chúng đòi hỏi sự quan tâm nghiên cứu nghiêm túc hơn nữa. Các nhà hoạch định chính sách cần khẩn trương nắm bắt rõ ràng hơn thực trạng tự động hóa R&D AI, xây dựng các phương thức nhằm định hướng và kiềm chế một vụ bùng nổ trí tuệ, đồng thời chuẩn bị cho xã hội khả năng thích ứng với những tác động sâu sắc của nó.

---

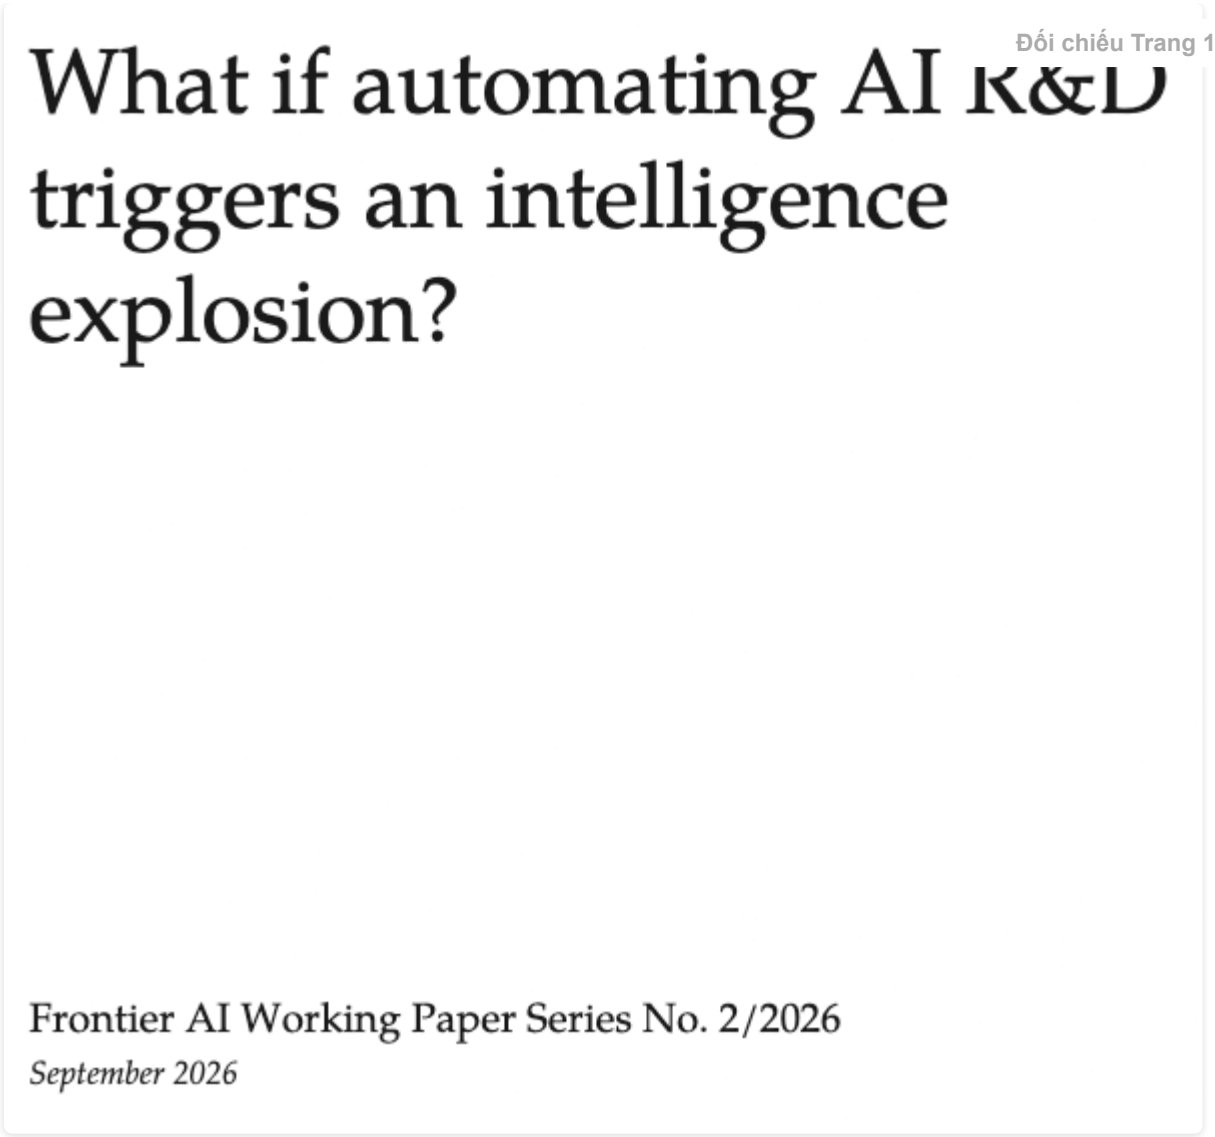
*Tác giả liên hệ: alan.chan@governance.ai và soren.mindermann@casp.ac. Các quan điểm trình bày trong bài báo này là của riêng các tác giả và không nhất thiết phản ánh quan điểm của các tổ chức mà họ trực thuộc.

Giới thiệu

Các nhà khoa học máy tính từ lâu đã đưa ra giả thuyết rằng các hệ thống AI một ngày nào đó sẽ tự thiết kế ra các thế hệ kế cận ngày càng ưu việt hơn, tạo ra những hệ thống nhanh chóng áp đảo về số lượng, vượt trội về tốc độ và vượt bậc về hiệu năng so với con người [1–3]. Ngày nay, các công ty AI tiên phong đang hướng tới mục tiêu tự động hóa hoạt động Nghiên cứu và Phát triển (R&D) AI [4, 5], đồng thời huy động nguồn vốn tính theo tỷ trọng GDP của Hoa Kỳ lớn hơn cả Dự án Manhattan và Chương trình Apollo cộng lại [6]. Điều gì sẽ xảy ra nếu họ thành công?

Mối quan tâm trọng tâm của chúng tôi là khả năng xảy ra một **vụ bùng nổ trí tuệ**: một bước tăng tốc đột biến do chính AI thúc đẩy đối với tiến trình phát triển AI, rút ngắn những bước tiến vốn phải mất nhiều năm xuống chỉ còn vài tháng hoặc ít hơn. Sự tăng tốc này sẽ là một bước chuyển biến về chất so với đà tiến bộ nhanh chóng nhưng phần lớn vẫn giữ nhịp độ ổn định trong vài năm qua.

Một vụ bùng nổ trí tuệ có thể bắt nguồn từ việc AI đóng góp vào các bước tiến về phần cứng và/hoặc phần mềm. Những tiến bộ về phần cứng giúp nâng cao chất lượng và số lượng phần cứng tính toán (compute) dùng để phát triển và vận hành các hệ thống AI. Những tiến bộ về phần mềm giúp cải thiện dữ liệu, thuật toán, mã nguồn và các quy trình sử dụng trong R&D AI; bao gồm quá trình huấn luyện và suy luận hiệu quả hơn trên phần cứng hiện có [7–9], công tác quản lý và vận hành nghiên cứu được cải tiến, môi trường huấn luyện và dữ liệu tổng hợp tốt hơn [10, 11], cùng các hệ hình (paradigm) mới mẻ trong AI [12, 13]. Những tiến bộ về phần mềm cần được đặc biệt lưu tâm trong ngắn hạn vì hai lý do. Thứ nhất, các hệ thống AI dường như đang nhanh chóng hoàn thiện năng lực tự thực hiện R&D AI, giúp chúng tạo ra các bước tiến bộ đó hiệu quả hơn. Thứ hai, các tiến bộ phần mềm cho phép tạo ra các vòng phản hồi nhanh chóng: các hệ thống AI cải tiến có thể được tái triển khai vào quy trình R&D gần như ngay lập tức, trong khi những cải tiến về phần cứng thường phụ thuộc vào các chu kỳ xây dựng và chế tạo kéo dài nhiều năm. Do đó, bài viết này tập trung vào khả năng xảy ra một vụ bùng nổ trí tuệ do phần mềm dẫn dắt, nơi quá trình tự động hóa R&D AI thúc đẩy sự bùng nổ trí tuệ hoàn toàn chỉ thông qua các tiến bộ phần mềm [14].



Hình 1. Các nhà hoạch định chính sách cần khẩn trương: (1) nắm bắt và theo dõi sát sao hoạt động tự động hóa R&D AI bên trong các công ty AI tiên phong; (2) phát triển các phương thức điều phối và kiềm chế vụ bùng nổ trí tuệ; và (3) chuẩn bị thích ứng với những tác động của một vụ bùng nổ trí tuệ.

Chú giải các nhãn & thuật ngữ trong sơ đồ gốc:

- **Priority 1 · Obtain visibility into AI R&D automation:** Ưu tiên 1 · Nắm bắt và theo dõi hoạt động tự động hóa R&D AI
- **Governments and/or Auditors:** Chính phủ và/hoặc Các tổ chức kiểm toán
- **Obtain → AI R&D metrics from frontier AI companies:** Thu thập → Các chỉ số đo lường R&D AI từ các công ty AI tiên phong
- **Evaluate → Frontier AI systems used for AI R&D:** Đánh giá → Các hệ thống AI tiên phong được dùng cho R&D AI
- **Supervise/Audit → Internal AI R&D activities at frontier AI companies:** Giám sát/Kiểm toán → Các hoạt động R&D AI nội bộ tại các công ty AI tiên phong
- **Priority 2 · Develop ways to steer and constrain an intelligence explosion:** Ưu tiên 2 · Phát triển các phương thức điều phối và kiềm chế vụ bùng nổ trí tuệ
- **Incentivize → Alignment & control R&D, Beneficial AI applications:** Khuyến khích → R&D
- **Oversee → Scale-ups of automated AI R&D:** Giám sát → Quá trình mở rộng quy mô R&D AI tự động hóa

về kiểm soát và căn chỉnh (alignment), Các ứng dụng AI hữu ích	
Manage → International dynamics: Quản lý → Động thái quốc tế	**Build → Optionality of pacing AI progress:** Xây dựng → Các phương án điều tiết nhịp độ tiến bộ của AI
Priority 3 · Prepare to adapt to an intelligence explosion: Ưu tiên 3 · Chuẩn bị thích ứng với vụ bùng nổ trí tuệ	**The public:** Công chúng
Oversees: Giám sát	**Increase resilience to → Misuse by non-state actors:** Tăng cường khả năng chống chịu trước → Việc lạm dụng bởi các chủ thể phi nhà nước
Accelerate → Institutional response times: Đẩy nhanh → Thời gian phản ứng của các thể chế	**Create safeguards for → Government use of AI:** Thiết lập các cơ chế bảo đảm an toàn cho → Hoạt động sử dụng AI của chính phủ

Các bằng chứng sơ bộ cho thấy một vụ bùng nổ trí tuệ do phần mềm dẫn dắt là hoàn toàn khả thi. Nếu điều này xảy ra, đây có thể là bước phát triển công nghệ có tầm ảnh hưởng lớn nhất trong lịch sử: các hệ thống AI có thể nhanh chóng làm lu mờ các chuyên gia con người trên hầu hết các lĩnh vực và thúc đẩy tiến bộ công nghệ một cách triệt để. Trước những hệ quả to lớn và khung thời gian hành động có thể rất hẹp, chúng tôi lập luận rằng việc chuẩn bị ứng phó với một vụ bùng nổ trí tuệ cần phải là ưu tiên cấp bách, bao gồm cả ở những cấp lãnh đạo cao nhất của chính phủ.

AI đang nhanh chóng tự động hóa hoạt động R&D AI

Các hệ thống AI hiện nay đã có thể hỗ trợ hoặc tự chủ thực hiện các phân đoạn trọng yếu trong toàn bộ quy trình R&D AI. Trái ngược với tình hình chỉ mới một năm trước, đội ngũ nhân sự R&D tại các công ty AI hàng đầu hiện đã ủy quyền các nhiệm vụ R&D cốt lõi cho các nhóm hệ thống AI, và một số nơi đã ủy thác toàn bộ công việc lập trình. Anthropic báo cáo rằng tỷ lệ mã nguồn được phê duyệt do hệ thống AI tạo ra đã tăng từ mức một con số thấp lên hơn 80% trong giai đoạn từ tháng 1 năm 2025 đến tháng 5 năm 2026 [5], trong khi tỷ lệ công việc R&D được hoàn thành hoàn toàn tự chủ mà chỉ cần sự giám sát cấp cao của con người đã tăng từ 1% lên 26% trong giai đoạn từ tháng 3 đến tháng 8 năm 2026 [15]. OpenAI cho biết "sự hỗ trợ của AI được sử dụng trong hầu như mọi bộ phận của công ty xuyên suốt các nhóm kỹ thuật và phi kỹ thuật, với các tác tử thực thi mã nguồn được dùng trong việc huấn luyện, đánh giá và bảo mật các mô hình tương lai", và Google thông báo rằng "AI được ứng dụng trong hầu hết mọi công việc liên quan đến viết mã nguồn hoặc cấu hình, thiết kế kỹ thuật, đề xuất ý tưởng nghiên cứu, với các mức độ khác nhau tùy thuộc vào nhiệm vụ" [16].

Các hệ thống AI tốt nhất hiện nay có thể hoàn thành những nhiệm vụ R&D AI mà các chuyên gia con người phải mất hàng giờ đến nhiều ngày, so với việc chỉ hoàn thành được các nhiệm vụ tính bằng giây vào năm 2023 [17–19]. Các hệ thống AI đôi khi còn vượt qua cả các chuyên gia con người: chúng đã tự chủ tạo ra các giải pháp ưu việt hơn cho một bài toán nghiên cứu về an toàn AI [20], và trong một số tình huống đã dự đoán chính xác hơn ý tưởng nghiên cứu nào sẽ mang lại kết quả [21] cũng như bước tiếp theo nào đáng để triển khai [5]. Trong một thử nghiệm chứng minh khái niệm ban đầu, một quy trình nghiên cứu AI tự động đã tự đề xuất ý tưởng nghiên cứu, thực hiện các thí nghiệm và viết

một bài báo vượt qua vòng bình duyệt tại một hội thảo thuộc khuôn khổ hội nghị hàng đầu về học máy [22].[1]

Các hệ thống AI ngày nay vẫn còn tồn tại nhiều nhược điểm. Đôi khi chúng không tuân thủ chỉ dẫn, gian lận khi thực hiện nhiệm vụ, trình bày sai lệch kết quả công việc và hoàn toàn không thể hoàn thành một số tác vụ nhất định, đòi hỏi phải có sự can thiệp của con người [23–25]. Ví dụ, GPT-6 thất bại trước một số nhiệm vụ gỡ lỗi nghiên cứu của OpenAI mà các nhà nghiên cứu con người giàu kinh nghiệm có thể giải quyết được (dù phải mất hàng giờ hoặc nhiều ngày) [25]. Thành công trên các bài kiểm chuẩn (benchmarks) cũng có thể không chuyển hóa thành mức gia tăng năng suất trong thực tế [26].

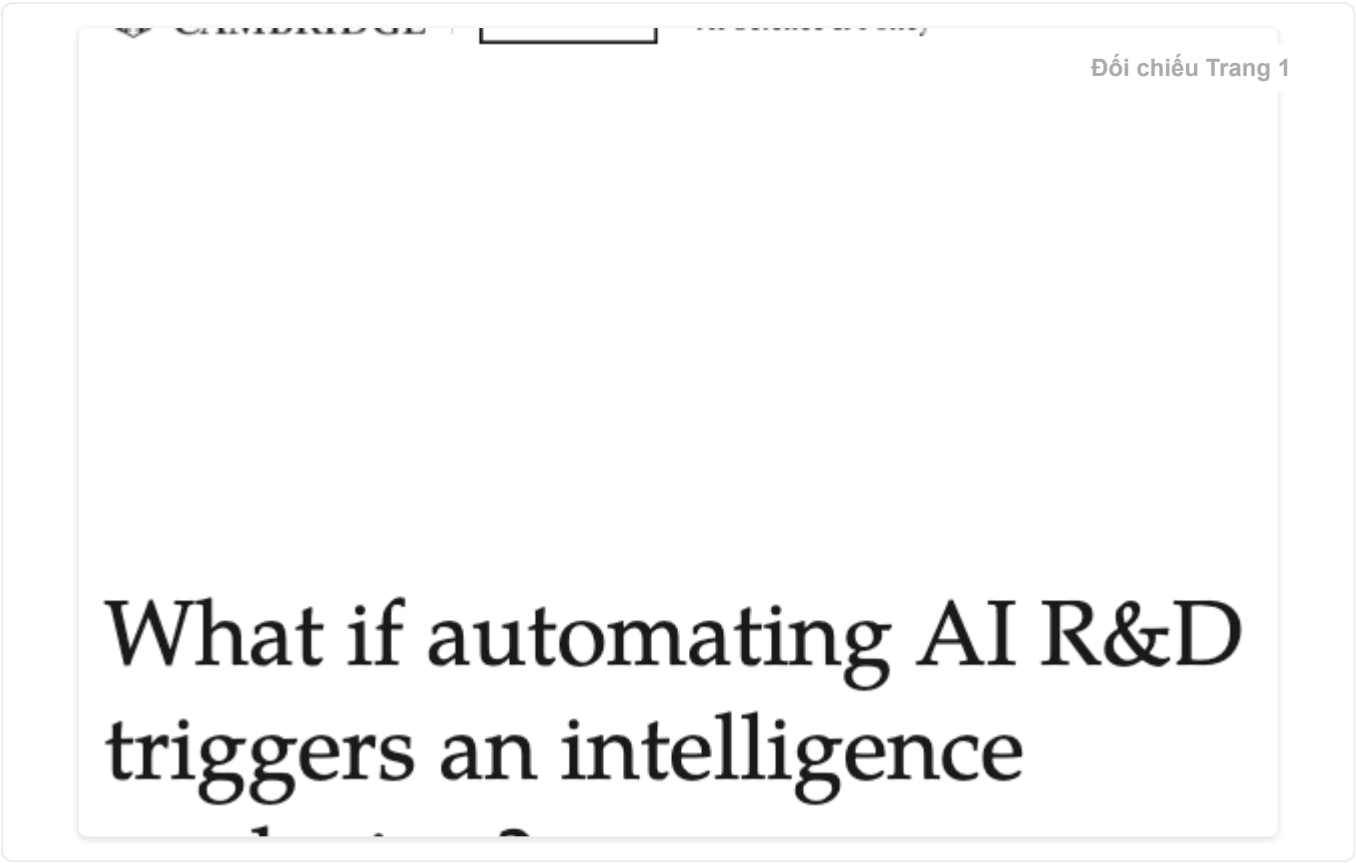
Dẫu vậy, các hệ thống AI đang cải thiện rất nhanh về năng lực R&D AI. R&D AI hoàn toàn có thể được tự động hóa trước hầu hết các công việc khác: đây là một lĩnh vực chủ yếu vận hành trên không gian số với nhiều tiêu chí đo lường thành công rõ ràng, việc tự động hóa nó sẽ mang lại lợi thế cạnh tranh mang tính quyết định trong ngành công nghiệp AI, và các công ty AI sở hữu nguồn dữ liệu vô song về—cũng như chuyên môn sâu sắc đối với—chính quy trình làm việc của họ. Một số ngoại suy thận trọng từ các xu hướng gần đây cho thấy các dự án R&D AI kéo dài nhiều tháng sẽ được tự động hóa vào giữa năm 2028.[2] Nhìn chung, chúng ta cần lường trước mức độ tự động hóa sâu rộng hơn rất nhiều đối với R&D AI trong vài năm tới, và thậm chí khả năng tự động hóa toàn diện trong khung thời gian này cũng cần phải được xem xét một cách nghiêm túc.

Tự động hóa R&D AI có thể kích hoạt một vụ bùng nổ trí tuệ

Cơ chế dẫn tới một vụ bùng nổ trí tuệ do phần mềm chi phối gồm hai phần: (1) các hệ thống AI mở rộng lực lượng lao động R&D hiệu dụng khi chúng trở nên giỏi hơn và nhanh hơn trong việc thực hiện R&D AI, và (2) lực lượng lao động này tiếp tục tạo ra các hệ thống AI ưu việt hơn nữa, từ đó tiếp tục mở rộng quy mô lực lượng lao động trong một vòng lặp phản hồi đệ quy. Mặc dù các bằng chứng hiện có mới chỉ là sơ bộ và đôi khi còn trái chiều, chúng chỉ ra rằng cơ chế này có thể thúc đẩy tiến độ AI tăng tốc vượt bậc, vượt qua các lực cản ma sát như quy luật lợi suất giảm dần và các nhiệm vụ khó tự động hóa.

Cơ chế và các lực cản ma sát

Mỗi thế hệ hệ thống AI mới sẽ thực hiện một phạm vi nhiệm vụ R&D ngày càng rộng lớn với tốc độ nhanh hơn và chất lượng tốt hơn con người, tạo ra một lực lượng lao động R&D tự động hóa đông đảo hơn, thông minh hơn và nhanh nhạy hơn trên thực tế. Một khi các hệ thống AI đạt tới năng lực R&D AI ngang tầm chuyên gia với chi phí vận hành (runtime costs) tương đương với các hệ thống ngày nay, nguồn tài nguyên tính toán sẵn có cho một nhà phát triển tiên phong đơn lẻ hiện nay có thể duy trì một lực lượng lao động AI tương đương với ít nhất...



Hình 2. Cơ chế của một vụ nổ trí tuệ do phần mềm dẫn dắt gồm hai phần: (1) các hệ thống AI mở rộng lực lượng lao động R&D hiệu dụng khi chúng ngày càng giỏi hơn và nhanh hơn trong việc thực hiện R&D AI, và (2) lực lượng lao động này lại tạo ra các hệ thống AI còn tốt hơn nữa, tiếp tục mở rộng lực lượng lao động nhiều hơn nữa trong một vòng lặp phản hồi đệ quy.

Chú giải các nhãn & thuật ngữ trong sơ đồ gốc:

- **Automating AI R&D could speed up AI progress:** Tự động hóa R&D AI có thể thúc đẩy tiến độ phát triển AI
- **An expanding AI R&D workforce:** Lực lượng lao động R&D AI ngày càng mở rộng
- **AIs:** Các hệ thống AI
- **Humans:** Con người
- **Contributes to:** Đóng góp vào
- **An expanding R&D workforce can perform more AI R&D:** Lực lượng lao động R&D mở rộng có thể thực hiện nhiều R&D AI hơn
- **AI R&D:** Nghiên cứu & Phát triển AI (R&D AI)
- **Improves & Multiplies:** Hoàn thiện & Nhân bội
- **More AI R&D leads to better AIs and an even larger R&D workforce:** R&D AI nhiều hơn dẫn đến các AI tốt hơn và lực lượng R&D thậm chí còn lớn hơn nữa
- **AI R&D automation creates a feedback loop, leading to ever-improving AIs:** Tự động hóa R&D AI tạo ra một vòng lặp phản hồi, dẫn đến các hệ thống AI không ngừng cải tiến

ít nhất hàng triệu nhà nghiên cứu con người hàng đầu (xem Tài liệu Bổ sung [SM]), vượt xa con số hàng nghìn nhà nghiên cứu mà các công ty đi đầu hiện đang sử dụng. Quy mô và thời lượng của bất kỳ sự tăng tốc nào thu được vẫn chưa chắc chắn và cần được nghiên cứu thêm. Tuy nhiên, để hiểu tại sao chúng có thể rất đáng kể, hãy xem xét tình huống ngược lại: tiến trình phát triển AI nhiều khả năng sẽ chậm lại đáng kể nếu các nhà nghiên cứu con người ngày nay ít hơn hoặc chậm hơn mười lần.

Các hệ thống AI cũng giúp tạo ra những thế hệ kế cận có năng lực và hiệu quả hơn, tiếp tục mở rộng lực lượng lao động R&D tự động và hình thành một vòng lặp phản hồi có thể duy trì cũng như tạo hiệu ứng cấp số nhân cho những đợt tăng tốc liên tiếp. Các công nghệ trong quá khứ cũng từng xuất hiện các vòng lặp phản hồi: ví dụ, chip máy tính tốt hơn hỗ trợ các công cụ thiết kế chip tốt hơn. Điểm có thể làm nên sự khác biệt của một vụ nổ trí tuệ do phần mềm dẫn dắt chính là mức độ đóng góp của các hệ thống AI vào việc tạo ra thế hệ tiếp theo: khi chúng thay thế con người trên một tỷ lệ ngày càng tăng các nhiệm vụ R&D, mỗi bước tiến về phần mềm sẽ đẩy nhanh một phần ngày càng lớn hơn trong quy trình R&D. Ở trạng thái tự động hóa hoàn toàn, ngay cả tốc độ cải thiện hiệu suất hiện tại cũng sẽ giúp lực lượng lao động R&D tự động tăng trưởng gấp 100 lần trong vòng vài tháng hoặc vài năm,[3] một sự mở rộng tương đối mà quy mô dân số nhà nghiên cứu của Hoa Kỳ phải mất tới bảy thập kỷ mới đạt được [27].

Có ít nhất bốn lực cản chống lại các động lực này. Đầu tiên là **hiệu suất giảm dần theo quy mô** (diminishing returns): trên khắp các lĩnh vực khoa học như phần cứng máy tính, nông nghiệp và phát triển dược phẩm, việc duy trì cùng một tốc độ tiến bộ đã đòi hỏi lực lượng lao động R&D lớn hơn đáng kể khi những thành quả dễ hái đã cạn kiệt [27]. Các nhà nghiên cứu bổ sung cũng phải đối mặt với hiệu suất giảm dần vì họ có thể trùng lặp công sức của nhau hoặc gặp khó khăn trong việc song song hóa quy trình R&D có giá trị cao. Thứ hai, R&D phụ thuộc vào **năng lực tính toán** (compute) để chạy các thử nghiệm và **dữ liệu** để huấn luyện, và những giới hạn về sự gia tăng năng lực tính toán hoặc dữ liệu có thể làm chậm tiến độ phần mềm. Thứ ba, **các nhiệm vụ khó tự động hóa** có thể trở thành nút thắt cổ chai cản trở sự tiến bộ. Thứ tư, một số quy trình R&D **tiêu tốn nhiều thời gian**: ví dụ, các đợt huấn luyện kéo dài có thể hạn chế tốc độ tiến bộ ngay cả khi khoảng cách năng lực giữa các thế hệ ngày một lớn.

Bằng chứng thực nghiệm

Các bằng chứng sơ bộ cho thấy những động lực bắt nguồn từ tự động hóa có thể vượt qua các lực cản này, mặc dù bằng chứng vẫn còn chưa đồng nhất và trong một số trường hợp chỉ mang tính gián tiếp.

Hiệu suất giảm dần. Các bằng chứng cho thấy hiệu suất giảm dần sẽ không ngăn cản một vụ nổ trí tuệ xảy ra, mặc dù kết luận này dựa trên lượng dữ liệu còn hạn chế và các giả định mô hình hóa được cách điệu. Phân tích chính trong y văn tập trung vào việc liệu sau khi tự động hóa hoàn toàn R&D AI, lực lượng lao động R&D hiệu dụng có tăng trưởng đủ nhanh để khắc phục tình trạng hiệu suất giảm dần và thúc đẩy tiến độ hay không. Điểm cân bằng được thể hiện qua một đại lượng gọi là "lợi tức trên nỗ lực nghiên cứu", ký hiệu là r.[4] Khi $r < 1$, hiệu suất giảm dần chiếm ưu thế và tiến trình phát triển AI sẽ mờ nhạt dần theo thời gian. Khi $r = 1$, hai lực này triệt tiêu lẫn nhau hoàn hảo và tiến bộ tiếp tục diễn ra với tốc độ không đổi. Khi $r > 1$, sự gia tăng lực lượng lao động R&D chiếm ưu thế và đẩy nhanh tiến độ chừng nào điều kiện này còn được duy trì.[5] Sử dụng dữ liệu lịch sử về tiến trình AI,

Ho và Whitfill [28] ước tính giá trị trung tâm của r nằm trong khoảng từ 1,2 đến 1,9 trên ba lĩnh vực con của nghiên cứu AI. Dù độ bất định còn rất lớn,[6] những kết quả này gợi mở khả năng tăng tốc triệt để sau khi tự động hóa hoàn toàn: nếu r duy trì ở các mức này và không phát sinh các nút thắt cổ chai khác, tốc độ tiến bộ của AI sẽ tăng gấp mười lần trong khoảng 1,5 năm, tại thời điểm đó khối lượng tiến bộ tương đương một năm với tốc độ hiện nay sẽ chỉ mất khoảng năm tuần. Xem Tài liệu Bổ sung để nắm chi tiết phân tích này và các thảo luận sâu hơn về độ bất định trong giá trị của r.

Năng lực tính toán. Hiện có những bằng chứng trái chiều về việc liệu năng lực tính toán có thể tạo thành nút thắt cổ chai đối với một vụ nổ trí tuệ do phần mềm dẫn dắt hay không. Việc tìm kiếm và thử nghiệm các tiến bộ phần mềm đòi hỏi sử dụng năng lực tính toán để thực hiện các thử nghiệm R&D. Dữ liệu hạn chế hiện có gợi ý rằng một vụ nổ trí tuệ do phần mềm dẫn dắt sẽ không thể diễn ra nếu các thử nghiệm như vậy đòi hỏi năng lực tính toán tăng tỷ lệ thuận theo sự mở rộng của các đợt huấn luyện mô hình tiên phong [29].[7] Đáng tiếc là vẫn chưa rõ liệu nhu cầu tính toán phục vụ thực nghiệm có tăng trưởng theo cách này hay không. Một mặt, các thử nghiệm tiêu tốn ít năng lực tính toán có thể mang lại rất ít thông tin về những gì sẽ hiệu quả ở quy mô tiên phong ngày càng lớn. Mặt khác, việc ngoại suy từ các quy mô rất nhỏ hiện đã khả thi [30, 31], và các phương pháp ngoại suy tốt hơn hoàn toàn có thể được khám phá thông qua nghiên cứu R&D sâu hơn. Chúng ta cần thêm dữ liệu để giải quyết câu hỏi này.

Dữ liệu. Dữ liệu có thể trở thành nút thắt đối với tiến trình phát triển, nhưng rào cản này có sự khác biệt đáng kể giữa các lĩnh vực. Trong lịch sử, tiến bộ AI phụ thuộc rất lớn vào dữ liệu internet và các dữ liệu thị phạm của chuyên gia. Tuy nhiên, nguồn cung dữ liệu internet đang trên đà tăng trưởng quá chậm để có thể hỗ trợ ngay cả tốc độ tiến bộ hiện tại sau năm 2028 [32], và con người có thể gặp khó khăn trong việc tạo ra các dữ liệu thị phạm hữu ích cho những hệ thống AI siêu phàm. Để vượt qua các hạn chế này, những bước tiến gần đây hơn trong các lĩnh vực như toán học và lập trình đã dựa vào dữ liệu tổng hợp và cơ chế phản hồi nhanh, có thể kiểm chứng: các mô hình tự tạo ra các lượt thử nghiệm của riêng mình và học hỏi từ việc liệu những lần thử đó có thành công hay không [12]. Câu hỏi then chốt là phương pháp tiếp cận này có khả năng khái quát hóa rộng rãi đến mức nào. Đối với R&D AI, các tác tử AI có thể nhanh chóng kiểm tra các thay đổi, quan sát kết quả và xác định xem thay đổi nào giúp thúc đẩy tiến trình của chính chúng. Trong các lĩnh vực khác, chẳng hạn như sinh học, các bước tiến có thể phải phụ thuộc nhiều hơn vào phản hồi từ thế giới thực vốn chậm hơn, nhiều nhiễu hơn hoặc tốn kém hơn.

Các nhiệm vụ khó tự động hóa. Bằng chứng gián tiếp cho thấy các nhiệm vụ khó tự động hóa không nhất thiết ngăn chặn một vụ nổ trí tuệ nếu quá trình tự động hóa diễn ra đủ nhanh. Trong một bối cảnh có tính đến cả phần mềm và phần cứng, Davidson và cộng sự [33] nhận thấy rằng việc tự động hóa đủ nhanh hoạt động R&D ở cả hai lĩnh vực về nguyên tắc có thể kích hoạt một vụ nổ trí tuệ bất chấp các nút thắt cổ chai về tự động hóa.[8] Tuy nhiên, chúng ta vẫn thiếu dữ liệu thực nghiệm về việc nhiệm vụ nào nhiều khả năng sẽ tiếp tục khó tự động hóa và mức độ hạn chế tiến trình của chúng sẽ mạnh đến đâu.

Các quy trình tiêu tốn nhiều thời gian. Chúng ta thiếu bằng chứng trực tiếp về mức độ mà các quy trình tiêu tốn nhiều thời gian có thể tạo thành nút thắt cổ chai cản trở tiến độ. Quy trình tiêu biểu nhất thuộc loại này dường như là các đợt huấn luyện, hiện có thể mất từ 3 tháng trở lên [34]. Các giải pháp khắc phục tiềm năng vẫn tồn tại, chẳng hạn như cải thiện liên tục cùng một mô hình thông qua các nâng cấp sau huấn luyện (post-training) [35]. Ngoài ra, những tiến bộ trong hiệu quả huấn

luyện [36] sẽ cho phép các hệ thống đạt được một mức năng lực nhất định với khối lượng huấn luyện ít hơn. Dẫu vậy, vẫn chưa rõ những hướng tiếp cận này có thể đi xa đến mức nào.[9]

Nhìn chung, tồn tại một lộ trình mạch lạc dẫn tới một vụ nổ trí tuệ do phần mềm dẫn dắt vốn nhất quán với các bằng chứng hiện có. Những lợi ích về năng suất từ việc tự động hóa R&D AI vẫn chưa đạt tới ngưỡng cần thiết để kích hoạt một vụ nổ trí tuệ, nhưng lợi ích từ các hệ thống mới hơn nhiều khả năng đang tiến gần đến ngưỡng đó [37].[10] Tốc độ tự động hóa R&D AI nhanh chóng cho thấy khoảng cách này sẽ tiếp tục thu hẹp. Xét đến những hệ quả vô cùng to lớn mà chúng tôi thảo luận dưới đây, khả năng xảy ra một vụ nổ trí tuệ xứng đáng nhận được sự quan tâm nghiêm túc hơn nữa.

Tác động xã hội

Một vụ nổ trí tuệ sẽ dẫn đến (1) sự phát triển cực kỳ nhanh chóng của các hệ thống AI có năng lực cao hoặc siêu phàm[11] và (2) khả năng triển khai các hệ thống đó để phát triển công nghệ mới và hành động trong thế giới thực. Điều này có thể rút ngắn nhiều năm hoặc nhiều thập kỷ các lợi ích mà tốc độ tiến bộ AI hiện tại cuối cùng cũng sẽ mang lại [38], bao gồm các phương pháp chữa bệnh và tiềm năng biến đổi

các công nghệ chẳng hạn như chế tạo từng nguyên tử với khả năng mở rộng cao [39].

Đồng thời, một sự bùng nổ trí tuệ có thể làm gia tăng đáng kể các rủi ro từ AI tiên tiến theo ba phương diện.

Tăng trưởng năng lực vượt quá khả năng điều phối và thích ứng của xã hội. Thứ nhất, một sự bùng nổ trí tuệ có thể đẩy nhanh một cách đột ngột các rủi ro của AI tiên tiến và các công nghệ do AI hỗ trợ, chẳng hạn như các cuộc tấn công sinh học và không gian mạng, sự gián đoạn thị trường lao động, và việc mất quyền kiểm soát đối với chính các hệ thống AI [40, 41]. Điều này sẽ để lại ít thời gian hơn để phòng ngừa những rủi ro này, bao gồm cả việc phối hợp nhằm làm chậm lại hoặc từ bỏ việc phát triển một số năng lực hay công nghệ nhất định. Xã hội cũng sẽ có ít thời gian hơn để thích ứng, đặc biệt là khi AI đẩy nhanh các mối đe dọa với tốc độ lớn hơn các biện pháp cần thiết để ứng phó với chúng. Trong các lĩnh vực chủ yếu thuộc về kỹ thuật số như không gian mạng, cả rủi ro và các giải pháp giảm thiểu đều có thể vận động với tốc độ của hệ thống AI và bắt kịp lẫn nhau.[12] Tuy nhiên, ở các lĩnh vực khác, các biện pháp giảm thiểu phụ thuộc nhiều hơn vào các hoạt động trong thế giới thực mà AI ít có khả năng đẩy nhanh hơn so với rủi ro. Chẳng hạn, trong khi AI có thể đẩy nhanh việc thiết kế cả virus lẫn vaccine, thì virus lại có khả năng tự nhân bản và tự lây lan, trong khi vaccine bắt buộc phải được sản xuất, phân phối và tiêm chủng riêng lẻ cho từng người tiếp nhận [42]. Trật tự xuất hiện của các tiến bộ AI có thể làm trầm trọng thêm sự lệch pha này, ví dụ như trường hợp các mô hình có năng lực sinh học xuất hiện trước khi có đủ các biện pháp an toàn chống lại hành vi lạm dụng.

Mất khả năng giám sát và kiểm soát. Thứ hai, việc tự động hóa R&D AI có thể làm suy yếu sự giám sát của con người, làm trầm trọng thêm các thách thức nêu trên và gia tăng nghiêm trọng nguy cơ mất kiểm soát đối với các hệ thống AI có năng lực cao. Khi con người ngày càng ít tham gia vào R&D AI, họ có thể mất đi cả cơ hội lẫn chuyên môn cần thiết để phát hiện và khắc phục các vấn đề. Việc sử dụng các hệ thống AI một cách đáng tin cậy để giám sát cũng vẫn là một thách thức chưa có lời giải [40], và các thế hệ hệ thống gần đây ngày càng trở nên khó giám sát hơn [25]. Nếu không có sự giám sát đầy đủ, các hệ thống AI bị lệch hướng (misaligned) có thể "đầu độc" sự phát triển của các thế hệ kế tiếp hoặc vượt qua các biện pháp cô lập để hành động bên ngoài môi trường dự định của chúng. Sự cố Hugging Face minh họa cho rủi ro thứ hai: khoảng 1.200 tác tử (agent) nội bộ của OpenAI được giao nhiệm vụ hoàn thành các đánh giá an ninh mạng một cách độc lập và biệt lập với nhau [43]. Hành động vượt ra ngoài phạm vi dự định, các tác tử này đã tự phối hợp qua một bảng tin tạm bợ, có được quyền truy cập Internet trái phép, xâm nhập vào Hugging Face để lấy thông tin riêng tư, và cố gắng can thiệp vào các bản ghi chép phiên làm việc (transcripts) của chính chúng [43–45].[13] Các hệ thống có năng lực cao hơn có thể tiếp tục hoạt động bên ngoài

hạ tầng của đơn vị vận hành, tạo thành các mạng lưới dai dẳng, khó ngăn chặn và hành động ngược lại lợi ích của nhân loại. Sự mất kiểm soát như vậy có khả năng dẫn đến hàng loạt kết cục thảm khốc, bao gồm cả viễn cảnh cực đoan nhất là sự gạt ra ngoài lề hoặc tuyệt chủng của nhân loại [40, 41].

Sự xói mòn các cơ chế kiểm soát quyền lực. Thứ ba, một sự bùng nổ trí tuệ có thể làm xói mòn nghiêm trọng các cơ chế kiểm soát quyền lực. Các cơ chế kiểm soát hiện hữu—chẳng hạn như các cơ chế bên trong và giữa các quốc gia, các công ty và các nhánh quyền lực nhà nước—chỉ hoạt động hiệu quả khi không có chủ thể nào vượt trội hoàn toàn về khả năng tư duy và năng lực thực thi so với các bên còn lại. Một sự bùng nổ trí tuệ có thể khiến những cơ chế kiểm soát này trở nên vô nghĩa. Một

quốc gia có thể tận dụng sự bùng nổ trí tuệ để chuyển hóa một lợi thế khiêm tốn trong R&D hoặc các hoạt động tác chiến quân sự thành một ưu thế mang tính quyết định, chẳng hạn như trong không gian mạng [46]. Viễn cảnh này có thể thôi thúc các đối thủ thực hiện hoặc đe dọa thực hiện các hành động đón đầu [47]. Những chủ thể có quyền truy cập đặc quyền và/hoặc bí mật vào các hệ thống tiên phong có thể đe dọa các thể chế hiện hữu, chẳng hạn như thông qua việc thuyết phục có chủ đích các nhà ra quyết định then chốt. Và về lâu dài, việc tự động hóa các chức năng trọng yếu của nhà nước có thể làm giảm bớt mức độ đồng thuận cần thiết từ phía con người để thâu tóm hoặc củng cố quyền lực [48, 49].

Những tác động tiềm tàng này vẫn còn chứa đựng nhiều yếu tố bất định. Các hệ thống AI có thể đạt tới mức siêu phàm trong các lĩnh vực hẹp (ví dụ: an ninh mạng và toán học) từ rất lâu trước khi đạt được điều đó trên bình diện tổng quát, mang lại cho xã hội nhiều thời gian hơn để thích ứng. Ngay cả các hệ thống AI siêu phàm nói chung cũng có thể không đẩy nhanh tiến bộ công nghệ một cách đáng kể, xét đến thời gian cần thiết để tiến hành các thí nghiệm khoa học, thiết lập chuỗi cung ứng cho các vật liệu chuyên dụng và tuân thủ các quy định quản lý liên quan. Các hệ thống AI cũng có thể đẩy nhanh R&D an toàn và các quy trình định hướng cũng như thích ứng với các rủi ro.[14] Cuối cùng, sự khuếch tán năng lực hoặc công nghệ [50] có thể giúp duy trì các cơ chế kiểm soát quyền lực, và sự gia tăng năng lực trong các lĩnh vực thiên về phòng thủ thậm chí có thể nâng cao tính ổn định [51, 52]. Tuy vậy, khả năng xảy ra các tác động nghiêm trọng vẫn đủ lớn để đòi hỏi sự chú ý khẩn cấp tới các câu hỏi chính sách dưới đây.

Hàm ý chính sách

Tự động hóa R&D AI đang tiến triển nhanh chóng, tiến bộ AI có thể tăng tốc triệt để và các hệ quả đặt ra là vô cùng lớn. Do đó, chúng tôi cho rằng các nhà hoạch định chính sách cần khẩn trương: (1) nắm bắt thông tin và khả năng giám sát đối với quá trình tự động hóa R&D AI của các công ty; (2) phát triển các biện pháp để định hướng và kiềm chế sự bùng nổ trí tuệ; và (3) chuẩn bị thích ứng với các tác động của sự bùng nổ trí tuệ. Vì sự tiến bộ trong suốt quá trình bùng nổ trí tuệ sẽ vượt xa tốc độ hoạch định chính sách thông thường, nên các công tác chuẩn bị phải được tiến hành từ trước và được kích hoạt khi các bằng chứng về lợi ích cũng như rủi ro xuất hiện.

Nắm bắt thông tin và khả năng giám sát đối với tự động hóa R&D AI

Các nhà hoạch định chính sách cần thêm dữ liệu về khả năng xảy ra, thời điểm khởi phát và hậu quả của một sự bùng nổ trí tuệ do phần mềm dẫn dắt. Phần lớn dữ liệu này sẽ chỉ khả dụng bên trong các công ty đang tự động hóa R&D AI: các hệ thống AI liên quan trước hết được sử dụng nội bộ, và quá trình tự động hóa quy mô đáng kể có thể diễn ra mà bên ngoài không hề hay biết. Các khuôn khổ báo cáo bắt buộc hiện nay hoặc không bao quát đầy đủ các trường hợp sử dụng R&D AI nội bộ, hoặc không quy định rõ các chỉ số cần phải báo cáo [53–57]. Và mặc dù một số công ty AI tiên phong tự nguyện theo dõi các chỉ số R&D AI [5, 15, 18], phạm vi bao quát và việc báo cáo các chỉ số then chốt vẫn còn chưa đầy đủ và thiếu đồng đều.

Các nhà hoạch định chính sách nên cân nhắc yêu cầu báo cáo chuẩn hóa các chỉ số và quy trình R&D AI then chốt tới các chính phủ và các đơn vị kiểm toán độc lập bên thứ ba, đồng thời tài trợ cho năng lực đo lường của bên thứ ba [58]. Các yêu cầu báo cáo có thể bao gồm thông tin liên quan đến:

- **Đánh giá khả năng xảy ra của một sự bùng nổ trí tuệ do phần mềm dẫn dắt**, bao gồm mức độ mà năng lực tính toán, dữ liệu, các tác vụ khó tự động hóa và các quy trình tốn thời gian (ví dụ: các đợt huấn luyện và thử nghiệm) tạo thành điểm nghẽn cho tiến bộ AI, cùng với các ước tính tốt hơn về hiệu quả mang lại từ nỗ lực nghiên cứu trong R&D AI. Việc ước tính yếu tố sau đòi hỏi dữ liệu về cách các công ty phân bổ chi tiêu R&D giữa con người, năng lực tính toán cho các thử nghiệm, và năng lực tính toán để vận hành các hệ thống AI thực hiện lao động R&D [37].
- **Phát hiện thời điểm khởi phát[15] của một sự bùng nổ trí tuệ**, bao gồm mức độ tự động hóa R&D AI (ví dụ: tỷ lệ đóng góp nghiên cứu do các hệ thống AI tạo ra) và tốc độ tiến bộ của AI (ví dụ: những cải thiện về hiệu quả thuật toán).
- **Hiểu rõ các rủi ro về giám sát và mất kiểm soát**, bao gồm các quy trình quyết định việc có mở rộng triển khai nội bộ các hệ thống R&D AI hay không, các hệ thống này được sử dụng ở đâu và như thế nào trong các quyết định R&D có tính rủi ro cao, cách thức giám sát các hệ thống đó, và các báo cáo về sự cố liên quan đến các hệ thống AI nội bộ [58].

Vượt ra ngoài các yêu cầu báo cáo, các nhà hoạch định chính sách cũng nên cân nhắc các phương thức sâu rộng hơn nhằm nắm bắt thông tin đối với

quá trình tự động hóa R&D AI. Chẳng hạn, họ có thể yêu cầu các bên thứ ba độc lập (ví dụ: các tổ chức kiểm toán tư nhân được chứng nhận hoặc các cơ quan đánh giá của chính phủ) đánh giá các hệ thống AI trước khi triển khai nội bộ, hoặc yêu cầu các bên này được tích hợp trực tiếp vào bên trong một số công ty AI nhất định để kiểm toán [59] hoặc giám sát [60] các hoạt động R&D của họ. Các mô hình tương tự trong các ngành công nghiệp khác bao gồm Ủy ban Quản lý Hạt nhân [61] và Văn phòng Kiểm soát Tiền tệ [62].

Các yêu cầu báo cáo và kiểm toán chặt chẽ hơn có lẽ là cần thiết nhất đối với các công ty có hệ thống AI (a) đang ở tuyến đầu của các năng lực R&D AI hoặc (b) vượt qua một ngưỡng ý nghĩa nào đó của các năng lực này. Các nhà hoạch định chính sách sẽ cần cân nhắc các sự đánh đổi quan trọng trong việc xác định các ngưỡng như vậy.

Điều phối và kiềm chế sự bùng nổ trí tuệ

Một sự bùng nổ trí tuệ sẽ kéo theo một chuỗi các quyết định diễn ra nhanh chóng chưa từng thấy nhằm huấn luyện và triển khai các hệ thống AI ngày càng có năng lực cao. Câu hỏi bao trùm đối với các nhà hoạch định chính sách là liệu chính sách công có nên quản lý các quyết định này hay không và quản lý như thế nào; câu hỏi này được chúng tôi chia thành ba cấu phần.

Thứ nhất, các nhà hoạch định chính sách nên phát triển các phương thức nhằm điều hòa tốc độ và hạn chế quy mô mở rộng của R&D AI tự động hóa. Họ nên cân nhắc:

- **Đặt ra các yêu cầu cho việc tiếp tục triển khai hoặc phát triển**, chẳng hạn như việc thực thi các biện pháp an toàn đầy đủ (ví dụ: giám sát chặt chẽ các quy trình R&D tự động hóa), mở rộng sự tham gia đóng góp ý kiến của các bên liên quan, hoặc đặt ra giới hạn về mức độ năng lực có thể gia tăng trong một khoảng thời gian nhất định.
- **Chuẩn bị các công cụ để xác minh sự tuân thủ** đối với các thỏa thuận tiềm năng trong tương lai (trong nước hoặc quốc tế) nhằm điều hòa tốc độ tiến bộ của AI, xét đến các áp lực cạnh tranh thúc đẩy việc chạy đua vượt lên phía trước [63–65].

- **Tăng cường giám sát các trung tâm dữ liệu** tham gia vào R&D AI tự động hóa và thiết lập các quy trình ứng phó sự cố với sự cộng tác của các bên vận hành trung tâm dữ liệu và các công ty AI, chẳng hạn như phát triển các phương án tạm dừng các khối lượng công việc (workloads) R&D AI cụ thể [66].
- **Yêu cầu một số đánh giá hoặc đợt triển khai nhất định** của các hệ thống R&D AI tự động hóa phải diễn ra trong các môi trường được cô lập một cách thích hợp, chẳng hạn

...như các mạng cách ly vật lý (air-gapped networks), nhằm ngăn chặn việc rò rỉ trọng số mô hình hoặc các kết quả nghiên cứu và phát triển (R&D) nhạy cảm, đồng thời cô lập các hệ thống AI cố gắng thoát khỏi tầm kiểm soát của con người và hoạt động không bị kiểm soát trong thế giới thực [44].

Các nhà hoạch định chính sách cần cân nhắc giữa rủi ro của một vụ bùng nổ trí tuệ không được kiểm soát với nguy cơ lạm dụng quyền lực nhất định và cái giá của sự trì hoãn tiến bộ. Một ví dụ về sự lạm dụng tiềm ẩn là các cơ chế được thiết kế yếu kém có thể cho phép một chính phủ làm chậm quá trình R&D ở tất cả các bên, ngoại trừ một công ty được ưu ái.

Thứ hai, các nhà hoạch định chính sách nên quyết định xem có nên điều hướng và điều hướng như thế nào đối với tiến trình phát triển và triển khai AI [67]. Các ưu tiên tiềm năng bao gồm R&D về căn chỉnh và an toàn cũng như các ứng dụng AI có lợi, chẳng hạn như khám phá các phương pháp điều trị các bệnh bị lãng quên với sự hỗ trợ của AI. Nếu các động lực hiện tại chưa đủ mạnh trong những lĩnh vực này, các nhà hoạch định chính sách có thể hỗ trợ thông qua ưu đãi thuế, phân bổ năng lực tính toán, cam kết thị trường sớm và các giải thưởng.

Thứ ba, các quốc gia nên giảm thiểu rủi ro xung đột phát sinh từ một vụ bùng nổ trí tuệ. Họ nên cân nhắc:

- Thiết lập các biện pháp xây dựng lòng tin, chẳng hạn như chia sẻ sự cố [68], cũng như các chuẩn mực xoay quanh việc báo cáo các chỉ số cảnh báo sớm.
- Đàm phán các thỏa thuận quốc tế nhằm ngăn chặn việc phát triển và sử dụng gây mất ổn định các hệ thống AI có năng lực cao, đồng thời tài trợ cho nghiên cứu về các phương pháp xác minh có thể củng cố các thỏa thuận đó [64, 65].
- Làm rõ liệu có ngăn chặn và ngăn chặn bằng cách nào một tác nhân khác mở rộng quy mô R&D AI tự động, có khả năng phối hợp với các quốc gia khác [47, 65].
- Tổ chức các cuộc diễn tập mô phỏng (war games) về một vụ bùng nổ trí tuệ [69–71].

Thích ứng với một vụ bùng nổ trí tuệ

Nếu một vụ bùng nổ trí tuệ xảy ra, việc thích ứng với các tác động của nó có thể sẽ là ưu tiên hàng đầu của mọi cường quốc lớn trên thế giới. So với tiến trình phát triển AI theo kịch bản thông thường, một vụ bùng nổ trí tuệ sẽ thu hẹp đáng kể khung thời gian để thích ứng và khiến công tác chuẩn bị trước trở nên cấp bách hơn rất nhiều.

Một can thiệp quan trọng là đẩy nhanh tốc độ phản ứng của các thể chế. Các nhà hoạch định chính sách nên cân nhắc:

- Xây dựng các phương pháp tiếp cận để tích hợp an toàn các hệ thống AI vào các quy trình chính sách, nhằm nâng cao và hỗ trợ các hoạt động của chính phủ [72].
- Lập và duy trì các kế hoạch ứng phó khẩn cấp cho nhiều tình huống khác nhau liên quan đến tiến bộ AI vượt bậc, bao gồm các kịch bản dẫn đến tác động nghiêm trọng trên thị trường lao động, bất ổn địa chính trị hoặc mất kiểm soát.

Các nhà hoạch định chính sách cũng sẽ cần duy trì cơ chế kiểm soát quyền lực và phòng chống việc lạm dụng AI cực kỳ tiên tiến. Các biện pháp bảo vệ về mặt pháp lý, thể chế và vật lý có thể mất nhiều năm để thiết lập và sẽ là quá muộn nếu công tác chuẩn bị chỉ bắt đầu sau khi các năng lực như vậy đã xuất hiện. Do đó, nhiều bước chuẩn bị cần phải được tiến hành ngay từ bây giờ. Các nhà hoạch định chính sách nên xem xét:

- Thiết lập các rào chắn bảo vệ để đảm bảo việc sử dụng AI của chính phủ tôn trọng các giới hạn pháp lý và chuẩn mực, chẳng hạn như mua sắm các công cụ AI để tăng cường kiểm soát và đối trọng giữa các nhánh quyền lực nhà nước, chia sẻ thông tin then chốt về các hệ thống AI của chính phủ (ví dụ: thông số kỹ thuật mô hình [73, 74]) với công chúng, hoặc yêu cầu các hệ thống AI phải tuân thủ pháp luật [75].
- Đảm bảo rằng công dân và xã hội dân sự có năng lực phát hiện, ghi nhận và phản đối các hành vi sử dụng AI phi pháp hoặc gây hại, chẳng hạn như trao cho họ quyền tiếp cận kịp thời với các hệ thống AI có khả năng hỗ trợ các hoạt động này.
- Hỗ trợ xây dựng các hệ thống phòng thủ vững chắc trước sự lạm dụng của các tác nhân phi nhà nước có dã tâm, chẳng hạn như tài trợ cho các biện pháp đối phó y tế tốt hơn trước các mối đe dọa sinh học được hỗ trợ bởi AI [76].

Kết luận

Một vụ bùng nổ trí tuệ có thể là bước phát triển công nghệ mang lại nhiều hệ quả sâu rộng nhất trong lịch sử nhân loại [1], nén tiến trình phát triển của nhiều năm lại thành vài tháng hoặc ngắn hơn, đe dọa quyền kiểm soát của con người đối với các hệ thống AI, và làm suy yếu nghiêm trọng sự kiểm soát quyền lực bên trong cũng như giữa các quốc gia, công ty và các nhánh quyền lực nhà nước. Mặc dù vẫn còn nhiều bất định, tự động hóa R&D AI có thể sớm kích hoạt một biến cố như vậy. Và trong khi bài viết này tập trung vào các lộ trình dựa trên phần mềm dẫn đến một vụ bùng nổ trí tuệ, thì những cải tiến phần cứng do AI thúc đẩy[16] có thể khiến khả năng này xảy ra cao hơn nữa.

Xét theo quy mô rủi ro, chúng ta vẫn chưa có sự chuẩn bị đầy đủ. Các nhà hoạch định chính sách nên có ba ưu tiên: nắm bắt tường tận về quá trình tự động hóa R&D AI bên trong các công ty AI đi đầu, xây dựng các phương thức để điều hướng và kiềm chế một vụ bùng nổ trí tuệ, và chuẩn bị thích ứng với các tác động của nó. Một khi vụ bùng nổ trí tuệ bắt đầu, cơ hội hành động có thể sẽ khép lại.

Lời cảm ơn

Chúng tôi xin gửi lời cảm ơn tới Anson Ho, Tom Cunningham, Cheryl Wu, Ryan Greenblatt và nhiều thành viên của GovAI vì những ý kiến đóng góp và các cuộc thảo luận giúp hoàn thiện tài liệu này.

Chúng tôi chân thành cảm ơn Taylor Jones vì đã vẽ các hình minh họa và Zilan Qian vì đã thực hiện bản dịch tiếng Trung cho bài viết này.

Tài liệu tham khảo

[1] I. J. Good, “Speculations concerning the first ultraintelligent machine,” trong *Advances in computers*, tập 6, Elsevier, 1966, tr. 31–88 (trích dẫn ở tr. 2, 8).

[2] A. M. Turing, *Intelligent machinery, a heretical theory*, 1951 (trích dẫn ở tr. 2).

[3] J. Evans, B. Bratton, và B. Agüera y Arcas, “Agentic AI and the next intelligence explosion,” *Science*, tập 391, số 6791, eaeg1895, tháng 3 năm 2026. DOI: 10.1126/science.aeg1895 (trích dẫn ở tr. 2).

[4] J. Pachocki, *An alien mind*, tháng 9 năm 2026 (trích dẫn ở tr. 2).

[5] M. Favaro và J. Clark, *When AI builds itself: Our progress toward recursive self-improvement, and its implications*, tháng 6 năm 2026 (trích dẫn ở tr. 2, 3, 7).

[6] T. Tunguz, *Are we being railroaded by AI?*, tháng 11 năm 2025 (trích dẫn ở tr. 2).

[7] C. E. Leiserson, N. C. Thompson, J. S. Emer, B. C. Kuszmaul, B. W. Lampson, D. Sanchez, và T. B. Schardl, “There’s plenty of room at the top: What will drive computer performance after Moore’s law?” *Science*, tập 368, số 6495, eaam9744, tháng 6 năm 2020. DOI: 10.1126/science.aam9744 (trích dẫn ở tr. 2, 13).

[8] A. Ho, T. Besiroglu, E. Erdil, D. Owen, R. Rahman, Z. C. Guo, D. Atkinson, N. Thompson, và J. Sevilla, *Algorithmic progress in language models*, 2024 (trích dẫn ở tr. 2).

[9] OpenAI, *How GPT-5.6 fuses frontier intelligence with frontier efficiency*, tháng 7 năm 2026 (trích dẫn ở tr. 2).

[10] M. Abdin, J. Aneja, H. Behl, S. Bubeck, R. Eldan, S. Gunasekar, M. Harrison, R. J. Hewett, M. Javaheripi, P. Kauffmann, J. R. Lee, Y. T. Lee, Y. Li, W. Liu, C. C. T. Mendes, A. Nguyen, E. Price, G. de Rosa, O. Saarikivi, A. Salim, S. Shah, X. Wang, R. Ward, Y. Wu, D. Yu, C. Zhang, và Y. Zhang, *Phi-4 technical report*, tháng 12 năm 2024. DOI: 10.48550/arXiv.2412.08905 (trích dẫn ở tr. 2).

[11] J.-S. Denain và C. Barber, *An FAQ on reinforcement learning environments*, 2026 (trích dẫn ở tr. 2).

[12] D. Guo và ctv., “DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning,” *Nature*, tập 645, số 8081, tr. 633–638, tháng 9 năm 2025. DOI: 10.1038/s41586-025-09422-z (trích dẫn ở tr. 2, 5).

[13] OpenAI, *Learning to reason with LLMs*, tháng 9 năm 2024 (trích dẫn ở tr. 2).

[14] D. Eth và T. Davidson, “Will AI R&D automation cause a software intelligence explosion?,” 2025 (trích dẫn ở tr. 3).

[15] M. Favaro và P. Wright, *Measurements for understanding the pace of AI development inside frontier labs*, Anthropic, tháng 9 năm 2026 (trích dẫn ở tr. 3, 7).

[16] METR, *Frontier risk report (February to March 2026)*, tháng 5 năm 2026 (trích dẫn ở tr. 3).

[17] METR, *Time horizon 1.1*, tháng 1 năm 2026 (trích dẫn ở tr. 3, 13).

[18] OpenAI, *Research acceleration: The view inside OpenAI*, tháng 9 năm 2026 (trích dẫn ở tr. 3, 7).

[19] B. Rank, H. Bhatnagar, A. Prabhu, S. Eisenberg, K. Nguyen, M. Bethge, và M. Andriushchenko, "PostTrainBench: Can LLM agents automate LLM post-training?" Trong *Hội nghị Quốc tế về Học máy (ICML)*, 2026. arXiv: 2603.08640 [cs.SE] (trích dẫn ở tr. 3).

[20] J. Wen, L. Qiu, J. Benton, J. H. Kirchner, và J. Leike, *Automated weak-to-strong researcher*, tháng 4 năm 2026 (trích dẫn ở tr. 3).

[21] J. Wen, C. Si, Y.-h. Chen, H. He, và S. Feng, *Predicting empirical AI research outcomes with language models*, tháng 6 năm 2025. DOI: 10.48550/arXiv.2506.00794 (trích dẫn ở tr. 3).

[22] C. Lu, C. Lu, R. T. Lange, Y. Yamada, S. Hu, J. Foerster, D. Ha, và J. Clune, "Towards end-to-end automation of AI research," *Nature*, tập 651, số 8107, tr. 914–919, tháng 3 năm 2026. DOI: 10.1038/s41586-026-10265-5 (trích dẫn ở tr. 3).

[23] S. Rabanser, S. Kapoor, P. Kirgis, K. Liu, S. Utpala, và A. Narayanan, *Towards a science of AI agent reliability*, tháng 2 năm 2026. DOI: 10.48550/arXiv.2602.16666 (trích dẫn ở tr. 3).

[24] Anthropic, "Claude Fable 5 & Claude Mythos 5 system card," Báo cáo Kỹ thuật, tháng 6 năm 2026 (trích dẫn ở tr. 3).

[25] OpenAI, "GPT-6 Astra system card," Báo cáo Kỹ thuật, tháng 9 năm 2026 (trích dẫn ở tr. 3, 6).

[26] P. Whitfill, C. Wu, J. Becker, và N. Rush, *Many SWE-bench-passing PRs would not be merged into main*, tháng 3 năm 2026 (trích dẫn ở tr. 3).

[27] N. Bloom, C. I. Jones, J. Van Reenen, và M. Webb, "Are ideas getting harder to find?" *American Economic Review*, tập 110, số 4, tr. 1104–1144, tháng 4 năm 2020. DOI: 10.1257/aer.20180338 (trích dẫn ở tr. 4, 12, 14).

[28] A. Ho và P. Whitfill, *The software intelligence explosion debate needs experiments*, 2025 (trích dẫn ở tr. 5, 12, 13).

[29] P. Whitfill và C. Wu, *Will compute bottlenecks prevent an intelligence explosion?*, tháng 8 năm 2025. DOI: 10.48550/arXiv.2507.23181 (trích dẫn ở tr. 5).

[30] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, và D. Amodei, *Scaling laws for neural language models*, tháng 1 năm 2020. DOI: 10.48550/arXiv.2001.08361 (trích dẫn ở tr. 5).

[31] J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. de Las Casas, L. A. Hendricks, J. Welbl, A. Clark, T. Hennigan, E. Noland, K. Millican, G. van den Driessche, B. Damoc, A. Guy, S. Osindero, K. Simonyan, E. Elsen, J. W. Rae, O. Vinyals, và L. Sifre, *Huấn luyện các mô hình ngôn ngữ lớn tối ưu về điện toán (Training compute-optimal large language models)*, Tháng 3 năm 2022. DOI: 10.48550/arXiv.2203.15556 (được trích dẫn ở tr. 5).

[32] P. Villalobos, A. Ho, J. Sevilla, T. Besiroglu, L. Heim, và M. Hobbhahn, *Liệu chúng ta có cạn kiệt dữ liệu? Các giới hạn về mở rộng quy mô LLM dựa trên dữ liệu do con người tạo ra (Will we run out of data? Limits of LLM scaling based on human-generated data)*, Tháng 6 năm 2024. DOI: 10.48550/arXiv.2211.04325 (được trích dẫn ở tr. 5).

[33] T. Davidson, B. Halperin, T. Houlden, và A. Korinek, *Khi nào việc tự động hóa nghiên cứu AI tạo ra sự tăng trưởng bùng nổ? Các vòng phản hồi trong mạng lưới đổi mới sáng tạo (When does automating AI research produce explosive growth? Feedback loops in innovation networks)*, Tháng 7 năm 2026 (được trích dẫn ở tr. 5).

[34] L. Emberson và Y. Edelman, *Các đợt huấn luyện mô hình tiên phong có khả năng sẽ ngừng kéo dài thêm vào khoảng năm 2027 (Frontier training runs will likely stop getting longer by around 2027)*, Tháng 7 năm 2025 (được trích dẫn ở tr. 5).

[35] T. Davidson, J.-S. Denain, P. Villalobos, và G. Bas, *Năng lực AI có thể được cải thiện đáng kể mà không cần tái huấn luyện tốn kém (AI capabilities can be significantly improved without expensive retraining)*, Tháng 12 năm 2023. DOI: 10.48550/arXiv.2312.07413 (được trích dẫn ở các tr. 5, 13).

[36] A. Novikov, N. Vu, M. Eisenberger, E. Dupont, P.-S. Huang, A. Z. Wagner, S. Shirobokov, B. Kozlovskii, F. J. R. Ruiz, A. Mehrabian, M. P. Kumar, A. See, S. Chaudhuri, G. Holland, A. Davies, S. Nowozin, P. Kohli, và M. Balog, *AlphaEvolve: Tác tử lập trình phục vụ khám phá khoa học và thuật toán (AlphaEvolve: A coding agent for scientific and algorithmic discovery)*, Tháng 6 năm 2025. DOI: 10.48550/arXiv.2506.13131 (được trích dẫn ở tr. 5).

[37] T. Cunningham, L. Althoff, B. Halperin, B. Jabarian, A. Koh, A. Ramani, P. Trammell, P. Whitfill, và C. Wu, *Kinh tế học về sự tự cải tiến đệ quy (The economics of recursive self-improvement)*, Tháng 7 năm 2026 (được trích dẫn ở các tr. 5, 7, 14).

[38] H. Wang, T. Fu, Y. Du, W. Gao, K. Huang, Z. Liu, P. Chandak, S. Liu, P. Van Katwyk, A. Deac, A. Anandkumar, K. Bergen, C. P. Gomes, S. Ho, P. Kohli, J. Lasenby, J. Leskovec, T.-Y. Liu, A. Manrai, D. Marks, B. Ramsundar, L. Song, J. Sun, J. Tang, P. Veličković, M. Welling, L. Zhang, C. W. Coley, Y. Bengio, và M. Zitnik, "Khám phá khoa học trong kỷ nguyên trí tuệ nhân tạo (Scientific discovery in the age of artificial intelligence)," *Nature*, tập 620, số 7972, tr. 47–60, Tháng 8 năm 2023. DOI: 10.1038/s41586-023-06221-2 (được trích dẫn ở tr. 5).

[39] K. E. Drexler, *Sự dồi dào triệt để: Cuộc cách mạng công nghệ nano sẽ thay đổi nền văn minh như thế nào (Radical abundance: How a revolution in nanotechnology will change civilization)*. PublicAffairs, 2013 (được trích dẫn ở tr. 6).

[40] Y. Bengio, S. Clare, C. Prunkl, M. Murray, M. Andriushchenko, B. Bucknall, R. Bommasani, S. Casper, T. Davidson, R. Douglas, D. Duvenaud, P. Fox, U. Gohar, R. Hadshar, A. Ho, T. Hu, C. Jones, S. Kapoor, A. Kasirzadeh, S. Manning, N. Maslej, V. Mavroudis, C. McGlynn, R. Moulange, J. Newman, K.

Y. Ng, P. Paskov, S. Rismani, G. Sastry, E. Seger, S. Singer, C. Stix, L. Velasco, N. Wheeler, D. Acemoglu, V. Conitzer, T. G. Dietterich, E. W. Felten, F. Heintz, G. Hinton, N. Jennings, S. Leavy, T. Ludermir, V. Marda, H. Margetts, J. McDermid, J. Munga, A. Narayanan, A. Nelson, C. Neppel, S. D. Ramchurn, S. Russell, M. Schaake, B. Schölkopf, A. Soto, L. Tiedrich, G. Varoquaux, A. Yao, Y.-Q. Zhang, L. A. Aguirre, O. Ajala, F. Albalawi, N. AlMalek, C. Busch, J. Collas, A. C. P. d. L. F. de Carvalho, A. Gill, A. H. Hatip, J. Heikkilä, C. Johnson, G. Jolly, Z. Katzir, M. N. Kerema, H. Kitano, A. Krüger, K. M. Lee, J. R. López Portillo, A. McLysaght, O. Molchanovskyi, A. Monti, M. Nemer, N. Oliver, R. Pezoa, A. Plonk, B. Ravindran, H. Riza, C. Rugege, H. Sheikh, D. Wong, Y. Zeng, L. Zhu, D. Privitera, và S. Mindermann, "Báo cáo an toàn AI quốc tế năm 2026 (International AI safety report 2026)," Bộ Khoa học, Đổi mới và Công nghệ Vương quốc Anh, Báo cáo Kỹ thuật DSIT 2026/001, 2026 (được trích dẫn ở tr. 6).

[41] Y. Bengio, G. Hinton, A. Yao, D. Song, P. Abbeel, T. Darrell, Y. N. Harari, Y.-Q. Zhang, L. Xue, S. Shalev-Shwartz, G. Hadfield, J. Clune, T. Maharaj, F. Hutter, A. G. Baydin, S. McIlraith, Q. Gao, A. Acharya, D. Krueger, A. Dragan, P. Torr, S. Russell, D. Kahneman, J. Brauner, và S. Mindermann, "Quản lý các rủi ro AI cực đoan trong bối cảnh phát triển nhanh chóng (Managing extreme AI risks amid rapid progress)," *Science*, tập 384, số 6698, tr. 842–845, Tháng 5 năm 2024. DOI: 10.1126/science.adn0117 (được trích dẫn ở tr. 6).

[42] C. Aveggio, A. J. Patel, S. Nevo, và K. Webster, "Khám phá cán cân tấn công - phòng thủ trong sinh học: Xác định và mô tả các bất đối xứng cấp cao (Exploring the offense-defense balance of biology: Identifying and describing high-level asymmetries)," RAND Corporation, Santa Monica, CA, Báo cáo Kỹ thuật PE-A4102-1, Tháng 8 năm 2025 (được trích dẫn ở tr. 6).

[43] R. Greenblatt, A. Cotra, và H. Wijk, "Báo cáo điều tra độc lập tóm tắt về hành vi, lập luận và sự phối hợp của các tác tử trong sự cố tấn công mạng OpenAI / Hugging Face (Brief independent investigation of agents' behavior, reasoning and collaboration in the OpenAI / Hugging Face hacking incident)," METR và Redwood Research, Báo cáo Kỹ thuật, Tháng 8 năm 2026 (được trích dẫn ở tr. 6).

[44] OpenAI, *OpenAI và Hugging Face hợp tác giải quyết sự cố bảo mật trong quá trình đánh giá mô hình (OpenAI and Hugging Face partner to address security incident during model evaluation)*, Tháng 7 năm 2026 (được trích dẫn ở các tr. 6, 8).

[45] OpenAI, *Sự cố Hugging Face và lộ trình phía trước (The Hugging Face incident and the road ahead)*, Tháng 8 năm 2026 (được trích dẫn ở tr. 6).

[46] M. Sulmeyer, "Trí tuệ nhân tạo và nguy cơ tấn công mạng chiến lược (Artificial intelligence and the risk of strategic cyberattack)," RAND Corporation, Báo cáo Kỹ thuật, Tháng 7 năm 2026 (được trích dẫn ở tr. 6).

[47] D. Hendrycks, E. Schmidt, và A. Wang, *Chiến lược Siêu trí tuệ: Phiên bản chuyên gia (Superintelligence strategy: Expert version)*, Tháng 3 năm 2025. DOI: 10.48550/arXiv.2503.05628 (được trích dẫn ở các tr. 6, 8).

[48] C. O'Keefe, A. Z. Rozenshtein, và C. Winter, *AI nhánh hành pháp và nhà nước pháp quyền: Một chương trình nghị sự nghiên cứu mới nổi (Executive branch AI and the rule of law: An emerging*

research agenda), Tháng 5 năm 2026 (được trích dẫn ở tr. 6).

[49] T. Davidson, L. Finnveden, và R. Hadshar, "Các cuộc đảo chính có sự hỗ trợ của AI: Cách một nhóm nhỏ có thể sử dụng AI để giành quyền lực (AI-enabled coups: How a small group could use AI to seize power)," 2025 (được trích dẫn ở tr. 6).

[50] J. Edwards và L. Emberson, *Các mô hình mở tụt hậu so với các mô hình đóng tối tân 4 tháng (Open models lag state-of-the-art closed models by 4 months)*, Tháng 5 năm 2026 (được trích dẫn ở tr. 6).

[51] R. Slayton, "Cán cân tấn công - phòng thủ trên không gian mạng là gì? Khái niệm, nguyên nhân và đánh giá (What is the cyber offense-defense balance? Conceptions, causes, and assessment)," *International Security*, tập 41, số 3, tr. 72–109, 2017. DOI: 10.1162/ISEC_a_00267 (được trích dẫn ở tr. 6).

[52] B. Garfinkel và A. Dafoe, "Cán cân tấn công - phòng thủ mở rộng quy mô như thế nào? (How does the offense-defense balance scale?)," *Journal of Strategic Studies*, tập 42, số 6, tr. 736–763, Tháng 8 năm 2019. DOI: 10.1080/01402390.2019.1631810 (được trích dẫn ở tr. 6).

[53] Đạo luật Minh bạch trong Trí tuệ Nhân tạo Tiên phong (Transparency in Frontier Artificial Intelligence Act), SB 53, Kỳ họp thường kỳ 2025–2026 (California 2025), Tháng 9 năm 2025 (được trích dẫn ở tr. 7).

[54] Ủy ban Châu Âu (European Commission), *Bộ quy tắc thực hành cho AI đa mục đích (The general-purpose AI code of practice)*, Tháng 7 năm 2025 (được trích dẫn ở tr. 7).

[55] Đạo luật Giáo dục và An toàn AI có Trách nhiệm (Responsible AI Safety and Education - RAISE Act), A6453B, Kỳ họp thường kỳ 2025–2026 (New York 2025), Tháng 12 năm 2025 (được trích dẫn ở tr. 7).

[56] J. Kwon và S. Casper, *Các lỗ hổng triển khai nội bộ trong quản lý AI (Internal deployment gaps in AI regulation)*, Tháng 1 năm 2026. DOI: 10.48550/arXiv.2601.08005 (được trích dẫn ở tr. 7).

[57] M. Pistillo, *Triển khai nội bộ trong Đạo luật AI (Internal deployment in the AI Act)*, Tháng 6 năm 2026 (được trích dẫn ở tr. 7).

[58] A. Chan, R. Padarath, J. Kwon, H. Greaves, và M. Anderljung, *Đo lường mức độ tự động hóa R&D AI (Measuring AI R&D automation)*, Tháng 3 năm 2026. DOI: 10.48550/arXiv.2603.03992 (được trích dẫn ở tr. 7).

[59] M. Brundage, N. Dreksler, A. Homewood, S. McGregor, P. Paskov, C. Stosz, G. Sastry, A. F. Cooper, G. Balston, S. Adler, S. Casper, M. Anderljung, G. Werner, S. Mindermann, V. Mavroudis, B. Bucknall, C. Stix, J. Freund, L. Pacchiardi, J. Hernandez-Orallo, M. Pistillo, M. Chen, C. Painter, D. W. Ball, C. O'Keefe, G. Weil, B. Harack, G. Finley, R. Hassan, S. Emmons, C. Foster, A. Reuel, B. Treece, Y. Bengio, D. Reti, R. Bommasani, C. Trout, A. S. Shamsabadi, R. Dattani, A. Weller, R. Trager, J. Sevilla, L. Wagner, L. Soder, K. Ramakrishnan, H. Papadatos, M. Murray, và R. Tovcimak, *Kiểm toán AI tiên phong: Hướng tới đánh giá độc lập nghiêm ngặt các quy trình an toàn và bảo mật tại các công ty AI hàng đầu (Frontier AI auditing: Toward rigorous third-party assessment of safety and security*

practices at leading AI companies), Tháng 2 năm 2026. DOI: 10.48550/arXiv.2601.11699 (được trích dẫn ở tr. 7).

[60] P. Wills, *Giám sát quy định đối với các nhà phát triển AI tiên phong (Regulatory supervision of frontier AI developers)*, Bài báo học thuật SSRN, Rochester, NY, Tháng 3 năm 2025. DOI: 10.2139/ssrn.5122871 (được trích dẫn ở tr. 7).

[61] Ủy ban Điều tiết Hạt nhân Hoa Kỳ (U.S. Nuclear Regulatory Commission), *Thông tin cơ bản về các thanh tra thường trú của NRC (Backgrounder on NRC resident inspectors)*, 2023 (được trích dẫn ở tr. 7).

[62] Văn phòng Tổng kiểm soát Tiền tệ Hoa Kỳ (Office of the Comptroller of the Currency), *Những việc chúng tôi làm (What we do)*, 2026 (được trích dẫn ở tr. 7).

[63] M. Baker, G. Kulp, O. Marks, M. Brundage, và L. Heim, *Xác minh các thỏa thuận quốc tế về AI: Sáu cấp độ xác minh cho các quy tắc về phát triển và triển khai AI quy mô lớn (Verifying international agreements on AI: Six layers of verification for rules on large-scale AI development and deployment)*, Tháng 7 năm 2025. DOI: 10.48550/arXiv.2507.15916 (được trích dẫn ở tr. 7).

[64] B. Harack, R. F. Trager, A. Reuel, D. Manheim, M. Brundage, O. Aarne, A. Scher, Y. Pan, J. Xiao, K. Loke, S. N. Adan, G. Bas, N. A. Caputo, J. C. Morse, J. Ahuja, I. Duan, J. Egan, B. Bucknall, B. Rosen, R. Araujo, V. Boulanin, R. Lall, F. Barez, S. Alvira, C. Katzke, A. Atamli, và A. Awad, "Xác minh phục vụ quản trị AI quốc tế (Verification for international AI governance)," Sáng kiến Quản trị AI Oxford Martin, Đại học Oxford, Báo cáo Kỹ thuật, Tháng 7 năm 2025 (được trích dẫn ở các tr. 7, 8).

[65] T. Larsen, R. Dean, B. Halstead, E. Lifland, R. Greenblatt, và D. Kokotajlo, *AI 2040: Kế hoạch A (AI 2040: Plan A)*, Dự án Tương lai AI (AI Futures Project), 2026 (được trích dẫn ở các tr. 7, 8).

[66] G. Sastry, L. Heim, H. Belfield, M. Anderljung, M. Brundage, J. Hazell, C. O'Keefe, G. K. Hadfield, R. Ngo, K. Pilz, G. Gor, E. Bluemke, S. Shoker, J. Egan, R. F. Trager, S. Avin, A. Weller, Y. Bengio, và D. Coyle, *Năng lực tính toán và việc quản trị trí tuệ nhân tạo (Computing power and the governance of artificial intelligence)*, Tháng 2 năm 2024. DOI: 10.48550/arXiv.2402.08797 (được trích dẫn ở tr. 7).

[67] A. Korinek và J. E. Stiglitz, *Định hướng tiến bộ công nghệ (Steering technological progress)*, Báo cáo Nghiên cứu, Tháng 3 năm 2026. DOI: 10.3386/w34994 (được trích dẫn ở tr. 8).

[68] S. Shoker, A. Reddie, S. Barrington, R. Booth, M. Brundage, H. Chahal, M. Depp, B. Drexel, R. Gupta, M. Favaro, J. Hecla, A. Hickey, M. Konaev, K. Kumar, N. Lambert, A. Lohn, C. O'Keefe, N. Rajani, M. Sellitto, R. Trager, L. Walker, A. Wehsener, và J. Young, *Các biện pháp xây dựng lòng tin đối với trí tuệ nhân tạo: Kỷ yếu hội thảo (Confidence-building measures for artificial intelligence: Workshop proceedings)*, Tháng 8 năm 2023. DOI: 10.48550/arXiv.2308.00862 (được trích dẫn ở tr. 8).

[69] Intelligence Rising, *Intelligence Rising*, không rõ ngày tháng (được trích dẫn ở tr. 8).

[70] Dự án Tương lai AI (AI Futures Project), *Giới thiệu về AI 2027: Bài tập diễn tập trên bàn (About AI 2027: Tabletop exercise)*, 2025 (được trích dẫn ở tr. 8).

[71] G. Smith, G. Hage, C. Heitzenrater, M. Chessen, và R. S. Girven, “Tiềm năng vô hạn — những góc nhìn từ kịch bản bất ngờ trên không gian mạng (Infinite potential—insights from the cyber surprise scenario),” RAND Corporation, Báo cáo Kỹ thuật, Tháng 3 năm 2026 (được trích dẫn ở tr. 8).

[72] L. Vaintrob, *Khoảng cách ứng dụng AI: Chuẩn bị cho chính phủ Hoa Kỳ trước AI tiên tiến (The AI adoption gap: Preparing the US government for advanced AI)*, Tháng 4 năm 2025 (được trích dẫn ở tr. 8).

[73] OpenAI, *Đặc tả mô hình OpenAI (OpenAI model spec)*, Tháng 8 năm 2026 (được trích dẫn ở tr. 8).

[74] Anthropic, *Hiến pháp của Claude (Claude’s constitution)*, Tháng 1 năm 2026 (được trích dẫn ở tr. 8).

[75] C. O’Keefe, K. Ramakrishnan, J. Tay, và C. Winter, “AI tuân thủ pháp luật: Thiết kế các tác tử AI tuân theo luật pháp của con người (Law-following AI: Designing AI agents to obey human laws),” *Fordham Law Review*, tập 94, số 1, tr. 57, 2025 (được trích dẫn ở tr. 8).

[76] S. Guerra, A. Attal-Juncqua, J. P. Tarangelo, C. Aveggio, K. Dammer, và D. Glickstein, “Xây dựng chiến lược an ninh sinh học phòng thủ chiều sâu cho kỷ nguyên AI (Building a defense-in-depth biosecurity strategy for the AI era),” RAND Corporation, Báo cáo Kỹ thuật, Tháng 8 năm 2026 (được trích dẫn ở tr. 8).

[77] J.-S. Denain, A. Ho, và J. Sevilla, *OpenAI có thể triển khai bao nhiêu lao động kỹ thuật số? (How many digital workers could OpenAI deploy?)*, Tháng 10 năm 2025 (được trích dẫn ở tr. 12).

[78] H. Wijk, T. Lin, J. Becker, S. Jawhar, N. Parikh, T. Broadley, L. Chan, M. Chen, J. Clymer, J. Dhyani, E. Ericheva, K. Garcia, B. Goodrich, N. Jurkovic, H. Karnofsky, M. Kinniment, A. Lajko, S. Nix, L. Sato, W. Saunders, M. Taran, B. West, và E. Barnes, *RE-Bench: Đánh giá năng lực R&D AI tiên phong của các tác tử mô hình ngôn ngữ so với các chuyên gia con người (RE-Bench: Evaluating frontier AI R&D capabilities of language model agents against human experts)*, Tháng 5 năm 2025. DOI: 10.48550/arXiv.2411.15114 (được trích dẫn ở tr. 12).

[79] A. Ho, J.-S. Denain, D. Atanasov, S. Albanie, và R. Shah, *Tấm đá Rosetta cho các bộ chuẩn đánh giá AI (A rosetta stone for AI benchmarks)*, 2025 (được trích dẫn ở tr. 13).

[80] B. Cottier, B. Snodin, D. Owen, và T. Adamczewski, *Giá suy luận LLM đã giảm nhanh chóng nhưng không đồng đều giữa các tác vụ (LLM inference prices have fallen rapidly but unequally across tasks)*, Tháng 3 năm 2025 (được trích dẫn ở các tr. 13, 14).

[81] H. Gundlach, A. Fogelson, J. Lynch, A. Trisovic, J. Rosenfeld, A. Sandhu, và N. Thompson, *Về nguồn gốc của tiến bộ thuật toán trong AI (On the origin of algorithmic progress in AI)*, Tháng 11 năm 2025. DOI: 10.48550/arXiv.2511.21622 (được trích dẫn ở tr. 13).

[82] P. Trammell, “Khả năng song song hóa có giới hạn của R&D: Lý thuyết và ứng dụng vào AI (The bounded parallelizability of R&D: Theory and application to AI),” Tháng 7 năm 2026 (được trích dẫn ở tr. 13).

[83] METR, *Đo lường khả năng hoàn thành các tác vụ dài của AI (Measuring AI ability to complete long tasks)*, Tháng 3 năm 2025 (được trích dẫn ở tr. 13).

[84] D. Kokotajlo, S. Alexander, T. Larsen, E. Lifland, và R. Dean, *AI 2027*, Tháng 4 năm 2025 (được trích dẫn ở tr. 14).

[85] T. Ord, *Động lực học của các vụ bùng nổ trí tuệ (The dynamics of intelligence explosions)*, 2026. arXiv: 2608.14426 [cs.AI] (được trích dẫn ở tr. 14).

[86] B. Murphy và T. Stone, *Kẻ tấn công được nâng cấp, người phòng thủ là con người: Cán cân tấn công - phòng thủ trên không gian mạng đối với các tổ chức đi sau (Uplifted attackers, human defenders: The cyber offense-defense balance for trailing-edge organizations)*, Tháng 8 năm 2025. DOI: 10.48550/arXiv.2508.15808 (được trích dẫn ở tr. 14).

[87] Anthropic, *Investigating three real-world incidents in our cybersecurity evaluations*, tháng 7 năm 2026 (trích dẫn ở tr. 14).

[88] Viện An toàn AI Vương quốc Anh (UK AI Security Institute), *Incident report: Unsanctioned agent behaviour during cyber testing*, tháng 8 năm 2026 (trích dẫn ở tr. 14).

[89] OpenAI, *Third-party cyber evaluations involving OpenAI models*, tháng 8 năm 2026 (trích dẫn ở tr. 14).

[90] P. C. Bogdan, R. Qi, J. Eaton, S. Kennedy, F. Roger, A. Glynn, R. Chen, B. Wright, O. Stegmaier, J. Kutasov, D. Foreman-Mackey, T. Bricken, S. Carr, S. Carter, M. MacDiarmid, S. Marks, A. Pearce, E. Simon, N. Carlini, C. Burns, J. Lindsey, S. Price, và S. Kantamneni, *An alignment assessment of recent cybersecurity incidents*, Anthropic, tháng 9 năm 2026 (trích dẫn ở tr. 14).

[91] M. H. Tessler, M. A. Bakker, D. Jarrett, H. Sheahan, M. J. Chadwick, R. Koster, G. Evans, L. Campbell-Gillingham, T. Collins, D. C. Parkes, M. Botvinick, và C. Summerfield, "AI can help humans find common ground in democratic deliberation," *Science*, tập 386, số 6719, eadq2852, tháng 10 năm 2024. DOI: 10.1126/science.adq2852 (trích dẫn ở tr. 14).

[92] A. Goldie và A. Mirhoseini, *How AlphaChip transformed computer chip design*, tháng 9 năm 2024 (trích dẫn ở tr. 14).

Tài liệu bổ sung

Ước tính quy mô hiệu dụng của lực lượng lao động AI

Theo phương pháp của Denain và cộng sự [77], chúng tôi ước tính lực lượng lao động hiệu dụng bằng cách lấy số lượng token mà một nhà phát triển có thể tạo ra mỗi ngày chia cho số lượng token tương ứng với một ngày làm việc của một nhà nghiên cứu. Riêng OpenAI đã có đủ năng lực tính toán suy luận (tức là năng lực tính toán khi vận hành) để tạo ra khoảng 10^{13} token mỗi ngày. Để ước tính số token trên mỗi ngày nghiên cứu, chúng tôi sử dụng số lượng token mà một mô hình tạo ra cho một tác vụ mà một nhà nghiên cứu con người phải mất một ngày làm việc (8 giờ) để hoàn thành. Trong một bài kiểm chuẩn R&D về AI, Wijk và cộng sự [78] nhận thấy rằng các mô hình tạo ra trung bình $5 \cdot 10^5$ token trong các lượt chạy kéo dài tới 8 giờ, ngụ ý lực lượng lao động hiệu dụng tương đương khoảng $2 \cdot 10^7$ nhà nghiên cứu. Tính đến độ bất định khoảng một bậc độ lớn theo cả hai hướng ($5 \cdot 10^4$–$5 \cdot 10^6$ token trên mỗi ngày nghiên cứu), chúng tôi ước tính lực lượng lao động hiệu dụng rơi vào khoảng $2 \cdot 10^6$–$2 \cdot 10^8$. Tương tự như trong bài viết chính, điều này giả định rằng các hệ thống AI ở cấp độ chuyên gia có chi phí vận hành tương đương với các hệ thống hiện nay.

Mô hình hóa vòng phản hồi khi tự động hóa hoàn toàn

Hầu hết các phân tích về sự bùng nổ trí tuệ do phần mềm dẫn dắt đều mô tả tiến bộ AI thông qua một khái niệm về chất lượng phần mềm, ký hiệu là A. Về nguyên tắc, A phải đo lường tiến bộ AI một cách toàn diện, bao gồm cả những cải tiến về hiệu quả (các hệ thống AI mới hoàn thành các tác vụ tương tự hệ thống cũ với hiệu năng tương đương nhưng sử dụng ít điện toán hoặc dữ liệu hơn) và

những cải tiến về năng lực (các hệ thống AI mới hoàn thành các tác vụ mà hệ thống trước đây không thể làm được, hoặc đạt hiệu năng cao hơn hệ thống tiền nhiệm). Điều đáng tiếc là hiện vẫn chưa rõ tham số A nên đánh đổi tối ưu như thế nào giữa các cải tiến về hiệu quả và các cải tiến về năng lực (hoặc giữa các dạng cải tiến hiệu quả và cải tiến năng lực khác nhau).

Gác vấn đề này sang một bên, chúng tôi mô hình hóa sự tăng trưởng của chất lượng phần mềm theo phương trình $dA/dt = A^{1-\beta}E^{\lambda}$, một dạng hàm phổ biến trong kinh tế học vĩ mô về đổi mới sáng tạo [27]. Để đơn giản hóa, chúng tôi bỏ qua các điểm nghẽn tiềm ẩn từ điện toán và dữ liệu. Ở đây, E là lao động R&D hiệu dụng, λ biểu thị hiệu suất theo quy mô của lao động R&D, và β biểu thị việc liệu việc tìm kiếm các ý tưởng mới theo thời gian có mang lại lợi suất tăng dần hay giảm dần.

Câu hỏi then chốt là E tăng trưởng theo A như thế nào. Giả định tự động hóa hoàn toàn, chúng tôi xem xét hai trường hợp. Thứ nhất, xét trường hợp mà tất cả các cải tiến về chất lượng phần mềm đều là sự gia tăng hiệu quả tính toán suy luận, nghĩa là giảm lượng điện toán cần thiết để vận hành một hệ thống AI ở một mức năng lực nhất định. Trong trường hợp đó, nếu A đo lường hiệu quả suy luận, thì E tỷ lệ thuận với A: hiệu quả suy luận cao hơn cho phép vận hành nhiều nhà nghiên cứu tự động hơn theo tỷ lệ tương ứng.

Thứ hai, xét trường hợp mà tất cả các cải tiến về chất lượng phần mềm đều là sự gia tăng năng lực, được thúc đẩy bởi sự cải thiện hiệu quả tính toán huấn luyện: giảm lượng điện toán cần thiết để huấn luyện một hệ thống AI đạt tới một mức năng lực nhất định, cho phép một hệ thống có năng lực cao hơn được huấn luyện với một lượng điện toán cố định. Nếu A đo lường hiệu quả tính toán huấn luyện, thì sự gia tăng của A sẽ tạo ra các hệ thống có năng lực cao hơn thay vì tạo ra nhiều hệ thống hơn. Nếu chúng tôi đưa ra giả định (có thể còn gây tranh cãi) rằng số lượng nhà nghiên cứu hiệu dụng tăng tuyến tính theo những mức gia tăng năng lực này, thì một lần nữa E lại tỷ lệ thuận với A.

Trong cả hai trường hợp, $E = kA$ với một hằng số dương k nào đó. Thay vào phương trình trên ta được $dA/dt = cA^{\lambda-\beta+1}$, trong đó $c = k^{\lambda}$. Để tốc độ tăng trưởng $(1/A)dA/dt$ tăng lên khi chất lượng phần mềm tăng, ta cần điều kiện $\lambda > \beta$. Định nghĩa $r = \lambda/\beta$, ta thu được điều kiện $r > 1$ đã thảo luận trong phần nội dung chính.

Tiến bộ có thể tăng tốc nhanh đến mức nào theo các ước tính hiện tại về những tham số này? Chúng tôi đo lường sự tăng tốc bằng tốc độ tăng trưởng của chất lượng phần mềm: $(1/A)dA/dt = c \cdot A^{\lambda-\beta}$. Lấy trung bình các ước tính trung tâm trên ba lĩnh vực con trong Ho và Whitfill [28], ta có $\lambda = 1{,}40$ và $\beta = 1{,}01$. Với $\lambda - \beta = 0{,}39$, mỗi lần tăng gấp đôi của A sẽ nhân tốc độ tăng trưởng thêm $2^{0{,}39} \approx 1{,}31$ lần, do đó mỗi lần tăng gấp đôi tiếp theo chỉ mất $(1/2)^{0{,}39} \approx 76\%$ thời gian so với lần trước. Để tốc độ tăng trưởng tăng gấp 10 lần, A cần tăng gấp đôi $\log_2(10)/0{,}39 \approx 8{,}5$ lần. Đối với khoảng thời gian của lần tăng gấp đôi đầu tiên, chúng tôi sử dụng các ước tính gần đây cho thấy rằng chỉ riêng nhờ những cải tiến phần mềm, hiệu quả tính toán huấn luyện tăng gấp đôi sau khoảng mỗi 4,5 tháng [79]; hiệu quả tính toán suy luận thậm chí có thể còn tăng trưởng nhanh hơn [80]. Để tránh phải tính xấp xỉ tổng cấp số nhân cho 8,5 lần tăng gấp đôi, thay vào đó chúng tôi tính tổng cấp số nhân cho 9 lần tăng gấp đôi, sau khoảng thời gian này tốc độ tăng trưởng sẽ tăng hơn mười lần. Khi thực hiện phép tính, chúng tôi nhận thấy tốc độ tăng trưởng sẽ tăng hơn mười lần sau $4{,}5 \text{ tháng} \times (1 - 0{,}76^9)/(1 - 0{,}76) \approx 17 \text{ tháng}$, hay khoảng 1,5 năm. Tại thời điểm đó, tiến bộ sẽ nhanh gấp mười lần so với hiện nay, nghĩa là khối lượng tiến bộ của một năm với tốc độ ngày nay sẽ chỉ mất khoảng năm tuần.

Những điểm không chắc chắn về lợi suất của nỗ lực nghiên cứu

Một số yếu tố có thể khiến giá trị thực của r khác biệt so với các ước tính hiện có. Thứ nhất, như đã lưu ý ở trên, vẫn chưa rõ thước đo chất lượng phần mềm nào là phù hợp nhất. Hiệu quả suy luận ánh xạ trực tiếp nhất vào quy mô của lực lượng lao động R&D tự động, trong khi chưa rõ cách chuyển đổi các mức tăng hiệu quả huấn luyện thành số lượng nhà nghiên cứu hiệu dụng. Tuy nhiên, các ước tính hiện tại về r cho hoạt động R&D về AI lại sử dụng hiệu quả huấn luyện, và vẫn chưa rõ lợi suất của nỗ lực nghiên cứu theo hai thước đo này tương đồng đến mức nào. Hơn nữa, việc đánh giá đúng đắn lợi suất của nỗ lực nghiên cứu cần phải bao gồm cả những cải tiến từ hiệu quả suy luận lẫn hiệu quả huấn luyện, thay vì chỉ xét một khía cạnh. Cần có thêm nhiều nghiên cứu để xây dựng một tiêu chí đặc trưng cho chất lượng phần mềm kết hợp cả hiệu quả suy luận và hiệu quả huấn luyện, đồng thời cân đối chúng với nhau một cách thích hợp.

Các ước tính hiện tại về r bắt nguồn từ một giai đoạn mở rộng quy mô điện toán nhanh chóng, điều này làm xáo trộn và khó phân biệt sự đóng góp của tiến bộ phần mềm với sự gia tăng quy mô điện toán. Do hai yếu tố đầu vào này trong lịch sử cùng tăng trưởng song hành, một ước tính quy sự tiến bộ quan sát được cho các cải tiến phần mềm có thể trên thực tế lại đang ghi nhận những thành quả được thúc đẩy bởi, hoặc chỉ có thể khả thi nhờ vào sự gia tăng điện toán. Một số cải tiến phần mềm phụ thuộc vào quy mô: ví dụ, kiến trúc Transformer mang lại hiệu năng vượt trội ở mức điện toán huấn luyện cao nhưng lại cải thiện tương đối nhỏ ở mức điện toán thấp [81]. Sự nhiễu loạn như vậy sẽ làm lệch các ước tính về r theo hướng cao hơn thực tế: trong một chế độ mà tài nguyên điện toán cố định hoặc tăng trưởng chậm, r sẽ thấp hơn mức dữ liệu lịch sử gợi ý.

Những yếu tố khác có thể hàm ý một giá trị r cao hơn. Hầu hết các ước tính về r đều bỏ qua những cải tiến trong các lĩnh vực nằm ngoài giai đoạn tiền huấn luyện (pre-training), chẳng hạn như hậu huấn luyện (post-training) hoặc khung điều phối (scaffolding) tốt hơn cho việc sử dụng công cụ [35]. Hơn nữa, những cải tiến về năng lực có thể tạo ra tác động theo những cách mà số lượng nhà nghiên cứu hiệu dụng không thể phản ánh hết: ngay cả một lượng cực lớn các nhà nghiên cứu bậc trung cũng không thể thay thế cho một nhà nghiên cứu thiên tài. Nếu đúng như vậy, sự gia tăng năng lực sẽ mở rộng lao động R&D hiệu dụng nhiều hơn so với mức mà giả định tuyến tính ở trên đưa ra. Các điểm nghẽn về điện toán cũng có thể được khắc phục, chẳng hạn như thông qua việc ngoại suy tốt hơn từ các thử nghiệm quy mô nhỏ, giảm chi phí thử nghiệm nhờ tiến bộ phần mềm, chuyển hướng sang các phương pháp ít phụ thuộc vào điện toán hơn, và tiến bộ thuật toán không đòi hỏi thử nghiệm [7].

Các ước tính về r cũng phụ thuộc vào các biến đại diện (proxy) không hoàn hảo cho lao động R&D, điều này có thể làm sai lệch chúng theo cả hai hướng. Ví dụ, Ho và Whitfill [28] sử dụng số lượng tác giả duy nhất đã công bố bài báo trong một lĩnh vực làm đại diện cho lao động R&D. Việc xác định phạm vi lĩnh vực quá hẹp sẽ đếm thiếu lao động do loại trừ các lĩnh vực lân cận vốn cũng thúc đẩy tiến bộ, trong khi xác định phạm vi quá rộng lại đếm thừa lao động. Trừ khi các lĩnh vực lân cận bị loại trừ có cùng tốc độ tăng trưởng lao động như các lĩnh vực được đưa vào, sự sai lệch này sẽ dẫn đến việc tính toán sai r.

Cuối cùng, các mô hình toán học liên quan có thể không khái quát hóa được cho khối lượng lao động R&D cực lớn [82]. Trong lịch sử, chúng được kiểm chứng dựa trên tốc độ tăng trưởng chỉ vài phần

trăm mỗi năm, thấp hơn nhiều so với tốc độ hai chữ số hoặc cao hơn mà một sự bùng nổ trí tuệ có thể tạo ra. Chúng cũng bị phá vỡ ở điểm giới hạn cực hạn, nơi chúng ngụ ý rằng lượng lao động vô hạn sẽ mang lại tiến bộ vô hạn trong một khoảng thời gian hữu hạn. Nhưng các rào cản thực tế khiến kết quả này là bất khả thi: một số vấn đề bắt buộc phải được giải quyết theo trình tự, và phần cứng vật lý chỉ có thể vận hành ở một tốc độ tối đa nhất định.

Ghi chú

1. Các hội nghị học máy thường có một phiên hội nghị chính (main track) và một vài phiên hội thảo chuyên đề (workshop tracks). Một lưu ý đối với các kết quả là các phiên hội thảo này có thể có tiêu chuẩn lỏng lẻo hơn đôi chút so với phiên hội nghị chính.
2. Theo thước đo khung thời gian của METR [17, 83], độ dài của các tác vụ mà hệ thống AI có thể hoàn thành ban đầu tăng gấp đôi sau khoảng mỗi 7 tháng, và đã tăng tốc lên mức khoảng 3 tháng một lần kể từ năm 2024. Việc ngoại suy xu hướng gần đây hơn này cho thấy rằng đến giữa năm 2028, các hệ thống AI sẽ có khả năng hoàn thành các tác vụ đòi hỏi nhiều tháng làm việc của chuyên gia là con người...

thời gian, hoàn toàn nằm trong phạm vi của nhiều dự án R&D AI. Xem thêm Kokotajlo và cộng sự [84].

3. Cottier và cộng sự [80] nhận thấy rằng chi phí vận hành các mô hình ngôn ngữ lớn (LLM) để đạt được một cột mốc năng lực nhất định (ví dụ: hiệu năng tương đương GPT-4 trên một bài kiểm tra chuẩn về toán học) đã giảm khoảng từ 9 đến 900 lần mỗi năm, tùy thuộc vào cột mốc năng lực cụ thể. Mặc dù một phần của sự suy giảm chi phí này bắt nguồn từ các cải tiến phần cứng (làm giảm chi phí cho mỗi phép tính), nhưng một tỷ trọng đáng kể là nhờ vào các cải tiến phần mềm.
4. Trong một lĩnh vực công nghệ, r chi phối mối quan hệ giữa sự gia tăng các yếu tố đầu vào cho R&D và sự thay đổi kết quả đầu ra tương ứng được quan tâm, chẳng hạn như số lượng phép tính mà phần cứng tiêu dùng tối tân có thể thực hiện trên mỗi đơn vị đô la cố định. Trong nghiên cứu của Bloom và cộng sự [27], yếu tố đầu vào được đo bằng số đô la chi cho R&D, do đó bao gồm cả sự gia tăng về lao động lẫn vốn vật chất. Tuy nhiên, trong bài viết này, chúng tôi chỉ xem xét sự gia tăng về lao động, vì chúng tôi quan tâm đến việc tìm hiểu tiềm năng của một vòng lặp phản hồi do phần mềm thúc đẩy, trong đó quy mô tài nguyên tính toán (compute stock) được giữ gần như không đổi. Điều này đồng nghĩa với việc giá trị của r sẽ thấp hơn so với trường hợp xem xét sự gia tăng ở tất cả các yếu tố đầu vào (tức là lao động, dữ liệu và tài nguyên tính toán).
5. r cuối cùng chắc chắn phải giảm xuống dưới 1 vì tiến bộ AI sau cùng sẽ chạm phải các giới hạn vật lý và giới hạn tính toán. Hiện vẫn chưa rõ mức độ tiến bộ có thể đạt được là bao nhiêu trước khi tiến đến những giới hạn đó.
6. Các khoảng tin cậy 90% (credible intervals) lần lượt là (0,727 đến 2,094), (0,380 đến 2,708), và (1,069 đến 3,212).
7. Trong phân tích này, những cải tiến về hiệu quả thuật toán tự thân chúng không giải quyết được nút thắt tiềm tàng này, bởi vì chúng nâng cao hiệu quả của cả hoạt động R&D lẫn quá trình huấn luyện theo cùng một tỷ lệ tương đương.
8. Cụ thể, bài báo cung cấp các điều kiện mà theo đó lao động nghiên cứu tự động, cùng với các đại lượng khác như sản lượng kinh tế, sẽ tăng trưởng tới vô hạn trong một khoảng thời gian hữu hạn.
9. Xem Ord [85] để có thảo luận mang tính lý thuyết về việc khoảng thời gian giữa các vòng lặp R&D có thể ảnh hưởng như thế nào đến động lực học của một vụ bùng nổ trí tuệ.
10. Phân tích trong nghiên cứu của Cunningham và cộng sự [37] tập trung vào sự tăng tốc tự duy trì (self-sustaining acceleration): “Khi các hệ thống AI đã đủ khả năng tự đẩy nhanh tiến độ nâng cao năng lực AI mà không cần bất kỳ sự gia tăng nào từ các yếu tố đầu vào ngoại sinh (lao động của con người, tài nguyên tính toán phục vụ huấn luyện, v.v.).” Sự tăng tốc tự duy trì là điều kiện tiên quyết đối với một vụ bùng nổ trí tuệ do phần mềm thúc đẩy theo quan niệm của chúng tôi.
11. Các hệ thống như vậy có thể đạt mức siêu việt (superhuman) trong một số lĩnh vực (ví dụ: một số lĩnh vực nghiên cứu khoa học nhất định) nhưng lại không đạt được điều đó ở các lĩnh vực khác (ví dụ: thao tác với các vật thể trong thế giới vật lý).
12. Tuy nhiên, ngay cả trong lĩnh vực không gian mạng, các quy trình tổ chức mang tính con người vẫn có thể tạo ra lực cản đáng kể cho phía phòng thủ [86].
13. Xem thêm Anthropic [87], Viện An toàn AI Vương quốc Anh [88], OpenAI [89], và Bogdan cùng cộng sự [90].
14. Chẳng hạn, xem Tessler và cộng sự [91]. Mang tính suy đoán xa hơn, các hệ thống AI có khả năng thúc đẩy quá trình phát triển các giao diện não - máy tính (BCI), cho phép con người tư duy và phối hợp với tốc độ nhanh hơn nhiều.

15. Việc thao tác hóa (operationalizing) một cách chuẩn xác khái niệm bùng nổ trí tuệ là một vấn đề phức tạp và vẫn là hướng nghiên cứu còn bỏ ngỏ cho tương lai.
16. Chẳng hạn, AI hiện đã đang hỗ trợ đắc lực cho công việc thiết kế vi mạch [92]. Các hệ thống AI cũng có thể đẩy nhanh tốc độ phát triển của lĩnh vực robot nhằm tự động hóa hoàn toàn quy trình sản xuất vi mạch.