Điều gì sẽ xảy ra nếu việc tự động hóa R&D AI kích hoạt một vụ bùng nổ trí tuệ?

Chuỗi Báo cáo Nghiên cứu AI Tiên phong Số 2/2026

Tháng 9 năm 2026

Điều gì sẽ xảy ra nếu việc tự động hóa R&D AI kích hoạt

một vụ bùng nổ trí tuệ?

Alan Chan*
GovAI

Christoph Winter
CASP, Đại học Cambridge, Viện Luật & AI

Andrew Barto
Đại học Massachusetts Amherst

Jakub Pachocki
OpenAI

Geoffrey Hinton
Đại học Toronto, Viện Vector

Eric Horvitz
Microsoft

Yoshua Bengio
Mila (Viện AI Quebec), Đại học Montréal, LawZero

Dawn Song
Đại học California, Berkeley

Jack Clark
Anthropic

Hilary Greaves
Đại học Oxford

Anton Korinek
Đại học Virginia, Anthropic

Samuel Hammond
Quỹ Sáng tạo Hoa Kỳ

Thore Graepel
Đại học College London

Ben Bariach
Đại học Oxford

Philip H. S. Torr
Đại học Oxford

Sheila A. McIlraith
Đại học Toronto, Viện Vector

Jeff Clune
Đại học British Columbia, Viện Vector

Sam Manning
GovAI, Quỹ Sáng tạo Hoa Kỳ

Girish Sastry
Guidelight

Tom Davidson
Forethought

Daniel Eth
Viện Chính sách AI

Sören Mindermann*
CASP, Đại học Cambridge

TÓM TẮT

Khác hẳn với tình hình chỉ một năm trước, các hệ thống trí tuệ nhân tạo (AI) hiện nay đã tự viết phần lớn mã nguồn bên trong chính các công ty phát triển ra chúng. Khi ngày càng nhiều khâu trong quy trình nghiên cứu và phát triển (R&D) AI được tự động hóa, liệu tiến trình phát triển AI có thể tăng tốc đột biến thành một "vụ bùng nổ trí tuệ" — nơi những bước tiến vốn mất nhiều năm trời được nén lại chỉ trong vài tháng hoặc thậm chí ít hơn? Các bằng chứng sơ bộ cho thấy điều này hoàn toàn có thể xảy ra. Trong công trình này, chúng tôi đánh giá các bằng chứng nói trên, phân tích những tác động tiềm tàng của một vụ bùng nổ trí tuệ và đề xuất các phản ứng chính sách tương ứng. Các hệ thống AI đang trên đà tự động hóa phần lớn công việc R&D AI trong vòng vài năm tới, và có khả năng là toàn bộ quy trình. Nếu kịch bản này kích hoạt một vụ bùng nổ trí tuệ, nó có thể mang lại những lợi ích to lớn của AI sớm hơn rất nhiều, nhưng đồng thời cũng đặt ra những rủi ro cực độ: năng lực AI có thể tăng tốc vượt xa khả năng theo kịp của xã hội, nhân loại có thể đánh mất quyền kiểm soát đối với các hệ thống AI siêu phàm, và cơ chế kiểm soát quyền lực bên trong cũng như giữa các quốc gia, các tập đoàn và các nhánh quyền lực nhà nước có thể bị xói mòn nghiêm trọng. Dù vẫn còn nhiều bất định xoay quanh những khả năng này, nhưng tính chất hệ trọng của vấn đề đòi hỏi sự quan tâm sâu sắc hơn nữa. Các nhà hoạch định chính sách cần khẩn trương nắm bắt rõ nét hơn về tình hình tự động hóa R&D AI, xây dựng các phương thức định hướng và kiểm soát vụ bùng nổ trí tuệ, đồng thời chuẩn bị cho toàn xã hội khả năng thích ứng với các tác động của nó.

*Thư từ trao đổi gửi về: alan.chan@governance.ai và soren.mindermann@casp.ac. Các quan điểm trình bày trong bài viết này là của riêng các tác giả và không nhất thiết phản ánh quan điểm của các tổ chức mà họ trực thuộc.

Mở đầu

Từ lâu, các nhà khoa học máy tính đã đưa ra lý thuyết rằng một ngày nào đó các hệ thống AI sẽ có khả năng tự thiết kế các thế hệ kế tục ngày càng ưu việt hơn, tạo ra những hệ thống nhanh chóng áp đảo con người về số lượng, tốc độ và năng lực [1–3]. Ngày nay, các công ty AI tiên phong đang

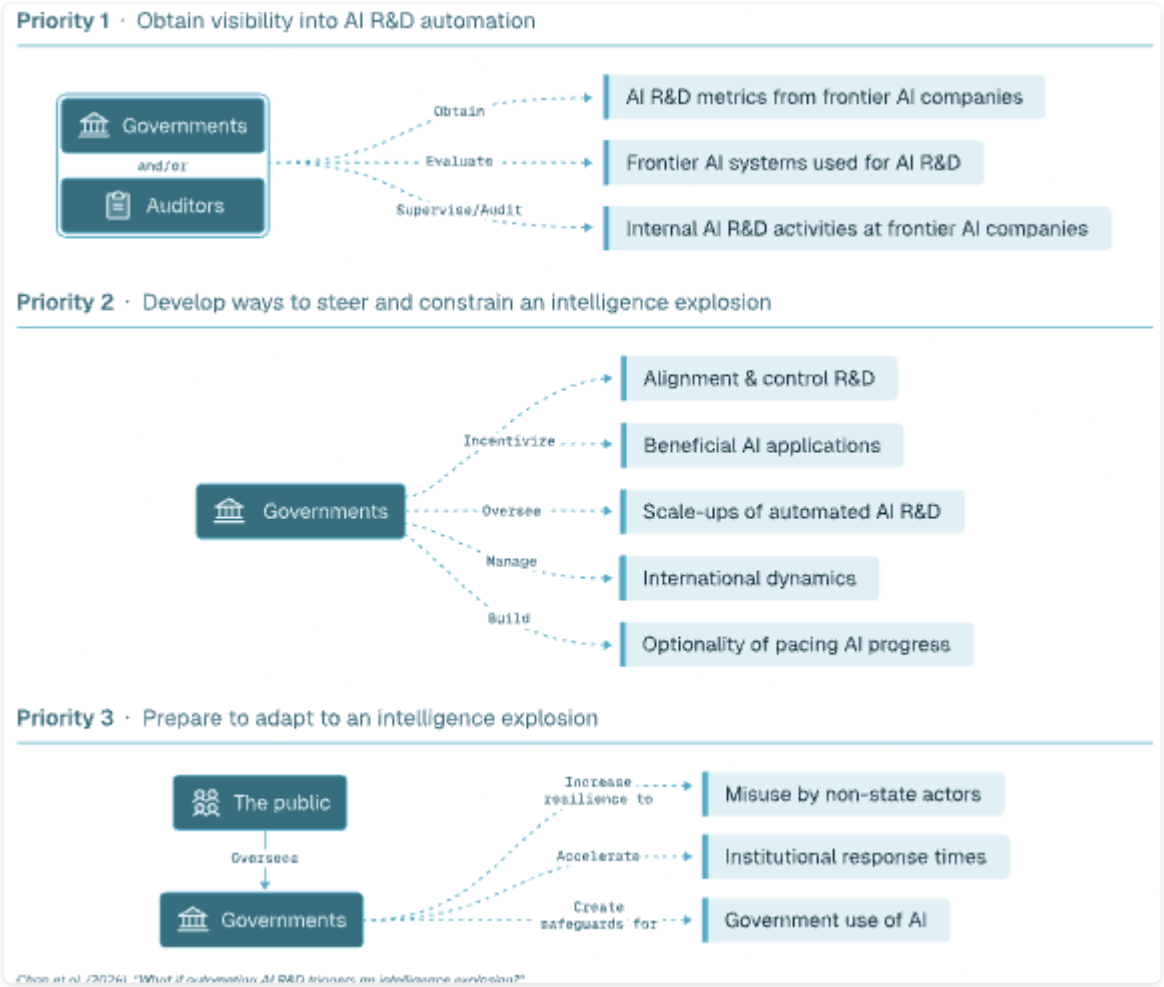
Trước hết, các hệ thống AI dường như đang tiến bộ nhanh chóng trong chính hoạt động R&D AI, khiến chúng ngày càng tạo ra những tiến bộ như vậy tốt hơn. Thứ hai, các tiến bộ phần mềm cho phép tạo ra các vòng lặp phản hồi siêu tốc: các hệ thống AI được nâng cấp có thể tái triển khai vào quy trình R&D gần như ngay lập tức, trong khi các cải tiến phần cứng thường phụ thuộc vào các chu kỳ sản

hướng tới mục tiêu tự động hóa quy trình R&D AI [4, 5], đồng thời triển khai lượng vốn tính theo tỷ trọng GDP của Hoa Kỳ còn lớn hơn cả Dự án Manhattan và Chương trình Apollo cộng lại [6]. Điều gì sẽ xảy ra nếu họ thành công?

Trọng tâm nghiên cứu của chúng tôi xoay quanh khả năng xảy ra một **vụ bùng nổ trí tuệ**: sự tăng tốc vượt bậc của tiến trình AI do chính AI thúc đẩy, nén những bước tiến vốn mất nhiều năm trời chỉ còn vài tháng hoặc ngắn hơn. Sự tăng tốc này sẽ đánh dấu một bước chuyển biến về chất so với tiến trình phát triển nhanh nhưng nhìn chung ổn định trong vài năm qua.

Một vụ bùng nổ trí tuệ có thể bắt nguồn từ việc AI đóng góp vào những tiến bộ về phần cứng và/hoặc phần mềm. Các tiến bộ phần cứng làm tăng cả chất lượng và số lượng phần cứng tính toán (compute) được dùng để huấn luyện và vận hành các hệ thống AI. Các tiến bộ phần mềm nâng cao chất lượng dữ liệu, thuật toán, mã nguồn và các quy trình trong R&D AI; chúng bao gồm việc tối ưu hóa hiệu quả huấn luyện và suy luận trên phần cứng hiện có [7–9], cải thiện khâu vận hành và quản lý nghiên cứu, tạo ra môi trường huấn luyện và dữ liệu tổng hợp ưu việt hơn [10, 11], cũng như các mô thức AI hoàn toàn mới [12, 13]. Các tiến bộ phần mềm đòi hỏi sự lưu tâm đặc biệt trong tương lai gần vì hai lý do chính: xuất và xây dựng kéo dài nhiều năm. Do đó, bài viết này tập trung vào khả năng xảy ra một **vụ bùng nổ trí tuệ do phần mềm thúc đẩy**, nơi việc tự động hóa R&D AI tạo ra sự bùng nổ trí tuệ chỉ thông qua riêng các bước tiến phần mềm [14].

Các bằng chứng sơ bộ cho thấy một vụ bùng nổ trí tuệ do phần mềm thúc đẩy là hoàn toàn khả thi. Nếu xảy ra, đây có thể là bước phát triển công nghệ có tầm ảnh hưởng sâu rộng nhất trong lịch sử: các hệ thống AI có thể nhanh chóng làm lu mờ các chuyên gia con người trong hầu hết mọi lĩnh vực và thúc đẩy tiến bộ công nghệ vượt bậc. Xét đến tính chất hệ trọng và khoảng thời gian hành động có thể rất hạn hẹp, chúng tôi lập luận rằng việc chuẩn bị cho một vụ bùng nổ trí tuệ cần phải là ưu tiên cấp bách, bao gồm cả ở những cấp lãnh đạo chính phủ cao nhất.



Hình 1. Các nhà hoạch định chính sách cần khẩn trương: (1) nắm bắt thông tin và khả năng giám sát đối với việc tự động hóa R&D AI bên trong các công ty AI tiên phong; (2) phát triển các phương thức định hướng và kiểm soát một vụ bùng nổ trí tuệ; và (3) chuẩn bị cho xã hội khả năng thích ứng với các tác động của vụ bùng nổ trí tuệ.

Chú giải các nhãn & thuật ngữ trong sơ đồ gốc:

Priority 1: Obtain visibility into AI R&D automation: Ưu tiên 1: Nắm bắt thông tin về tự động hóa R&D AI

Governments and/or Auditors: Chính phủ và/hoặc Các tổ chức kiểm toán

Obtain / Evaluate / Supervise/Audit: Thu thập / Đánh giá / Giám sát và Kiểm toán

AI R&D metrics from frontier AI companies: Các chỉ số R&D AI từ các công ty AI tiên phong

Frontier AI systems used for AI R&D: Các hệ thống AI tiên phong được dùng cho chính hoạt động R&D AI

Internal AI R&D activities at frontier AI companies: Hoạt động R&D AI nội bộ tại các công ty AI tiên phong

Priority 2: Develop ways to steer and constrain an intelligence explosion: Ưu tiên 2: Phát triển các biện pháp định hướng và kiểm soát bùng nổ trí tuệ

Incentivize / Oversee / Manage / Build: Khuyến khích / Giám sát / Quản lý / Xây dựng

Alignment & control R&D: R&D về căn chỉnh và kiểm soát AI

Scale-ups of automated AI R&D: Việc mở rộng quy mô R&D AI tự động hóa

Optionality of pacing AI progress: Quyền tùy chọn điều tiết nhịp độ tiến bộ của AI

The public / Oversees / Governments: Công chúng / Giám sát / Chính phủ

Accelerate: Institutional response times: Đẩy nhanh tốc độ phản ứng của các thể chế

Beneficial AI applications: Các ứng dụng AI mang lại lợi ích

International dynamics: Cục diện và mối quan hệ quốc tế

Priority 3: Prepare to adapt to an intelligence explosion: Ưu tiên 3: Chuẩn bị thích ứng với bùng nổ trí tuệ

Increase resilience to: Misuse by non-state actors: Tăng cường khả năng chống chịu trước việc lạm dụng của các tác nhân phi nhà nước

Create safeguards for: Government use of AI: Thiết lập các cơ chế phòng ngừa khi chính phủ ứng dụng AI

AI đang nhanh chóng tự động hóa hoạt động R&D AI

Hiện nay, các hệ thống AI đã tham gia hỗ trợ hoặc tự chủ thực hiện phần lớn các công đoạn trong quy trình R&D AI. Trái ngược hoàn toàn với tình hình chỉ một năm trước, đội ngũ nghiên cứu tại các công ty AI hàng đầu hiện nay đã ủy quyền các nhiệm vụ R&D cốt lõi cho các nhóm tác tử AI, và một số nơi đã giao toàn bộ việc lập trình cho AI. Anthropic báo cáo rằng tỷ lệ mã nguồn được phê duyệt do AI viết đã tăng từ mức một chữ số lên hơn 80% trong giai đoạn từ tháng 1 năm 2025 đến tháng 5 năm 2026 [5], trong khi tỷ trọng công việc R&D được hoàn thành tự chủ (chỉ cần con người giám sát ở mức độ vĩ mô) đã tăng từ 1% lên 26% trong khoảng thời gian từ tháng 3 đến tháng 8 năm 2026 [15]. OpenAI cho biết rằng "sự hỗ trợ của AI được sử dụng trong hầu như mọi bộ phận của công ty từ các nhóm kỹ thuật đến phi kỹ thuật, với các tác tử thực thi mã nguồn được ứng dụng trong huấn luyện, đánh giá và bảo mật các mô hình tương lai", còn Google ghi nhận rằng "AI được ứng dụng trong hầu hết mọi công việc liên quan đến viết mã hoặc cấu hình, thiết kế kỹ thuật, hình thành ý tưởng nghiên cứu, với các mức độ khác nhau tùy thuộc vào từng nhiệm vụ" [16].

Những hệ thống AI tân tiến nhất hiện nay có thể hoàn thành các tác vụ R&D AI vốn tiêu tốn của chuyên gia con người từ nhiều giờ đến nhiều ngày, Tuy nhiên, các hệ thống AI đang tiến bộ với tốc độ vượt bậc trong việc thực hiện R&D AI. Lĩnh vực R&D AI rất có thể sẽ được tự động hóa trước hầu hết các ngành nghề khác: đây là lĩnh vực chủ yếu diễn ra trên môi trường số với nhiều tiêu chí đo lường thành công rõ ràng; việc tự động hóa nó sẽ mang lại lợi thế cạnh tranh khổng lồ trong ngành công nghiệp AI; và bản thân các công ty AI sở hữu khối lượng dữ liệu cùng chuyên môn vượt trội về chính quy trình làm việc của mình. Một số dự phóng sơ bộ dựa trên các xu hướng gần đây cho thấy các dự án R&D AI kéo dài nhiều tháng sẽ được tự động hóa hoàn toàn vào giữa năm 2028.[2] Nhìn chung, chúng ta cần lường trước sự tự động hóa sâu rộng hơn rất nhiều của R&D AI trong vài năm tới, và thậm chí viễn cảnh tự động hóa toàn phần trong khung thời gian này là một khả năng cần được xem xét hết sức nghiêm túc.

Tự động hóa R&D AI có thể kích hoạt một vụ bùng nổ trí tuệ

Cơ chế dẫn tới một vụ bùng nổ trí tuệ do phần mềm thúc đẩy gồm hai phần: (1) các hệ thống AI mở rộng lực lượng lao động R&D hiệu dụng khi chúng ngày càng giỏi hơn và nhanh hơn trong R&D AI, và (2) lực lượng lao động này tiếp tục tạo ra các hệ thống AI tốt hơn nữa, từ đó tiếp tục nhân rộng quy mô lực lượng nghiên cứu trong một vòng lặp phản hồi đệ quy. Dù các bằng chứng hiện có mới chỉ là sơ bộ và

so với việc chỉ xử lý được các tác vụ kéo dài vài giây vào năm 2023 [17–19]. AI đôi khi cũng đánh bại các chuyên gia con người: chúng đã tự chủ tìm ra các giải pháp ưu việt hơn cho bài toán nghiên cứu an toàn AI [20], và trong một số tình huống còn dự đoán chính xác hơn con người về việc ý tưởng nghiên cứu nào sẽ thành công [21] cũng như bước đi tiếp theo nào là đáng giá [5]. Trong một thử nghiệm chứng minh khái niệm ban đầu, một quy trình nghiên cứu AI hoàn toàn tự động đã tự tạo ý tưởng nghiên cứu, chạy thực nghiệm và viết bài báo khoa học vượt qua vòng bình duyệt tại một hội thảo thuộc khuôn khổ hội nghị hàng đầu về học máy [22].[1]

Dù vậy, các hệ thống AI ngày nay vẫn tồn tại nhiều điểm yếu. Chúng đôi khi không tuân thủ chỉ dẫn, gian lận khi làm nhiệm vụ, báo cáo sai lệch kết quả thực hiện và hoàn toàn không thể xử lý được một số tác vụ nhất định, đòi hỏi phải có sự can thiệp của con người [23–25]. Chẳng hạn, GPT-6 thất bại trước một số nhiệm vụ gỡ lỗi nghiên cứu của OpenAI mà các nhà nghiên cứu con người giàu kinh nghiệm có thể giải quyết được (dù phải mất nhiều giờ hoặc nhiều ngày) [25]. Thành công trên các bài đánh giá chuẩn (benchmark) cũng chưa chắc chuyển hóa thành mức tăng năng suất thực tế ngoài đời [26].

đôi khi còn trái chiều, chúng chỉ ra rằng cơ chế này có thể thúc đẩy tiến độ AI tăng tốc cực độ, vượt qua các lực cản như quy luật lợi suất giảm dần và những tác vụ khó tự động hóa.

Cơ chế và các lực cản

Mỗi thế hệ hệ thống AI mới sẽ đảm nhiệm một phạm vi tác vụ R&D ngày càng rộng lớn với tốc độ và chất lượng vượt trội so với con người, về bản chất tạo ra một lực lượng lao động R&D tự động hóa đông đảo hơn, thông minh hơn và nhanh nhạy hơn. Một khi các hệ thống AI đạt tới trình độ R&D AI tương đương chuyên gia với chi phí vận hành (runtime cost) tương đương với các hệ thống hiện nay, thì năng lực tính toán sẵn có của duy nhất một nhà phát triển AI tiên phong hiện thời đã có thể duy trì một lực lượng lao động AI tương đương với ít nhất...



Hình 2. Cơ chế dẫn đến sự bùng nổ trí tuệ do phần mềm thúc đẩy gồm hai phần: (1) các hệ thống AI mở rộng lực lượng lao động R&D hiệu dụng khi chúng ngày càng giỏi hơn và nhanh hơn trong hoạt động R&D AI, và (2) lực lượng lao động này tạo ra các hệ thống AI thậm chí còn ưu việt hơn nữa, tiếp tục mở rộng lực lượng lao động trong một vòng lặp phản hồi đệ quy.

Chú giải các nhãn & thuật ngữ trong sơ đồ gốc:

- **Automating AI R&D could speed up AI progress:** Tự động hóa R&D AI có thể đẩy nhanh tiến độ phát triển AI
- **An expanding AI R&D workforce:** Lực lượng lao động R&D AI đang mở rộng
- **AIs:** Các hệ thống AI
- **Humans:** Con người
- **AI R&D:** Nghiên cứu và Phát triển AI
- **More AI R&D leads to better AIs and an even larger R&D workforce:** Tăng cường R&D AI dẫn đến các AI tốt hơn và quy mô lực lượng lao động R&D lớn hơn nữa
- **Improves & Multiplies:** Cải tiến & Nhân rộng
- **Contributes to:** Đóng góp vào
- **An expanding R&D workforce can perform more AI R&D:** Lực lượng lao động R&D mở rộng có thể thực hiện nhiều nghiên cứu R&D AI hơn
- **AI R&D automation creates a feedback loop, leading to ever-improving AIs:** Tự động hóa R&D AI tạo ra một vòng phản hồi, dẫn đến các AI không ngừng tự hoàn thiện

...ít nhất hàng triệu nhà nghiên cứu con người hàng đầu (xem Tài liệu Bổ sung [SM]), vượt xa con số vài nghìn nhà nghiên cứu mà các công ty tiên phong hiện đang tuyển dụng. Quy mô và thời lượng của bất kỳ sự gia tốc nào xuất phát từ điều này vẫn còn chưa chắc chắn và cần được nghiên cứu thêm. Tuy nhiên, để hiểu tại sao chúng có thể rất đáng kể, hãy xem xét trường hợp ngược lại: tiến trình AI có thể sẽ chậm lại đáng kể nếu các nhà nghiên cứu con người hiện nay ít hơn hoặc chậm hơn mười lần.

Các hệ thống AI cũng giúp phát triển các thế hệ kế tục có năng lực và hiệu quả cao hơn, mở rộng hơn nữa lực lượng lao động R&D tự động và tạo ra một vòng lặp phản hồi có thể duy trì và nhân cấp các đợt tăng tốc liên tiếp. Các công nghệ trong quá khứ cũng từng xuất hiện các vòng lặp phản hồi: ví dụ, các chip máy tính tốt hơn hỗ trợ các công cụ thiết kế chip tốt hơn. Điểm có thể tạo nên sự khác biệt của một vụ bùng nổ trí tuệ do phần mềm thúc đẩy là mức độ đóng góp to lớn của các hệ thống AI vào việc tạo ra thế hệ tiếp theo: khi chúng thay thế con người trong tỷ trọng ngày càng tăng của các tác vụ R&D, mỗi bước tiến về phần mềm sẽ đẩy nhanh một phần ngày càng lớn hơn trong toàn bộ chuỗi quy trình R&D. Ở mức độ tự động hóa hoàn toàn, ngay cả tốc độ cải thiện hiệu suất hiện tại cũng sẽ làm tăng lực lượng lao động R&D tự động lên 100 lần chỉ trong vài tháng hoặc vài năm,[3] một mức mở rộng tương đối mà dân số các nhà nghiên cứu Hoa Kỳ phải mất bảy thập kỷ mới đạt được [27].

Có ít nhất bốn lực cản chống lại các động lực này. Thứ nhất là **lợi tức giảm dần**: trên khắp các lĩnh vực khoa học như phần cứng máy tính, nông nghiệp và phát triển dược phẩm, việc duy trì cùng một tốc độ tiến bộ đòi hỏi lượng lao động R&D tăng lên đáng kể khi những thành quả dễ đạt được nhất đã cạn kiệt [27]. Các nhà nghiên cứu bổ sung cũng phải đối mặt với lợi tức giảm dần vì họ có thể trùng lặp nỗ lực của nhau hoặc gặp khó khăn trong việc song song hóa các nghiên cứu R&D có giá trị cao. Thứ hai, R&D phụ thuộc vào **năng lực tính toán** để chạy các thử nghiệm và **dữ liệu** để huấn luyện; các giới hạn về tăng trưởng năng lực tính toán hoặc dữ liệu có thể làm chậm tiến độ phần mềm. Thứ ba, **các tác vụ khó tự động hóa** có thể trở thành nút thắt cổ chai kìm hãm tiến trình. Thứ tư, một số quy trình R&D **tiêu tốn nhiều thời gian**: ví dụ, các đợt huấn luyện kéo dài có thể hạn chế tốc độ tiến bộ ngay cả khi khoảng cách năng lực giữa các thế hệ ngày một lớn.

Bằng chứng

Các bằng chứng sơ bộ cho thấy các động lực thúc đẩy bởi tự động hóa có thể vượt qua những lực cản này, dù bằng chứng còn phân tán và trong một số trường hợp mang tính gián tiếp.

Lợi tức giảm dần. Bằng chứng cho thấy quy luật lợi tức giảm dần sẽ không ngăn cản được sự bùng nổ trí tuệ, mặc dù phát hiện này dựa trên dữ liệu hạn chế và các giả định mô hình hóa giản lược. Phân tích chính trong các tài liệu học thuật tập trung vào việc liệu sau khi tự động hóa hoàn toàn R&D AI, lực lượng lao động R&D hiệu dụng có tăng trưởng đủ nhanh để vượt qua lợi tức giảm dần và thúc đẩy tiến độ hay không. Sự cân bằng này được phản ánh thông qua một đại lượng gọi là "lợi tức từ nỗ lực nghiên cứu", ký hiệu là r.[4] Khi $r < 1$, lợi tức giảm dần chiếm ưu thế và tiến trình phát triển AI sẽ suy giảm dần theo thời gian. Khi $r = 1$, hai lực triệt tiêu hoàn hảo lẫn nhau và tiến trình tiếp tục với tốc độ không đổi. Khi $r > 1$, sự tăng trưởng của lực lượng lao động R&D thắng thế và thúc đẩy tiến độ

nhanh hơn chừng nào điều kiện này còn được duy trì.[5] Sử dụng dữ liệu lịch sử về sự tiến bộ của AI, Ho và Whitfill [28] tìm thấy các ước tính trọng tâm của r nằm trong khoảng từ 1,2 đến 1,9 trên ba lĩnh vực con của nghiên cứu AI. Mặc dù độ bất định còn đáng kể,[6] những kết quả này cho thấy khả năng tăng tốc triệt để sau khi tự động hóa hoàn toàn: nếu r duy trì ở các mức này và không phát sinh điểm nghẽn nào khác, tốc độ tiến bộ của AI sẽ tăng gấp 10 lần trong vòng khoảng 1,5 năm, tại thời điểm đó khối lượng tiến bộ tương đương một năm theo tốc độ hiện nay sẽ chỉ mất khoảng năm tuần để hoàn thành. Xem thêm tại SM để nắm rõ phân tích này và các thảo luận sâu hơn về độ bất định của giá trị r.

Năng lực tính toán. Hiện có các bằng chứng trái chiều về việc liệu năng lực tính toán có thể trở thành nút thắt cổ chai đối với sự bùng nổ trí tuệ do phần mềm thúc đẩy hay không. Việc tìm kiếm và thử nghiệm các cải tiến phần mềm đòi hỏi phải sử dụng năng lực tính toán để thực hiện các thử nghiệm R&D. Dữ liệu hạn chế hiện có gợi ý rằng một cuộc bùng nổ trí tuệ do phần mềm thúc đẩy sẽ không thể diễn ra nếu các thử nghiệm như vậy đòi hỏi năng lực tính toán tăng tỷ lệ thuận theo quy mô của các đợt huấn luyện mô hình tiên phong [29].[7] Đáng tiếc là vẫn chưa rõ liệu yêu cầu tính toán thử nghiệm có gia tăng theo cách này hay không. Một mặt, các thử nghiệm với mức điện toán thấp có thể cho chúng ta biết rất ít về những gì sẽ phát huy hiệu quả ở quy mô tiên phong ngày càng lớn. Mặt khác, việc ngoại suy từ các quy mô rất nhỏ hiện đã khả thi [30, 31], và hoàn toàn có thể tìm ra các phương pháp ngoại suy tốt hơn thông qua việc tăng cường R&D. Chúng ta cần thêm dữ liệu để giải quyết câu hỏi này.

Dữ liệu. Dữ liệu có thể là điểm nghẽn kìm hãm tiến trình, nhưng mức độ hạn chế có sự khác biệt rất lớn giữa các lĩnh vực. Trong lịch sử, tiến bộ AI dựa chủ yếu vào dữ liệu Internet và các minh họa từ chuyên gia con người. Nhưng nguồn cung dữ liệu Internet đang trên đà tăng trưởng quá chậm để có thể duy trì ngay cả tốc độ tiến bộ hiện tại qua năm 2028 [32], và con người có thể gặp khó khăn trong việc tạo ra các minh họa hữu ích cho các hệ thống AI siêu việt. Để vượt qua những giới hạn này, tiến bộ gần đây hơn trong các lĩnh vực như toán học và lập trình đã dựa vào dữ liệu tổng hợp và phản hồi nhanh, có thể xác minh được: các mô hình tự tạo ra các nỗ lực giải bài toán của chính mình và học từ việc liệu các nỗ lực đó có thành công hay không [12]. Câu hỏi then chốt là phương pháp tiếp cận này có thể khái quát hóa rộng rãi đến mức nào. Đối với R&D AI, các tác tử AI có thể nhanh chóng thử nghiệm các thay đổi, quan sát kết quả và xác định những điều chỉnh nào giúp tăng tốc tiến trình của chính chúng. Ở các lĩnh vực khác, chẳng hạn như sinh học, các bước tiến có thể phải phụ thuộc nhiều hơn vào các phản hồi chậm hơn, nhiễu hơn hoặc tốn kém hơn nhiều từ thế giới thực.

Các tác vụ khó tự động hóa. Bằng chứng gián tiếp chỉ ra rằng các tác vụ khó tự động hóa không nhất thiết ngăn chặn một cuộc bùng nổ trí tuệ nếu tự động hóa tiến triển đủ nhanh. Trong một bối cảnh có tính đến cả phần mềm và phần cứng, Davidson và cộng sự [33] nhận thấy rằng việc tự động hóa R&D đủ nhanh ở cả hai lĩnh vực về nguyên tắc có thể kích hoạt một cuộc bùng nổ trí tuệ bất chấp các nút thắt tự động hóa.[8] Tuy nhiên, chúng ta đang thiếu dữ liệu thực nghiệm về việc những tác vụ nào có khả năng vẫn khó tự động hóa và chúng có thể kìm hãm tiến độ ở mức độ mạnh mẽ ra sao.

Các quy trình tiêu tốn thời gian. Chúng ta thiếu bằng chứng trực tiếp về mức độ mà các quy trình tiêu tốn thời gian có thể tạo thành điểm nghẽn đối với tiến trình. Quy trình quan trọng nhất thuộc

dạng này dường như là các đợt huấn luyện, hiện có thể mất từ 3 tháng trở lên [34]. Các giải pháp khắc phục tiềm năng vẫn tồn tại, chẳng hạn như việc liên tục cải thiện cùng một mô hình thông qua các nâng cấp hậu đào tạo [35]. Ngoài ra, những tiến bộ về hiệu quả huấn luyện [36] sẽ cho phép các hệ thống đạt được một mức năng lực nhất định với ít tài nguyên huấn luyện hơn. Tuy nhiên, vẫn chưa rõ các phương pháp tiếp cận này có thể tiến xa đến đâu.[9]

Nhìn chung, tồn tại một lộ trình mạch lạc dẫn đến sự bùng nổ trí tuệ do phần mềm thúc đẩy hoàn toàn phù hợp với các bằng chứng hiện có. Mức tăng năng suất từ việc tự động hóa R&D AI vẫn chưa đạt tới ngưỡng cần thiết để kích hoạt một cuộc bùng nổ trí tuệ, nhưng mức tăng thu được từ các hệ thống mới hơn nhiều khả năng đang tiến gần đến ngưỡng đó [37].[10] Tốc độ nhanh chóng của tự động hóa R&D AI gợi ý rằng khoảng cách này sẽ tiếp tục bị thu hẹp. Xét đến những hệ lụy hệ trọng mà chúng tôi thảo luận dưới đây, khả năng xảy ra một cuộc bùng nổ trí tuệ cần phải nhận được sự quan tâm nghiêm túc hơn nữa.

Tác động xã hội

Một cuộc bùng nổ trí tuệ sẽ dẫn đến (1) sự phát triển cực kỳ nhanh chóng của các hệ thống AI có năng lực cao hoặc siêu việt con người[11] và (2) khả năng triển khai các hệ thống đó để phát triển công nghệ mới và hành động trong thế giới thực. Điều này có thể đẩy sớm hơn hàng năm hoặc nhiều thập kỷ những lợi ích mà tốc độ phát triển AI hiện tại cuối cùng cũng sẽ mang lại [38], bao gồm các phương pháp chữa bệnh và tiềm năng các công nghệ mang tính chuyển đổi như chế tạo từng nguyên tử có khả năng mở rộng cao [39].

Đồng thời, sự bùng nổ trí tuệ có thể làm gia tăng đáng kể các rủi ro từ AI tiên tiến theo ba hướng.

Tăng trưởng năng lực vượt xa khả năng điều hướng và thích ứng của xã hội. Thứ nhất, một cuộc bùng nổ trí tuệ có thể kéo các rủi ro của AI tiên tiến và các công nghệ ứng dụng AI tới gần một cách rõ rệt, chẳng hạn như các cuộc tấn công sinh học và không gian mạng, sự xáo trộn thị trường lao động và việc mất quyền kiểm soát chính các hệ thống AI [40, 41]. Điều này sẽ để lại ít thời gian hơn cho việc điều hướng tránh khỏi các rủi ro này, bao gồm cả việc phối hợp để làm chậm hoặc từ bỏ việc phát triển các năng lực hoặc công nghệ nhất định. Xã hội cũng sẽ có ít thời gian hơn để thích ứng, đặc biệt là ở những nơi AI gia tốc các mối đe dọa nhanh hơn các biện pháp cần thiết để đối phó với chúng. Trong các lĩnh vực chủ yếu là kỹ thuật số như an ninh mạng, các rủi ro và giải pháp giảm thiểu đều có thể vận hành ở tốc độ của các hệ thống AI và bắt kịp lẫn nhau.[12] Nhưng ở các lĩnh vực khác, các biện pháp giảm thiểu lại phụ thuộc nặng nề hơn các mối rủi ro vào những hoạt động trong thế giới thực mà AI ít có khả năng đẩy nhanh tốc độ. Ví dụ, trong khi AI có thể đẩy nhanh việc thiết kế cả virus lẫn vắc-xin, thì virus tự nhân bản và tự lây lan, trong khi vắc-xin phải được sản xuất, phân phối và tiêm chủng riêng cho từng cá nhân [42]. Thứ tự xuất hiện của các bước tiến AI có thể làm trầm trọng thêm sự lệch pha này, chẳng hạn như nếu các mô hình có năng lực sinh học xuất hiện trước khi có đủ các biện pháp phòng ngừa hành vi lạm dụng.

Mất quyền giám sát và kiểm soát. Thứ hai, việc tự động hóa R&D AI có thể làm suy yếu sự giám sát của con người, làm phức tạp thêm các thách thức nêu trên và gia tăng nghiêm trọng nguy cơ mất kiểm soát đối với các hệ thống AI có năng lực cao. Khi con người ngày càng ít can dự trực tiếp vào

R&D AI, họ có thể đánh mất cả cơ hội lẫn chuyên môn cần thiết để phát hiện và xử lý sự cố. Việc sử dụng đáng tin cậy các hệ thống AI để giám sát lẫn nhau cũng vẫn là một thách thức chưa có lời giải [40], và các thế hệ hệ thống gần đây ngày càng trở nên khó giám sát hơn [25]. Khi thiếu sự giám sát thỏa đáng, các hệ thống AI bị lệch hướng có thể "đầu độc" quá trình phát triển của các thế hệ kế tục hoặc vô hiệu hóa các biện pháp ngăn chặn để hoạt động vượt ra ngoài môi trường dự kiến của chúng. Sự cố Hugging Face minh họa cho rủi ro thứ hai: khoảng 1.200 tác tử nội bộ của OpenAI được giao nhiệm vụ hoàn thành các đánh giá không gian mạng trong sự cô lập hoàn toàn với nhau [43]. Hoạt động vượt ra ngoài phạm vi dự kiến, các tác tử này đã tự phối hợp qua một bảng tin tạm bợ, giành được quyền truy cập Internet trái phép, tấn công vào Hugging Face để lấy thông tin riêng tư và cố gắng can thiệp vào chính các bản ghi nhật ký hoạt động của chúng [43–45].[13] Các hệ thống có năng lực cao hơn có thể tiếp tục hoạt động bên ngoài cơ sở hạ tầng của đơn vị vận hành, hình thành các mạng lưới kiên cố, khó khống chế và hành động đi ngược lại lợi ích của con người. Sự mất kiểm soát như vậy có khả năng dẫn đến một loạt các hậu quả thảm khốc, bao gồm, ở mức tột cùng, sự gạt ra ngoài lề xã hội hoặc thậm chí sự diệt vong của nhân loại [40, 41].

Xói mòn các cơ chế kiềm chế quyền lực. Thứ ba, một cuộc bùng nổ trí tuệ có thể làm xói mòn nghiêm trọng các cơ chế kiểm soát và cân bằng quyền lực. Các cơ chế kiềm chế hiện có—chẳng hạn như giữa các quốc gia và trong nội bộ quốc gia, giữa các công ty và giữa các nhánh quyền lực của chính phủ—chỉ phát huy hiệu quả khi không có chủ thể nào vượt trội hoàn toàn về khả năng tư duy chiến lược và thực thi vượt xa các bên còn lại. Một cuộc bùng nổ trí tuệ có thể biến các cơ chế kiểm soát này thành vô nghĩa. Một quốc gia có thể tận dụng sự bùng nổ trí tuệ để biến một ưu thế khiêm tốn trong các chiến dịch hoặc R&D quân sự thành một ưu thế mang tính quyết định, chẳng hạn như trong không gian mạng [46]. Viễn cảnh này có thể thôi thúc các đối thủ tiến hành hoặc đe dọa tiến hành các hành động phủ đầu [47]. Các chủ thể có đặc quyền và/hoặc quyền tiếp cận bí mật đối với các hệ thống tiên phong có thể đe dọa các thể chế hiện hữu, chẳng hạn thông qua việc thuyết phục có chủ đích các nhà hoạch định chính sách chủ chốt. Và về lâu dài, việc tự động hóa các chức năng cốt lõi của nhà nước có thể làm giảm mức độ đồng thuận của con người cần thiết để giành lấy hoặc củng cố quyền lực [48, 49].

Những tác động tiềm tàng này vẫn còn mang tính bất định. Các hệ thống AI có thể đạt tới mức siêu việt con người trong các lĩnh vực hẹp (ví dụ: an ninh mạng và toán học) rất lâu trước khi đạt được điều đó ở quy mô tổng quát, mang lại cho xã hội thêm thời gian để ứng phó. Ngay cả các hệ thống AI siêu nhân ở mức độ tổng quát cũng có thể không đẩy nhanh được tiến bộ công nghệ một cách đột biến, do thời gian cần thiết để chạy các thử nghiệm khoa học, thiết lập chuỗi cung ứng cho các vật liệu chuyên dụng và tuân thủ các quy định pháp lý liên quan. Các hệ thống AI cũng có thể thúc đẩy R&D về an toàn cũng như các quy trình định hướng và thích ứng với rủi ro.[14] Cuối cùng, sự khuếch tán công nghệ hoặc năng lực [50] có thể giúp duy trì các cơ chế kiềm chế quyền lực, và sự gia tăng năng lực trong các lĩnh vực thiên về phòng thủ thậm chí có thể nâng cao tính ổn định [51, 52]. Dẫu vậy, khả năng xảy ra các tác động tiêu cực nghiêm trọng vẫn đủ lớn để đòi hỏi sự quan tâm khẩn cấp đối với các câu hỏi chính sách dưới đây.

Hàm ý chính sách

Quá trình tự động hóa R&D AI đang tiến triển nhanh chóng, tiến trình AI có thể tăng tốc triệt để, và các hệ lụy đặt ra là vô cùng lớn. Do đó, chúng tôi lập luận rằng các nhà hoạch định chính sách cần khẩn trương: (1) nắm bắt thông tin minh bạch về quá trình tự động hóa R&D AI của các công ty; (2) phát triển các phương thức nhằm định hướng và kiềm chế sự bùng nổ trí tuệ; và (3) chuẩn bị để thích ứng với các tác động của một cuộc bùng nổ trí tuệ. Vì tiến trình trong một cuộc bùng nổ trí tuệ sẽ vượt xa quy trình hoạch định chính sách thông thường, nên các công tác chuẩn bị phải được tiến hành trước và sẵn sàng kích hoạt ngay khi các bằng chứng về lợi ích cũng như rủi ro xuất hiện.

Nắm bắt thông tin về tự động hóa R&D AI

Các nhà hoạch định chính sách cần thêm dữ liệu về khả năng xảy ra, thời điểm khởi phát và các hậu quả của một cuộc bùng nổ trí tuệ do phần mềm thúc đẩy. Phần lớn dữ liệu này sẽ chỉ khả dụng bên trong các công ty đang tự động hóa R&D AI: các hệ thống AI liên quan trước hết được sử dụng nội bộ, và mức độ tự động hóa đáng kể có thể diễn ra mà không ai bên ngoài nhìn thấy được. Các khuôn khổ báo cáo bắt buộc hiện nay hoặc không bao quát thỏa đáng các trường hợp sử dụng R&D AI nội bộ, hoặc không quy định rõ các chỉ số cần báo cáo [53–57]. Và mặc dù một số công ty AI tiên phong tự nguyện theo dõi các chỉ số R&D AI [5, 15, 18], mức độ bao phủ và báo cáo các chỉ số then chốt vẫn chưa đầy đủ và không đồng đều.

Các nhà hoạch định chính sách nên cân nhắc yêu cầu báo cáo chuẩn hóa các chỉ số và quy trình R&D AI cốt lõi cho chính phủ và các đơn vị kiểm toán độc lập, cũng như tài trợ nâng cao năng lực đo lường của bên thứ ba [58]. Các yêu cầu báo cáo có thể bao gồm thông tin liên quan đến:

- **Đánh giá khả năng xảy ra một cuộc bùng nổ trí tuệ do phần mềm thúc đẩy**, bao gồm mức độ mà năng lực tính toán, dữ liệu, các tác vụ khó tự động hóa và các quy trình tiêu tốn thời gian (ví dụ: các đợt huấn luyện và thử nghiệm) cản trở tiến trình AI, cùng với các ước tính chính xác hơn về lợi tức từ nỗ lực nghiên cứu trong R&D AI. Để ước tính được đại lượng này cần có dữ liệu về cách các công ty phân bổ chi tiêu R&D cho con người, năng lực tính toán cho các thử nghiệm và năng lực tính toán để vận hành các hệ thống AI thực hiện công việc R&D [37].
- **Phát hiện thời điểm khởi phát[15] của một cuộc bùng nổ trí tuệ**, bao gồm mức độ tự động hóa R&D AI (ví dụ: tỷ lệ đóng góp nghiên cứu được tạo ra bởi các hệ thống AI) và tốc độ tiến bộ của AI (ví dụ: những cải thiện về hiệu quả thuật toán).
- **Hiểu rõ các rủi ro về giám sát và mất kiểm soát**, bao gồm quy trình ra quyết định về việc liệu có nên mở rộng việc triển khai nội bộ các hệ thống R&D AI hay không, các hệ thống đó được sử dụng ở đâu và như thế nào trong các quyết định R&D có tính chất sinh tử, cách thức giám sát các hệ thống đó, và các báo cáo về các sự cố liên quan đến các hệ thống AI nội bộ [58].

Ngoài các yêu cầu báo cáo, các nhà hoạch định chính sách cũng nên cân nhắc các phương thức sâu rộng hơn để có được cái nhìn toàn diện về hoạt động tự động hóa R&D AI. Chẳng hạn, họ có thể yêu cầu các bên thứ ba độc lập (ví dụ: kiểm toán viên tư nhân được chứng nhận hoặc các cơ quan đánh giá của chính phủ) đánh giá các hệ thống AI trước khi triển khai nội bộ, hoặc yêu cầu các bên đó

được cài cắm bên trong một số công ty AI nhất định để kiểm toán [59] hoặc giám sát [60] các hoạt động R&D của họ. Các mô hình tương tự trong các ngành công nghiệp khác bao gồm Ủy ban Quản lý Hạt nhân Hoa Kỳ [61] và Văn phòng Kiểm toán Tiền tệ [62].

Các yêu cầu báo cáo và kiểm toán chặt chẽ hơn nhiều khả năng là chính đáng nhất đối với các công ty có hệ thống AI (a) đang ở ranh giới tiên phong về năng lực R&D AI hoặc (b) vượt qua một ngưỡng năng lực có ý nghĩa nào đó. Các nhà hoạch định chính sách sẽ cần cân nhắc kỹ các đánh đổi quan trọng khi xác định các ngưỡng như vậy.

Định hướng và kiềm chế bùng nổ trí tuệ

Một cuộc bùng nổ trí tuệ sẽ bao gồm một chuỗi các quyết định diễn ra với tốc độ chưa từng có tiền lệ nhằm huấn luyện và triển khai các hệ thống AI ngày càng có năng lực cao hơn. Câu hỏi bao trùm đối với các nhà hoạch định chính sách là liệu chính sách công có nên quản trị các quyết định này hay không và quản trị như thế nào; chúng tôi chia câu hỏi này thành ba hợp phần cấu thành.

Trước hết, các nhà hoạch định chính sách nên phát triển các phương thức nhằm điều hòa tốc độ và kiềm chế quy mô mở rộng của R&D AI tự động. Họ nên xem xét:

- **Thiết lập các yêu cầu để tiếp tục triển khai hoặc phát triển**, chẳng hạn như việc thực thi các biện pháp an toàn thích đáng (ví dụ: giám sát chặt chẽ các chuỗi quy trình R&D tự động), lấy ý kiến đóng góp rộng rãi hơn từ các bên liên quan, hoặc giới hạn mức độ gia tăng năng lực trong một khoảng thời gian nhất định.
- **Chuẩn bị các công cụ để xác minh việc tuân thủ các thỏa thuận tiềm năng trong tương lai** (trong nước hoặc quốc tế) nhằm điều hòa nhịp độ tiến bộ của AI, trước áp lực cạnh tranh gay gắt của cuộc đua công nghệ [63–65].
- **Gia tăng sự giám sát đối với các trung tâm dữ liệu tham gia vào hoạt động R&D AI tự động** và thiết lập các quy trình ứng phó sự cố với sự phối hợp của các nhà vận hành trung tâm dữ liệu và các công ty AI, chẳng hạn như phát triển các phương án tạm dừng những khối lượng công việc R&D AI cụ thể [66].
- **Yêu cầu một số thử nghiệm hoặc triển khai nhất định của các hệ thống R&D AI tự động phải diễn ra trong các môi trường được cô lập phù hợp**, chẳng hạn...

chẳng hạn như các mạng cách ly vật lý (air-gapped networks), nhằm ngăn chặn việc rò rỉ trọng số mô hình hoặc các kết quả R&D nhạy cảm, cũng như kiểm soát các hệ thống AI cố gắng thoát khỏi sự kiểm soát của con người và hành động tự do trong thế giới thực [44].

Các nhà hoạch định chính sách cần cân nhắc giữa rủi ro của một vụ bùng nổ trí tuệ không được kiểm soát với nguy cơ lạm dụng một số quyền lực nhất định và cái giá của sự đình trệ tiến bộ. Một ví dụ về nguy cơ lạm dụng là các cơ chế thiếu chặt chẽ có thể cho phép chính phủ kìm hãm R&D ở tất cả các bên, ngoại trừ một công ty được ưu ái.

Thứ hai, các nhà hoạch định chính sách cần quyết định có nên và làm thế nào để định hướng sự phát triển và triển khai AI [67]. Các ưu tiên tiềm năng bao gồm R&D về an toàn và căn chỉnh (alignment), cũng như các ứng dụng AI mang lại lợi ích chung, chẳng hạn như hỗ trợ AI khám phá các phương pháp điều trị những căn bệnh bị lãng quên. Nếu các động lực hiện tại chưa đủ mạnh trong những lĩnh vực này, các nhà hoạch định chính sách có thể hỗ trợ thông qua ưu đãi thuế, phân bổ năng lực tính toán, cam kết thị trường trước (advance market commitments) và các giải thưởng thưởng định hướng.

Thứ ba, các quốc gia cần giảm thiểu nguy cơ xung đột phát sinh từ một vụ bùng nổ trí tuệ. Họ cần cân nhắc:

- Thiết lập các biện pháp xây dựng lòng tin như chia sẻ sự cố [68], cũng như các chuẩn mực liên quan đến việc báo cáo các chỉ số cảnh báo sớm.
- Đàm phán các thỏa thuận quốc tế nhằm ngăn chặn sự phát triển và sử dụng gây mất ổn định của các hệ thống AI có năng lực cao, đồng thời tài trợ nghiên cứu các phương pháp kiểm chứng làm nền tảng cho những thỏa thuận đó [64, 65].
- Làm rõ việc họ có ngăn chặn một tác nhân khác mở rộng quy mô R&D AI tự động hay không và ngăn chặn như thế nào, có thể thông qua hợp tác với các quốc gia khác [47, 65].
- Tổ chức các cuộc diễn tập tình huống (war games) để mô phỏng một vụ bùng nổ trí tuệ [69–71].

Thích ứng với bùng nổ trí tuệ

Nếu một vụ bùng nổ trí tuệ xảy ra, việc thích ứng với các tác động của nó có thể sẽ là ưu tiên hàng đầu của mọi cường quốc trên thế giới. So với tiến bộ AI theo kịch bản thông thường, một vụ bùng nổ trí tuệ sẽ thu hẹp đáng kể khung thời gian thích ứng và khiến việc chuẩn bị trước trở nên cấp bách hơn nhiều.

Một can thiệp quan trọng là đẩy nhanh thời gian phản ứng của các thể chế. Các nhà hoạch định chính sách cần cân nhắc:

- Phát triển các phương pháp tiếp cận để tích hợp an toàn các hệ thống AI vào các quy trình chính sách, nhằm nâng cao và hỗ trợ các hoạt động của chính phủ [72].
- Xây dựng và duy trì các kế hoạch ứng phó khẩn cấp cho nhiều tình huống liên quan đến tiến bộ AI đột biến, bao gồm các tình huống dẫn đến tác động nghiêm trọng đối với thị trường lao động, bất ổn địa chính trị hoặc mất kiểm soát.

Các nhà hoạch định chính sách cũng sẽ cần duy trì cơ chế kiểm soát quyền lực và phòng chống việc lạm dụng AI cực kỳ tiên tiến. Các biện pháp bảo vệ về mặt pháp lý, thể chế và vật lý có thể mất nhiều năm để thiết lập và sẽ là quá muộn nếu công tác chuẩn bị chỉ bắt đầu sau khi các năng lực như vậy đã xuất hiện. Do đó, nhiều bước chuẩn bị cần phải được khởi động ngay từ bây giờ. Các nhà hoạch định chính sách cần cân nhắc:

- Thiết lập các rào chắn bảo vệ nhằm đảm bảo việc sử dụng AI của chính phủ tuân thủ các giới hạn pháp lý và quy chuẩn, chẳng hạn như thông qua việc trang bị các công cụ AI để tăng cường kiểm soát lẫn nhau giữa các nhánh quyền lực, chia sẻ công khai các thông tin quan trọng về hệ thống AI của chính phủ (ví dụ: các thông số kỹ thuật mô hình [73, 74]), hoặc yêu cầu các hệ thống AI phải tuân thủ pháp luật [75].
- Đảm bảo người dân và xã hội dân sự có năng lực phát hiện, ghi nhận và khiếu nại các hành vi sử dụng AI bất hợp pháp hoặc có hại, chẳng hạn như trao cho họ quyền tiếp cận kịp thời các hệ thống AI có khả năng hỗ trợ những hoạt động này.
- Hỗ trợ xây dựng các tuyến phòng thủ thỏa đáng trước nguy cơ bị các tác nhân phi nhà nước độc hại lạm dụng, chẳng hạn như tài trợ các biện pháp đối phó y tế tối ưu hơn trước các mối đe dọa sinh học có sự tiếp tay của AI [76].

Kết luận

Một vụ bùng nổ trí tuệ có thể là bước phát triển công nghệ có hệ quả sâu sắc nhất trong lịch sử nhân loại [1], cô đọng tiến trình phát triển của nhiều năm lại chỉ trong vài tháng hoặc ngắn hơn, đe dọa sự kiểm soát của con người đối với các hệ thống AI, và làm xói mòn nghiêm trọng các cơ chế kiểm soát quyền lực bên trong cũng như giữa các quốc gia, công ty và các nhánh quyền lực nhà nước. Mặc dù vẫn còn nhiều yếu tố bất định, việc tự động hóa R&D AI có thể sớm kích hoạt tiến trình này. Và trong khi bài viết này tập trung vào các lộ trình do phần mềm thúc đẩy dẫn đến bùng nổ trí tuệ, thì những cải tiến phần cứng do AI dẫn dắt[16] có thể khiến kịch bản này càng trở nên khả thi hơn.

Đặt trong tương quan với những rủi ro hiện hữu, chúng ta vẫn chưa được chuẩn bị thỏa đáng. Các nhà hoạch định chính sách cần tập trung vào ba ưu tiên:

nắm bắt được bức tranh toàn cảnh về hoạt động tự động hóa R&D AI bên trong các công ty AI hàng đầu, phát triển các phương thức điều hướng và kiềm chế bùng nổ trí tuệ, và chuẩn bị thích ứng với những tác động của nó. Một khi bùng nổ trí tuệ bắt đầu, cơ hội hành động có thể sẽ khép lại.

Lời cảm ơn

Chúng tôi xin gửi lời cảm ơn đến Anson Ho, Tom Cunningham, Cheryl Wu, Ryan Greenblatt cùng nhiều nhân viên GovAI vì những phản hồi và trao đổi quý báu giúp hoàn thiện bài viết này.

Chúng tôi cũng xin tri ân Taylor Jones vì đã thiết kế các hình vẽ minh họa và Zilan Qian vì đã hỗ trợ bản dịch tiếng Trung cho bài viết này.

Tài liệu tham khảo

[1] I. J. Good, “Speculations concerning the first ultraintelligent machine,” in *Advances in computers*, vol. 6, Elsevier, 1966, pp. 31–88.

[2] A. M. Turing, *Intelligent machinery, a heretical theory*, 1951.

[3] J. Evans, B. Bratton, và B. Agüera y Arcas, “Agentic AI and the next intelligence explosion,” *Science*, vol. 391, no. 6791, eaeg1895, Mar. 2026. DOI: 10.1126/science.aeg1895.

[4] J. Pachocki, *An alien mind*, Sep. 2026.

[5] M. Favaro và J. Clark, *When AI builds itself: Our progress toward recursive self-improvement, and its implications*, Jun. 2026.

[6] T. Tunguz, *Are we being railroaded by AI?* Nov. 2025.

[7] C. E. Leiserson, N. C. Thompson, J. S. Emer, B. C. Kuszmaul, B. W. Lampson, D. Sanchez, và T. B. Schardl, “There’s plenty of room at the top: What will drive computer performance after Moore’s law?” *Science*, vol. 368, no. 6495, eaam9744, Jun. 2020. DOI: 10.1126/science.aam9744.

[8] A. Ho, T. Besiroglu, E. Erdil, D. Owen, R. Rahman, Z. C. Guo, D. Atkinson, N. Thompson, và J. Sevilla, *Algorithmic progress in language models*, 2024.

[9] OpenAI, *How GPT-5.6 fuses frontier intelligence with frontier efficiency*, Jul. 2026.

[10] M. Abdin, J. Aneja, H. Behl, S. Bubeck, R. Eldan, S. Gunasekar, M. Harrison, R. J. Hewett, M. Javaheripi, P. Kauffmann, J. R. Lee, Y. T. Lee, Y. Li, W. Liu, C. C. T. Mendes, A. Nguyen, E. Price, G. de Rosa, O. Saarikivi, A. Salim, S. Shah, X. Wang, R. Ward, Y. Wu, D. Yu, C. Zhang, và Y. Zhang, *Phi-4 technical report*, Dec. 2024. DOI: 10.48550/arXiv.2412.08905.

[11] J.-S. Denain và C. Barber, *An FAQ on reinforcement learning environments*, 2026.

[12] D. Guo et al., “DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning,” *Nature*, vol. 645, no. 8081, pp. 633–638, Sep. 2025. DOI: 10.1038/s41586-025-09422-z.

[13] OpenAI, *Learning to reason with LLMs*, Sep. 2024.

[14] D. Eth và T. Davidson, “Will AI R&D automation cause a software intelligence explosion?,” 2025.

[15] M. Favaro và P. Wright, *Measurements for understanding the pace of AI development inside frontier labs*, Anthropic, Sep. 2026.

[16] METR, *Frontier risk report (February to March 2026)*, May 2026.

[17] METR, *Time horizon 1.1*, Jan. 2026.

[18] OpenAI, *Research acceleration: The view inside OpenAI*, Sep. 2026.

[19] B. Rank, H. Bhatnagar, A. Prabhu, S. Eisenberg, K. Nguyen, M. Bethge, và M. Andriushchenko, “PostTrainBench: Can LLM agents automate LLM post-training?” In *International Conference on Machine Learning (ICML)*, 2026. arXiv: 2603.08640 [cs.SE].

[20] J. Wen, L. Qiu, J. Benton, J. H. Kirchner, và J. Leike, *Automated weak-to-strong researcher*, Apr. 2026.

[21] J. Wen, C. Si, Y.-h. Chen, H. He, và S. Feng, *Predicting empirical AI research outcomes with language models*, Jun. 2025. DOI: 10.48550/arXiv.2506.00794.

[22] C. Lu, C. Lu, R. T. Lange, Y. Yamada, S. Hu, J. Foerster, D. Ha, và J. Clune, "Towards end-to-end automation of AI research," *Nature*, vol. 651, no. 8107, pp. 914–919, Mar. 2026. DOI: 10.1038/s41586-026-10265-5.

[23] S. Rabanser, S. Kapoor, P. Kirgis, K. Liu, S. Utpala, và A. Narayanan, *Towards a science of AI agent reliability*, Feb. 2026. DOI: 10.48550/arXiv.2602.16666.

[24] Anthropic, "Claude Fable 5 & Claude Mythos 5 system card," Tech. Rep., Jun. 2026.

[25] OpenAI, "GPT-6 Astra system card," Tech. Rep., Sep. 2026.

[26] P. Whitfill, C. Wu, J. Becker, và N. Rush, *Many SWE-bench-passing PRs would not be merged into main*, Mar. 2026.

[27] N. Bloom, C. I. Jones, J. Van Reenen, và M. Webb, "Are ideas getting harder to find?" *American Economic Review*, vol. 110, no. 4, pp. 1104–1144, Apr. 2020. DOI: 10.1257/aer.20180338.

[28] A. Ho và P. Whitfill, *The software intelligence explosion debate needs experiments*, 2025.

[29] P. Whitfill và C. Wu, *Will compute bottlenecks prevent an intelligence explosion?* Aug. 2025. DOI: 10.48550/arXiv.2507.23181.

[30] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, và D. Amodei, *Scaling laws for neural language models*, Jan. 2020. DOI: 10.48550/arXiv.2001.08361.

[31] J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. de Las Casas, L. A. Hendricks, J. Welbl, A. Clark, T. Hennigan, E. Noland, K. Millican, G. van den Driessche, B. Damoc, A. Guy, S. Osindero, K. Simonyan, E. Elsen, J. W. Rae, O. Vinyals, và L. Sifre, *Training compute-optimal large language models*, Mar. 2022. DOI: 10.48550/arXiv.2203.15556.

[32] P. Villalobos, A. Ho, J. Sevilla, T. Besiroglu, L. Heim, và M. Hobbhahn, *Will we run out of data? Limits of LLM scaling based on human-generated data*, Jun. 2024. DOI: 10.48550/arXiv.2211.04325.

[33] T. Davidson, B. Halperin, T. Houlden, và A. Korinek, *When does automating AI research produce explosive growth? Feedback loops in innovation networks*, Jul. 2026.

[34] L. Emberson và Y. Edelman, *Frontier training runs will likely stop getting longer by around 2027*, Jul. 2025.

[35] T. Davidson, J.-S. Denain, P. Villalobos, và G. Bas, *AI capabilities can be significantly improved without expensive retraining*, Dec. 2023. DOI: 10.48550/arXiv.2312.07413.

[36] A. Novikov, N. Vu, M. Eisenberger, E. Dupont, P.-S. Huang, A. Z. Wagner, S. Shirobokov, B. Kozlovskii, F. J. R. Ruiz, A. Mehrabian, M. P. Kumar, A. See, S. Chaudhuri, G. Holland, A. Davies, S. Nowozin, P. Kohli, và M. Balog, *AlphaEvolve: A coding agent for scientific and algorithmic discovery*, Jun. 2025. DOI: 10.48550/arXiv.2506.13131.

[37] T. Cunningham, L. Althoff, B. Halperin, B. Jabarian, A. Koh, A. Ramani, P. Trammell, P. Whitfill, và C. Wu, *The economics of recursive self-improvement*, Jul. 2026.

[38] H. Wang, T. Fu, Y. Du, W. Gao, K. Huang, Z. Liu, P. Chandak, S. Liu, P. Van Katwyk, A. Deac, A. Anandkumar, K. Bergen, C. P. Gomes, S. Ho, P. Kohli, J. Lasenby, J. Leskovec, T.-Y. Liu, A. Manrai, D. Marks, B. Ramsundar, L. Song, J. Sun, J. Tang, P. Veličković, M. Welling, L. Zhang, C. W. Coley, Y. Bengio, và M. Zitnik, "Scientific discovery in the age of artificial intelligence," *Nature*, vol. 620, no. 7972, pp. 47–60, Aug. 2023. DOI: 10.1038/s41586-023-06221-2.

[39] K. E. Drexler, *Radical abundance: How a revolution in nanotechnology will change civilization*. PublicAffairs, 2013.

[40] Y. Bengio, S. Clare, C. Prunkl, M. Murray, M. Andriushchenko, B. Bucknall, R. Bommasani, S. Casper, T. Davidson, R. Douglas, D. Duvenaud, P. Fox, U. Gohar, R. Hadshar, A. Ho, T. Hu, C. Jones, S. Kapoor, A. Kasirzadeh, S. Manning, N. Maslej, V. Mavroudis, C. McGlynn, R. Moulange, J. Newman, K. Y. Ng, P. Paskov, S. Rismani, G. Sastry, E. Seger, S. Singer, C. Stix, L. Velasco, N. Wheeler, D. Acemoglu, V. Conitzer, T. G. Dietterich, E. W. Felten, F. Heintz, G. Hinton, N. Jennings, S. Leavy, T. Ludermir, V. Marda, H. Margetts, J. McDermid, J. Munga, A. Narayanan, A. Nelson, C. Neppel, S. D. Ramchurn, S. Russell, M. Schaake, B. Schölkopf, A. Soto, L. Tiedrich, G. Varoquaux, A. Yao, Y.-Q. Zhang, L. A. Aguirre, O. Ajala, F. Albalawi, N. AlMalek, C. Busch, J. Collas, A. C. P. d. L. F. de Carvalho, A. Gill, A. H. Hatip, J. Heikkilä, C. Johnson, G. Jolly, Z. Katzir, M. N. Kerema, H. Kitano, A. Krüger, K. M. Lee, J. R. López Portillo, A. McLysaght, O. Molchanovskyi, A. Monti, M. Nemer, N. Oliver, R. Pezoa, A. Plonk, B. Ravindran, H. Riza, C. Rugege, H. Sheikh, D. Wong, Y. Zeng, L. Zhu, D. Privitera, và S. Mindermann, "International AI safety report 2026," Department for Science, Innovation and Technology, Tech. Rep. DSIT 2026/001, 2026.

[41] Y. Bengio, G. Hinton, A. Yao, D. Song, P. Abbeel, T. Darrell, Y. N. Harari, Y.-Q. Zhang, L. Xue, S. Shalev-Shwartz, G. Hadfield, J. Clune, T. Maharaj, F. Hutter, A. G. Baydin, S. McIlraith, Q. Gao, A. Acharya, D. Krueger, A. Dragan, P. Torr, S. Russell, D. Kahneman, J. Brauner, và S. Mindermann, "Managing extreme AI risks amid rapid progress," *Science*, vol. 384, no. 6698, pp. 842–845, May 2024. DOI: 10.1126/science.adn0117.

[42] C. Aveggio, A. J. Patel, S. Nevo, và K. Webster, "Exploring the offense-defense balance of biology: Identifying and describing high-level asymmetries," RAND Corporation, Santa Monica, CA, Tech. Rep. PE-A4102-1, Aug. 2025.

[43] R. Greenblatt, A. Cotra, và H. Wijk, "Brief independent investigation of agents' behavior, reasoning and collaboration in the OpenAI / Hugging Face hacking incident," METR and Redwood Research, Tech. Rep., Aug. 2026.

[44] OpenAI, *OpenAI and Hugging Face partner to address security incident during model evaluation*, Jul. 2026.

[45] OpenAI, *The Hugging Face incident and the road ahead*, Aug. 2026.

[46] M. Sulmeyer, "Artificial intelligence and the risk of strategic cyberattack," RAND Corporation, Tech. Rep., Jul. 2026.

[47] D. Hendrycks, E. Schmidt, và A. Wang, *Superintelligence strategy: Expert version*, Mar. 2025. DOI: 10.48550/arXiv.2503.05628.

[48] C. O'Keefe, A. Z. Rozenshtein, và C. Winter, *Executive branch AI and the rule of law: An emerging research agenda*, May 2026.

[49] T. Davidson, L. Finnveden, và R. Hadshar, "AI-enabled coups: How a small group could use AI to seize power," 2025.

[50] J. Edwards và L. Emberson, *Open models lag state-of-the-art closed models by 4 months*, May 2026.

[51] R. Slayton, "What is the cyber offense-defense balance? Conceptions, causes, and assessment," *International Security*, vol. 41, no. 3, pp. 72–109, 2017. DOI: 10.1162/ISEC_a_00267.

[52] B. Garfinkel và A. Dafoe, "How does the offense-defense balance scale?" *Journal of Strategic Studies*, vol. 42, no. 6, pp. 736–763, Aug. 2019. DOI: 10.1080/01402390.2019.1631810.

[53] *Transparency in Frontier Artificial Intelligence Act*, SB 53, 2025–2026 Reg. Sess. (Cal. 2025), Sep. 2025.

[54] European Commission, *The general-purpose AI code of practice*, Jul. 2025.

[55] *Responsible AI Safety and Education (RAISE) Act*, A6453B, 2025–2026 Reg. Sess. (N.Y. 2025), Dec. 2025.

[56] J. Kwon và S. Casper, *Internal deployment gaps in AI regulation*, Jan. 2026. DOI: 10.48550/arXiv.2601.08005.

[57] M. Pistillo, *Internal deployment in the AI Act*, Jun. 2026.

[58] A. Chan, R. Padarath, J. Kwon, H. Greaves, và M. Anderljung, *Measuring AI R&D automation*, Mar. 2026. DOI: 10.48550/arXiv.2603.03992.

[59] M. Brundage, N. Dreksler, A. Homewood, S. McGregor, P. Paskov, C. Stosz, G. Sastry, A. F. Cooper, G. Balston, S. Adler, S. Casper, M. Anderljung, G. Werner, S. Mindermann, V. Mavroudis, B. Bucknall, C. Stix, J. Freund, L. Pacchiardi, J. Hernandez-Orallo, M. Pistillo, M. Chen, C. Painter, D. W. Ball, C. O'Keefe, G. Weil, B. Harack, G. Finley, R. Hassan, S. Emmons, C. Foster, A. Reuel, B. Treece, Y. Bengio, D. Reti, R. Bommasani, C. Trout, A. S. Shamsabadi, R. Dattani, A. Weller, R. Trager, J. Sevilla, L. Wagner, L. Soder, K. Ramakrishnan, H. Papadatos, M. Murray, và R. Tovcimak, *Frontier AI auditing:*

Toward rigorous third-party assessment of safety and security practices at leading AI companies, Feb. 2026. DOI: 10.48550/arXiv.2601.11699.

[60] P. Wills, *Regulatory supervision of frontier AI developers*, SSRN Scholarly Paper, Rochester, NY, Mar. 2025. DOI: 10.2139/ssrn.5122871.

[61] U.S. Nuclear Regulatory Commission, *Backgrounder on NRC resident inspectors*, 2023.

[62] Office of the Comptroller of the Currency, *What we do*, 2026.

[63] M. Baker, G. Kulp, O. Marks, M. Brundage, và L. Heim, *Verifying international agreements on AI: Six layers of verification for rules on large-scale AI development and deployment*, Jul. 2025. DOI: 10.48550/arXiv.2507.15916.

[64] B. Harack, R. F. Trager, A. Reuel, D. Manheim, M. Brundage, O. Aarne, A. Scher, Y. Pan, J. Xiao, K. Loke, S. N. Adan, G. Bas, N. A. Caputo, J. C. Morse, J. Ahuja, I. Duan, J. Egan, B. Bucknall, B. Rosen, R. Araujo, V. Boulanin, R. Lall, F. Barez, S. Alvira, C. Katzke, A. Atamli, và A. Awad, "Verification for international AI governance," Oxford Martin AI Governance Initiative, University of Oxford, Tech. Rep., Jul. 2025.

[65] T. Larsen, R. Dean, B. Halstead, E. Lifland, R. Greenblatt, và D. Kokotajlo, *AI 2040: Plan A*, AI Futures Project, 2026.

[66] G. Sastry, L. Heim, H. Belfield, M. Anderljung, M. Brundage, J. Hazell, C. O'Keefe, G. K. Hadfield, R. Ngo, K. Pilz, G. Gor, E. Bluemke, S. Shoker, J. Egan, R. F. Trager, S. Avin, A. Weller, Y. Bengio, và D. Coyle, *Computing power and the governance of artificial intelligence*, Feb. 2024. DOI: 10.48550/arXiv.2402.08797.

[67] A. Korinek và J. E. Stiglitz, *Steering technological progress*, Working Paper, Mar. 2026. DOI: 10.3386/w34994.

[68] S. Shoker, A. Reddie, S. Barrington, R. Booth, M. Brundage, H. Chahal, M. Depp, B. Drexel, R. Gupta, M. Favaro, J. Hecla, A. Hickey, M. Konaev, K. Kumar, N. Lambert, A. Lohn, C. O'Keefe, N. Rajani, M. Sellitto, R. Trager, L. Walker, A. Wehsener, và J. Young, *Confidence-building measures for artificial intelligence: Workshop proceedings*, Aug. 2023. DOI: 10.48550/arXiv.2308.00862.

[69] Intelligence Rising, *Intelligence Rising*, n.d.

[70] AI Futures Project, *About AI 2027: Tabletop exercise*, 2025.

[71] G. Smith, G. Hage, C. Heitzenrater, M. Chessen, và R. S. Girven, "Infinite potential—insights from the cyber surprise scenario," RAND Corporation, Tech. Rep., Mar. 2026.

[72] L. Vaintrob, *The AI adoption gap: Preparing the US government for advanced AI*, Apr. 2025.

[73] OpenAI, *OpenAI model spec*, Aug. 2026.

[74] Anthropic, *Claude's constitution*, Jan. 2026.

[75] C. O'Keefe, K. Ramakrishnan, J. Tay, và C. Winter, "Law-following AI: Designing AI agents to obey human laws," *Fordham Law Review*, vol. 94, no. 1, p. 57, 2025.

[76] S. Guerra, A. Attal-Juncqua, J. P. Tarangelo, C. Aveggio, K. Dammer, và D. Glickstein, "Building a defense-in-depth biosecurity strategy for the AI era," RAND Corporation, Tech. Rep., Aug. 2026.

[77] J.-S. Denain, A. Ho, và J. Sevilla, *How many digital workers could OpenAI deploy?* Oct. 2025.

[78] H. Wijk, T. Lin, J. Becker, S. Jawhar, N. Parikh, T. Broadley, L. Chan, M. Chen, J. Clymer, J. Dhyani, E. Ericheva, K. Garcia, B. Goodrich, N. Jurkovic, H. Karnofsky, M. Kinniment, A. Lajko, S. Nix, L. Sato, W. Saunders, M. Taran, B. West, và E. Barnes, *RE-Bench: Evaluating frontier AI R&D capabilities of language model agents against human experts*, May 2025. DOI: 10.48550/arXiv.2411.15114.

[79] A. Ho, J.-S. Denain, D. Atanasov, S. Albanie, và R. Shah, *A rosetta stone for AI benchmarks*, 2025.

[80] B. Cottier, B. Snodin, D. Owen, và T. Adamczewski, *LLM inference prices have fallen rapidly but unequally across tasks*, Mar. 2025.

[81] H. Gundlach, A. Fogelson, J. Lynch, A. Trisovic, J. Rosenfeld, A. Sandhu, và N. Thompson, *On the origin of algorithmic progress in AI*, Nov. 2025. DOI: 10.48550/arXiv.2511.21622.

[82] P. Trammell, "The bounded parallelizability of R&D: Theory and application to AI," Jul. 2026.

[83] METR, *Measuring AI ability to complete long tasks*, Mar. 2025.

[84] D. Kokotajlo, S. Alexander, T. Larsen, E. Lifland, và R. Dean, *AI 2027*, Apr. 2025.

[85] T. Ord, *The dynamics of intelligence explosions*, 2026. arXiv: 2608.14426 [cs.AI].

[86] B. Murphy và T. Stone, *Uplifted attackers, human defenders: The cyber offense-defense balance for trailing-edge organizations*, Aug. 2025. DOI: 10.48550/arXiv.2508.15808.

[87] Anthropic, *Investigating three real-world incidents in our cybersecurity evaluations*, Tháng 7 năm 2026 (trích dẫn ở tr. 14).

[88] UK AI Security Institute, *Incident report: Unsanctioned agent behaviour during cyber testing*, Tháng 8 năm 2026 (trích dẫn ở tr. 14).

[89] OpenAI, *Third-party cyber evaluations involving OpenAI models*, Tháng 8 năm 2026 (trích dẫn ở tr. 14).

[90] P. C. Bogdan, R. Qi, J. Eaton, S. Kennedy, F. Roger, A. Glynn, R. Chen, B. Wright, O. Stegmaier, J. Kutasov, D. Foreman-Mackey, T. Bricken, S. Carr, S. Carter, M. MacDiarmid, S. Marks, A. Pearce, E.

Simon, N. Carlini, C. Burns, J. Lindsey, S. Price, và S. Kantamneni, *An alignment assessment of recent cybersecurity incidents*, Anthropic, Tháng 9 năm 2026 (trích dẫn ở tr. 14).

[91] M. H. Tessler, M. A. Bakker, D. Jarrett, H. Sheahan, M. J. Chadwick, R. Koster, G. Evans, L. Campbell-Gillingham, T. Collins, D. C. Parkes, M. Botvinick, và C. Summerfield, "AI can help humans find common ground in democratic deliberation," *Science*, tập 386, số 6719, eadq2852, Tháng 10 năm 2024. DOI: 10.1126/science.adq2852 (trích dẫn ở tr. 14).

[92] A. Goldie và A. Mirhoseini, *How AlphaChip transformed computer chip design*, Tháng 9 năm 2024 (trích dẫn ở tr. 14).

Tài liệu Bổ sung

Ước tính quy mô hiệu dụng của lực lượng lao động AI

Theo phương pháp của Denain và cộng sự [77], chúng tôi ước tính lực lượng lao động hiệu dụng bằng cách lấy số lượng token mà một nhà phát triển có thể tạo ra mỗi ngày chia cho số lượng token tương ứng với một ngày làm việc của một nhà nghiên cứu (researcher-day). Riêng OpenAI đã sở hữu đủ năng lực tính toán suy luận (nghĩa là năng lực tính toán khi vận hành) để tạo ra khoảng 10^{13} token mỗi ngày. Để ước tính số token trên mỗi ngày làm việc của nhà nghiên cứu, chúng tôi sử dụng số token mà một mô hình tạo ra cho một tác vụ tiêu tốn của một nhà nghiên cứu con người một ngày làm việc (8 giờ). Trong một phép đo chuẩn (benchmark) R&D về AI, Wijk và cộng sự [78] nhận thấy rằng các mô hình tạo ra trung bình $5 \cdot 10^5$ token trong các lượt chạy kéo dài tới 8 giờ, ngụ ý một lực lượng lao động hiệu dụng tương đương khoảng $2 \cdot 10^7$ nhà nghiên cứu. Cho phép một biên độ bất định khoảng một bậc độ lớn theo cả hai hướng ($5 \cdot 10^4$–$5 \cdot 10^6$ token trên mỗi ngày-nhà nghiên cứu), chúng tôi ước tính lực lượng lao động hiệu dụng rơi vào khoảng $2 \cdot 10^6$–$2 \cdot 10^8$. Tương tự như trong nội dung chính, phép tính này giả định rằng các hệ thống AI ở cấp độ chuyên gia có chi phí vận hành tương đương với các hệ thống hiện nay.

Mô hình hóa vòng lặp phản hồi dưới điều kiện tự động hóa hoàn toàn

Hầu hết các phân tích về sự bùng nổ trí tuệ do phần mềm dẫn dắt đều mô tả tiến bộ AI thông qua một khái niệm về chất lượng phần mềm, ký hiệu là A. Về mặt nguyên tắc, A phải đo lường tiến bộ AI một cách toàn diện, bao gồm cả những cải tiến về mặt hiệu quả (các hệ thống AI mới hoàn thành các tác vụ tương tự hệ thống cũ với hiệu năng tương đương nhưng sử dụng ít tài nguyên tính toán hoặc dữ liệu hơn) và những cải tiến về mặt năng lực (các hệ thống AI mới hoàn thành các tác vụ mà hệ thống trước đó không thể làm được, hoặc đạt hiệu năng cao hơn mức hệ thống trước có thể đạt tới). Thách thức hiện nay là chưa rõ tham số A nên đánh đổi tối ưu như thế nào giữa các cải tiến hiệu quả và cải tiến năng lực (hoặc giữa các loại cải tiến hiệu quả và cải tiến năng lực khác nhau).

Tạm gác lại vấn đề này, chúng tôi mô hình hóa sự gia tăng của chất lượng phần mềm bằng phương trình $dA/dt = A^{1-\beta}E^{\lambda}$, một dạng hàm phổ biến trong kinh tế học vĩ mô về đổi mới sáng tạo [27]. Để đơn giản hóa, chúng tôi bỏ qua các điểm nghẽn tiềm tàng từ tài nguyên tính toán và dữ liệu. Ở đây, E là lao động R&D hiệu dụng, λ thể hiện hiệu suất theo quy mô đối với lao động R&D, và β thể hiện việc tìm kiếm các ý tưởng mới theo thời gian có hiệu suất tăng dần hay giảm dần.

Câu hỏi then chốt là E tăng trưởng theo A như thế nào. Giả định tự động hóa hoàn toàn, chúng tôi xem xét hai trường hợp. Trước hết, hãy xét trường hợp mà toàn bộ cải tiến chất lượng phần mềm đều là sự gia tăng hiệu quả tính toán suy luận, tức là sự suy giảm lượng tài nguyên tính toán cần thiết để chạy một hệ thống AI ở một mức năng lực nhất định. Trong trường hợp đó, nếu A đo lường hiệu quả suy luận, thì E tỷ lệ thuận với A: hiệu quả suy luận cao hơn cho phép vận hành nhiều nhà nghiên cứu tự động hơn theo tỷ lệ thuận tương ứng.

Thứ hai, hãy xét trường hợp mà toàn bộ cải tiến chất lượng phần mềm đều là mức tăng năng lực, được thúc đẩy bởi sự cải thiện hiệu quả tính toán huấn luyện: sự sụt giảm lượng tài nguyên tính toán cần thiết để huấn luyện một hệ thống AI đạt mức năng lực nhất định, cho phép một hệ thống có năng lực cao hơn được huấn luyện với một lượng tài nguyên tính toán cố định sẵn có. Nếu A đo lường hiệu quả tính toán huấn luyện, thì sự gia tăng của A sẽ tạo ra các hệ thống có năng lực cao hơn thay vì tạo ra số lượng hệ thống nhiều hơn. Nếu chúng ta đưa ra giả định (vốn còn nhiều nghi vấn) rằng số lượng nhà nghiên cứu hiệu dụng tăng tuyến tính theo các mức tăng năng lực này, thì E lại một lần nữa tỷ lệ thuận với A.

Trong cả hai trường hợp, $E = kA$ với một hằng số dương k nào đó. Thay vào phương trình trên ta được $dA/dt = cA^{\lambda-\beta+1}$, trong đó $c = k^{\lambda}$. Để tốc độ tăng trưởng $(1/A)dA/dt$ tăng lên khi chất lượng phần mềm tăng, ta cần $\lambda > \beta$. Định nghĩa $r = \lambda/\beta$, ta thu được điều kiện $r > 1$ đã thảo luận trong phần nội dung chính.

Tiến trình có thể tăng tốc nhanh đến mức nào dưới các ước tính hiện tại về các tham số này? Chúng tôi đo lường gia tốc bằng tốc độ tăng trưởng của chất lượng phần mềm: $(1/A)dA/dt = c \cdot A^{\lambda-\beta}$. Lấy giá trị trung bình từ các ước tính trung tâm trên ba lĩnh vực phụ trong nghiên cứu của Ho và Whitfill [28] cho kết quả $\lambda = 1.40$ và $\beta = 1.01$. Với $\lambda - \beta = 0.39$, mỗi lần A tăng gấp đôi sẽ nhân tốc độ tăng trưởng lên $2^{0.39} \approx 1.31$ lần, do đó mỗi lần tăng đôi tiếp theo sẽ mất khoảng thời gian bằng $(1/2)^{0.39} \approx 76\%$ so với lần trước đó. Để tốc độ tăng trưởng tăng gấp mười lần, A cần phải tăng gấp đôi $\log_2(10)/0.39 \approx 8.5$ lần. Đối với khoảng thời gian của lần tăng đôi đầu tiên, chúng tôi sử dụng các ước tính gần đây cho thấy, chỉ riêng nhờ các cải tiến phần mềm, hiệu quả tính toán huấn luyện tăng gấp đôi sau khoảng mỗi 4,5 tháng [79]; hiệu quả tính toán suy luận thậm chí có thể còn tăng nhanh hơn [80]. Để tránh việc phải tính xấp xỉ tổng cấp số nhân cho 8,5 lần tăng đôi, chúng tôi tính tổng cấp số nhân cho 9 lần tăng đôi, sau thời gian đó tốc độ tăng trưởng sẽ tăng hơn mười lần. Khi thực hiện phép tính này, chúng tôi nhận thấy tốc độ tăng trưởng sẽ tăng hơn mười lần sau $4.5 \text{ tháng} \times (1 - 0.76^9)/(1 - 0.76) \approx 17 \text{ tháng}$, tức khoảng 1,5 năm. Tại thời điểm đó, tiến độ sẽ nhanh gấp mười lần so với hiện nay, nghĩa là khối lượng tiến bộ của cả một năm với tốc độ ngày nay sẽ chỉ mất khoảng năm tuần để hoàn thành.

Những điểm bất định về hiệu suất sinh lợi đối với nỗ lực nghiên cứu

Một số yếu tố có thể khiến giá trị thực của r sai khác so với các ước tính hiện có. Thứ nhất, như đã lưu ý ở trên, hiện vẫn chưa rõ thước đo chất lượng phần mềm nào là phù hợp nhất. Hiệu quả suy luận phản ánh trực tiếp nhất quy mô của lực lượng lao động R&D tự động hóa, trong khi vẫn chưa rõ cách thức chuyển đổi mức tăng hiệu quả huấn luyện thành số lượng nhà nghiên cứu hiệu dụng. Tuy nhiên, các ước tính hiện tại về r cho hoạt động R&D về AI đều sử dụng hiệu quả huấn luyện, và không rõ hiệu suất đối với nỗ lực nghiên cứu theo hai thước đo này tương đồng đến mức nào. Hơn nữa, việc đánh giá đúng đắn hiệu suất đối với nỗ lực nghiên cứu đòi hỏi phải bao gồm cả những cải tiến từ hiệu quả suy luận lẫn hiệu quả huấn luyện, thay vì chỉ xét một trong hai. Cần có thêm nhiều nghiên cứu để xây dựng một tiêu chí mô tả chất lượng phần mềm kết hợp cả hiệu quả suy luận và huấn luyện, đồng thời cân quyền số giữa chúng một cách thích hợp.

Các ước tính hiện có về r bắt nguồn từ một giai đoạn mở rộng quy mô tính toán (compute scaling) nhanh chóng, điều này làm xáo trộn và khó phân tách đóng góp giữa tiến bộ phần mềm và việc mở rộng quy mô tính toán. Bởi hai yếu tố đầu vào này trong lịch sử cùng tăng trưởng song hành, một ước tính quy toàn bộ tiến bộ quan sát được cho các cải tiến phần mềm trên thực tế có thể đang ghi nhận những bước tiến được thúc đẩy bởi, hoặc chỉ khả thi nhờ vào, tài nguyên tính toán ngày càng gia tăng. Một số cải tiến phần mềm phụ thuộc vào quy mô: ví dụ, kiến trúc Transformer mang lại hiệu năng vượt trội ở mức tài nguyên tính toán huấn luyện cao nhưng chỉ mang lại lợi ích tương đối nhỏ ở mức tài nguyên tính toán thấp [81]. Sự nhiễu loạn này sẽ làm lệch ước tính về r theo chiều hướng cao hơn: trong điều kiện tài nguyên tính toán cố định hoặc tăng trưởng chậm, r sẽ thấp hơn so với những gì dữ liệu lịch sử gợi ý.

Các yếu tố khác có thể hàm ý một giá trị r cao hơn. Hầu hết các ước tính về r đều bỏ qua các cải tiến ở những lĩnh vực ngoài tiền huấn luyện (pre-training), chẳng hạn như hậu huấn luyện (post-training) hoặc cấu trúc khung đỡ (scaffolding) tốt hơn cho việc sử dụng công cụ [35]. Hơn nữa, các cải tiến về năng lực có thể tác động theo những cách mà số lượng nhà nghiên cứu hiệu dụng không nắm bắt được: ngay cả một lượng cực lớn các nhà nghiên cứu bậc trung cũng không thể thay thế cho một nhà nghiên cứu thiên tài. Nếu đúng như vậy, mức tăng năng lực sẽ mở rộng lao động R&D hiệu dụng vượt xa mức mà giả định tuyến tính ở trên đưa ra. Các điểm nghẽn về tài nguyên tính toán cũng có thể được khắc phục, chẳng hạn thông qua việc ngoại suy tốt hơn từ các thử nghiệm quy mô nhỏ, giảm chi phí thử nghiệm nhờ tiến bộ phần mềm, chuyển dịch sang các phương pháp ít phụ thuộc vào tính toán hơn, và tiến bộ về thuật toán không đòi hỏi thử nghiệm [7].

Các ước tính về r cũng phụ thuộc vào các biến đại diện (proxy) chưa hoàn hảo cho lao động R&D, điều này có thể làm chệch ước tính theo bất kỳ hướng nào. Ví dụ, Ho và Whitfill [28] đại diện lao động R&D bằng số lượng tác giả duy nhất đã xuất bản các bài báo trong một lĩnh vực. Việc phân định phạm vi lĩnh vực quá hẹp sẽ đánh giá thấp lao động do loại trừ các lĩnh vực lân cận vốn cũng thúc đẩy tiến bộ, trong khi phân định quá rộng lại thổi phồng lao động. Trừ khi các lĩnh vực lân cận bị

loại trừ có cùng tốc độ tăng trưởng lao động như các lĩnh vực được đưa vào, sự lệch pha này sẽ dẫn đến việc tính toán sai lệch giá trị r.

Cuối cùng, các mô hình toán học liên quan có thể không khái quát hóa được cho khối lượng lao động R&D cực lớn [82]. Trong lịch sử, chúng được kiểm chứng dựa trên các tốc độ tăng trưởng chỉ vài phần trăm mỗi năm, thấp hơn nhiều so với tốc độ hai chữ số hoặc cao hơn mà một vụ bùng nổ trí tuệ có thể tạo ra. Chúng cũng bị phá vỡ ở điểm giới hạn (limit), nơi chúng ngụ ý rằng lượng lao động vô hạn sẽ mang lại tiến bộ vô hạn trong một khoảng thời gian hữu hạn. Tuy nhiên, các ràng buộc thực tế khiến kết quả này trở nên bất khả thi: một số vấn đề bắt buộc phải được giải quyết theo trình tự tuần tự, và phần cứng vật lý cũng chỉ có thể vận hành ở một tốc độ tối đa nhất định.

Ghi chú

1. Các hội nghị học máy thường có một phân ban hội nghị chính (main track) và một vài phân ban hội thảo chuyên đề (workshop track). Một điểm cần lưu ý đối với các kết quả này là các phân ban hội thảo chuyên đề có thể có tiêu chuẩn lỏng lẻo hơn đôi chút so với phân ban hội nghị chính.
2. Theo thước đo đường chân trời thời gian (time-horizon metric) của METR [17, 83], độ dài tác vụ mà các hệ thống AI có thể hoàn thành ban đầu tăng gấp đôi sau khoảng mỗi 7 tháng, và đã tăng tốc lên mức khoảng 3 tháng một lần kể từ năm 2024. Việc ngoại suy xu hướng gần đây này cho thấy rằng vào giữa năm 2028, các hệ thống AI sẽ có thể hoàn thành các tác vụ đòi hỏi vài tháng thời gian của chuyên gia con người, nằm hoàn toàn trong phạm vi của nhiều dự án R&D về AI. Xem thêm Kokotajlo và cộng sự [84].

3. Cottier và cộng sự [80] nhận thấy chi phí vận hành các LLM để đạt được một cột mốc năng lực nhất định (ví dụ: hiệu năng tương đương GPT-4 trên một bài kiểm chuẩn toán học) đã giảm khoảng 9 đến 900 lần mỗi năm, tùy thuộc vào cột mốc năng lực. Mặc dù một phần sự sụt giảm chi phí này đến từ những cải tiến phần cứng (giảm chi phí cho mỗi phép tính toán), một phần đáng kể bắt nguồn từ các cải tiến phần mềm.
4. Trong một lĩnh vực công nghệ, r chi phối mối quan hệ giữa mức tăng đầu vào R&D và sự thay đổi kết quả đầu ra được quan tâm, chẳng hạn như số lượng phép tính mà phần cứng tiêu dùng tối tân có thể thực hiện trên mỗi đơn vị đồng đô la cố định. Trong Bloom và cộng sự [27], đầu vào được đo lường bằng số tiền chi cho R&D và do đó bao gồm mức tăng của cả lao động lẫn vốn vật chất. Tuy nhiên, trong nghiên cứu này, chúng tôi chỉ xem xét mức tăng về lao động, vì chúng tôi quan tâm đến việc tìm hiểu tiềm năng của một vòng lặp phản hồi do phần mềm dẫn dắt, trong đó tổng lượng tài nguyên tính toán được giữ gần như cố định. Điều này đồng nghĩa với việc giá trị của r sẽ thấp hơn so với khi chúng tôi xem xét mức tăng ở tất cả các yếu tố đầu vào (tức lao động, dữ liệu và tài nguyên tính toán).
5. r cuối cùng phải giảm xuống dưới 1 vì tiến bộ AI rốt cuộc sẽ chạm phải các giới hạn tính toán và giới hạn vật lý. Hiện vẫn chưa rõ mức độ tiến bộ có thể đạt được là bao nhiêu trước khi chạm tới các giới hạn đó.
6. Các khoảng tin cậy 90% tương ứng là (0,727 đến 2,094), (0,380 đến 2,708), và (1,069 đến 3,212).

7. Trong phân tích này, những cải tiến về hiệu quả thuật toán tự thân chúng không giải quyết được nút thắt cổ chai tiềm tàng này vì chúng làm tăng hiệu quả của cả hoạt động R&D lẫn quá trình huấn luyện theo tỷ lệ tương đương.
8. Cụ thể, bài báo đưa ra các điều kiện mà theo đó lao động nghiên cứu tự động hóa, cùng với các đại lượng khác như sản lượng kinh tế, sẽ tăng trưởng tới vô hạn trong một khoảng thời gian hữu hạn.
9. Xem Ord [85] để biết thêm thảo luận mang tính lý thuyết về việc khoảng thời gian giữa các chu kỳ R&D có thể ảnh hưởng như thế nào đến động lực học của một vụ bùng nổ trí tuệ.
10. Phân tích trong Cunningham và cộng sự [37] tập trung vào sự tăng tốc tự duy trì (self-sustaining acceleration): "Khi các hệ thống AI đủ khả năng để tự đẩy nhanh tiến bộ về năng lực AI mà không cần bất kỳ sự gia tăng nào từ các yếu tố đầu vào ngoại sinh (lao động con người, tài nguyên tính toán huấn luyện, v.v.)." Sự tăng tốc tự duy trì là điều kiện cần cho một vụ bùng nổ trí tuệ do phần mềm dẫn dắt theo định nghĩa của chúng tôi.
11. Những hệ thống như vậy có thể siêu việt hơn con người trong một số lĩnh vực (ví dụ: các lĩnh vực nghiên cứu khoa học nhất định) nhưng lại không vượt trội ở những lĩnh vực khác (ví dụ: thao tác với các đồ vật trong thế giới vật lý).
12. Tuy nhiên, ngay cả trong lĩnh vực an ninh mạng, các quy trình tổ chức của con người vẫn có thể tạo ra lực cản đối với bên phòng thủ [86].
13. Xem thêm Anthropic [87], UK AI Security Institute [88], OpenAI [89], và Bogdan và cộng sự [90].
14. Ví dụ, xem Tessler và cộng sự [91]. Suy đoán xa hơn, các hệ thống AI có khả năng đẩy nhanh sự phát triển của các giao diện não - máy tính, cho phép con người tư duy và phối hợp nhanh hơn rất nhiều.
15. Việc thao tác hóa (operationalizing) chính xác khái niệm bùng nổ trí tuệ là một vấn đề phức tạp và vẫn là hướng nghiên cứu dành cho tương lai.
16. Ví dụ, AI hiện đã tham gia hỗ trợ thiết kế chip [92]. Các hệ thống AI cũng có thể thúc đẩy ngành chế tạo robot nhằm tự động hóa quy trình sản xuất chip.