Đại học Cambridge • CASP (Chương trình Khoa học & Chính sách AI Cambridge)

Điều gì sẽ xảy ra nếu việc tự động hóa R&D AI kích hoạt một vụ nổ trí tuệ?

Chuỗi Báo cáo Nghiên cứu AI Đi đầu (Frontier AI Working Paper Series) Số 2/2026
Tháng 9 năm 2026

Điều gì sẽ xảy ra nếu việc tự động hóa R&D AI kích hoạt một vụ nổ trí tuệ?

Alan Chan*
GovAI

Andrew Barto
Đại học Massachusetts Amherst

Geoffrey Hinton
Đại học Toronto, Viện Vector

Yoshua Bengio
Mila (Viện AI Quebec), Đại học Montréal, LawZero

Jack Clark
Anthropic

Anton Korinek
Đại học Virginia, Anthropic

Thore Graepel
University College London

Philip H. S. Torr
Đại học Oxford

Jeff Clune
Đại học British Columbia, Viện Vector

Girish Sastry
Guidelight

Daniel Eth
Viện Chính sách AI (AI Policy Institute)

Christoph Winter
CASP, Đại học Cambridge, Viện Luật & AI

Jakub Pachocki
OpenAI

Eric Horvitz
Microsoft

Dawn Song
Đại học California, Berkeley

Hilary Greaves
Đại học Oxford

Samuel Hammond
Foundation for American Innovation

Ben Bariach
Đại học Oxford

Sheila A. McIlraith
Đại học Toronto, Viện Vector

Sam Manning
GovAI, Foundation for American Innovation

Tom Davidson
Forethought

Sören Mindermann*
CASP, Đại học Cambridge

TÓM TẮT

Khác biệt hoàn toàn so với chỉ một năm trước, các hệ thống AI hiện nay đã tự viết phần lớn mã nguồn tại chính các công ty phát triển ra chúng. Khi ngày càng nhiều khâu trong quy trình nghiên cứu và phát triển (R&D) AI được tự động hóa, liệu tiến bộ AI có thể tăng tốc đột biến thành một "vụ nổ trí tuệ", nơi những bước tiến vốn mất nhiều năm bị nén lại chỉ còn vài tháng hoặc ngắn hơn? Các bằng chứng sơ bộ cho thấy điều này hoàn toàn có thể xảy ra. Trong công trình này, chúng tôi đánh giá các bằng chứng này, phân tích những tác động tiềm tàng của một vụ nổ trí tuệ và đề xuất các biện pháp ứng phó chính sách. Các hệ thống AI đang trên đà tự động hóa hầu hết công việc R&D AI trong vòng vài năm tới, và khả năng cao là toàn bộ công việc này. Nếu điều đó kích hoạt một vụ nổ trí tuệ, nó có thể mang lại những lợi ích to lớn của AI sớm hơn nhiều, nhưng cũng đặt ra những rủi ro cực độ: sự gia tăng năng lực có thể vượt xa khả năng theo kịp của xã hội, nhân loại có thể mất quyền kiểm soát đối với các hệ thống AI siêu trí tuệ, và cơ chế kiểm soát quyền lực bên trong cũng như giữa các quốc gia, các tập đoàn và các nhánh quyền lực nhà nước có thể bị xói mòn nghiêm trọng. Dù vẫn còn nhiều bất định xung quanh các kịch bản này, nhưng hệ quả mang tính sống còn đòi hỏi phải có sự quan tâm nghiêm túc hơn nữa. Các nhà hoạch định chính sách cần khẩn trương nắm bắt rõ ràng hơn quy trình tự động hóa R&D AI, xây dựng các phương thức để định hướng và kiểm soát một vụ nổ trí tuệ, đồng thời chuẩn bị cho xã hội khả năng thích ứng trước các tác động của hiện tượng này.

*Thư từ trao đổi gửi về: alan.chan@governance.ai và soren.mindermann@casp.ac. Các quan điểm trình bày trong bài báo này là của riêng các tác giả và không nhất thiết đại diện cho quan điểm của các tổ chức mà họ trực thuộc.

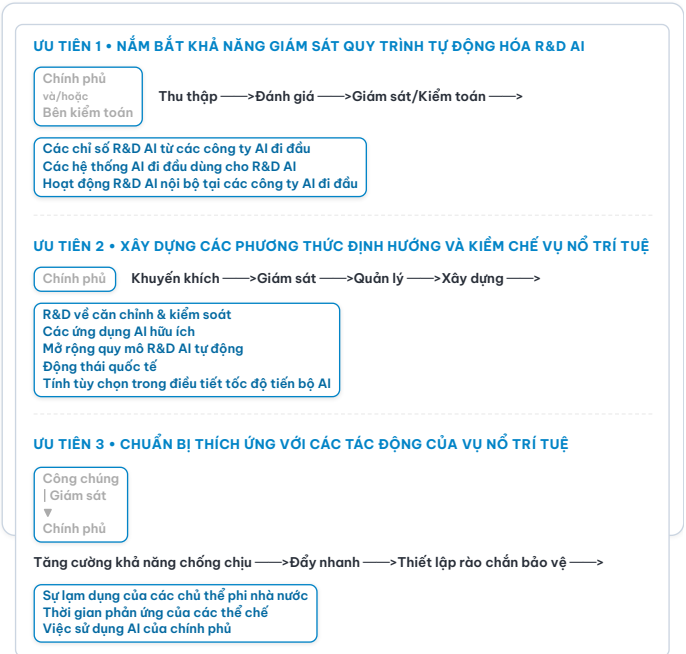
Giới thiệu

Các nhà khoa học máy tính từ lâu đã đưa ra giả thuyết rằng một ngày nào đó các hệ thống AI sẽ thiết kế ra các thế hệ kế thừa ngày càng ưu việt hơn, tạo ra những hệ thống nhanh chóng áp đảo về số lượng, tốc độ và vượt trội hơn con người [1–3]. Ngày nay, các công ty AI đi đầu đang đặt mục tiêu tự động hóa quy trình R&D AI [4, 5] đồng thời triển khai lượng vốn tính theo tỷ trọng GDP của Hoa Kỳ lớn hơn cả Dự án Manhattan và Chương trình Apollo cộng lại [6]. Điều gì sẽ xảy ra nếu họ thành công?

Mối quan tâm trọng tâm của chúng tôi là khả năng xảy ra một **vụ nổ trí tuệ**: sự tăng tốc vượt bậc của tiến bộ AI do chính AI thúc đẩy, nén những bước tiến vốn phải mất nhiều năm xuống chỉ còn vài tháng hoặc ngắn hơn. Sự tăng tốc này sẽ là một bước chuyển biến về chất so với tiến trình phát triển nhanh chóng nhưng phần lớn là đều đặn của vài năm qua.

Một vụ nổ trí tuệ có thể phát sinh từ việc AI đóng góp vào các tiến bộ phần cứng và/hoặc phần mềm. Các tiến bộ phần cứng làm tăng chất lượng và số lượng phần cứng điện toán (năng lực tính toán - compute) dùng để phát triển và vận hành các hệ thống AI. Các tiến bộ phần mềm cải thiện dữ liệu, thuật toán, mã nguồn và các quy trình được sử dụng trong R&D AI; chúng bao gồm việc huấn luyện và suy luận hiệu quả hơn trên phần cứng hiện có [7–9], cải thiện việc quản lý và vận hành nghiên cứu, tối ưu hóa dữ liệu tổng hợp và môi trường huấn luyện [10, 11], cùng các mô hình tiếp cận mới trong AI [12, 13]. Những tiến bộ về phần mềm cần được đặc biệt quan tâm trong ngắn hạn vì hai lý do. Thứ nhất, các hệ thống AI dường như đang nhanh chóng hoàn thiện kỹ năng R&D AI, giúp chúng tạo ra các tiến bộ này tốt hơn. Thứ hai, các tiến bộ phần mềm cho phép tạo ra các vòng phản hồi nhanh: các hệ thống AI cải tiến có thể được tái triển khai vào quy trình R&D gần như ngay lập tức, trong khi các cải tiến phần cứng thường phụ thuộc vào các chu kỳ sản xuất và xây dựng kéo dài nhiều năm. Do đó, bài viết này tập trung vào khả năng xảy ra một vụ nổ trí tuệ do phần mềm dẫn dắt, nơi quá trình tự động hóa R&D AI thúc đẩy một vụ nổ trí tuệ chỉ thông qua các tiến bộ phần mềm [14].

Các bằng chứng sơ bộ cho thấy một vụ nổ trí tuệ do phần mềm dẫn dắt là hoàn toàn khả thi. Nếu xảy ra, đây có thể là bước phát triển công nghệ có hệ quả sâu rộng nhất trong lịch sử: các hệ thống AI có thể nhanh chóng làm lu mờ các chuyên gia con người trong hầu hết mọi lĩnh vực và thúc đẩy tiến bộ công nghệ vượt bậc.



Hình 1. Các nhà hoạch định chính sách cần khẩn trương: (1) nắm bắt khả năng giám sát việc tự động hóa R&D AI bên trong các công ty AI đi đầu; (2) xây dựng các phương thức để định hướng và kiểm chế một vụ nổ trí tuệ; và (3) chuẩn bị thích ứng với những tác động của một vụ nổ trí tuệ.

Các hệ thống AI hiện nay vẫn còn nhiều điểm yếu. Đôi khi chúng không tuân thủ hướng dẫn, gian lận khi thực hiện nhiệm vụ, trình bày sai lệch kết quả công việc và hoàn toàn không thể hoàn thành một số nhiệm vụ nhất định, đòi hỏi phải có sự can thiệp của con người [23–25]. Ví dụ, GPT-6 thất bại trước một số nhiệm vụ gỡ lỗi nghiên cứu của OpenAI mà các nhà nghiên cứu con người giàu kinh nghiệm có thể

Xét đến tầm mức quan trọng và khoảng thời gian hành động có thể rất hẹp, chúng tôi cho rằng việc chuẩn bị ứng phó với một vụ nổ trí tuệ phải là ưu tiên cấp bách, bao gồm cả ở cấp lãnh đạo cao nhất của chính phủ.

AI đang nhanh chóng tự động hóa R&D AI

Các hệ thống AI hiện đang hỗ trợ hoặc tự chủ thực hiện các phần quan trọng trong quy trình R&D AI. Trái ngược với tình hình chỉ một năm trước, đội ngũ nhân sự R&D tại các công ty AI hàng đầu hiện nay đã ủy thác các nhiệm vụ R&D cốt lõi cho các nhóm hệ thống AI, và một số nơi đã ủy thác toàn bộ việc lập trình. Anthropic báo cáo rằng tỷ lệ mã nguồn được phê duyệt do các hệ thống AI viết đã tăng từ mức một chữ số lên hơn 80% trong khoảng thời gian từ tháng 1 năm 2025 đến tháng 5 năm 2026 [5], trong khi tỷ lệ công việc R&D được hoàn thành tự chủ chỉ với sự giám sát cấp cao của con người đã tăng từ 1% lên 26% từ tháng 3 đến tháng 8 năm 2026 [15]. OpenAI cho biết "sự hỗ trợ của AI được sử dụng trong hầu như mọi bộ phận của công ty từ các nhóm kỹ thuật đến phi kỹ thuật, với các tác tử thực thi mã nguồn được sử dụng trong việc huấn luyện, đánh giá và bảo mật các mô hình tương lai", và Google ghi nhận rằng "AI được sử dụng trong hầu hết mọi công việc liên quan đến viết mã hoặc cấu hình, thiết kế kỹ thuật, lên ý tưởng nghiên cứu, ở các mức độ khác nhau tùy thuộc vào nhiệm vụ" [16].

Các hệ thống AI tốt nhất hiện nay đã hoàn thành được các nhiệm vụ R&D AI mà các chuyên gia con người phải mất hàng giờ đến hàng ngày, so với việc chỉ giải quyết được các tác vụ kéo dài vài giây vào năm 2023 [17–19]. Đôi khi, các hệ thống AI còn đánh bại các chuyên gia con người: chúng đã tự chủ tạo ra các giải pháp tốt hơn cho một vấn đề nghiên cứu an toàn AI [20], và trong một số tình huống đã dự đoán chính xác hơn những ý tưởng nghiên cứu nào sẽ mang lại kết quả [21] cũng như những bước đi tiếp theo nào đáng thực hiện [5]. Trong một thử nghiệm chứng minh khái niệm ban đầu, một quy trình nghiên cứu AI tự động đã tự đưa ra ý tưởng nghiên cứu, tiến hành thí nghiệm và viết một bài báo vượt qua vòng bình duyệt tại một hội thảo thuộc hội nghị hàng đầu về học máy [22].[1]

hoàn thành (dù phải mất hàng giờ hoặc hàng ngày) [25]. Thành công trên các bài đánh giá chuẩn (benchmarks) cũng có thể không chuyển hóa được thành sự gia tăng năng suất trong thực tế [26].

Dẫu vậy, các hệ thống AI đang tiến bộ nhanh chóng trong năng lực R&D AI. Quy trình R&D AI rất có thể sẽ được tự động hóa trước hầu hết các công việc khác: đây là lĩnh vực chủ yếu hoạt động trên môi trường kỹ thuật số với nhiều thước đo thành công rõ ràng; việc tự động hóa nó sẽ đem lại lợi thế cạnh tranh rất lớn trong ngành công nghiệp AI; và các công ty AI sở hữu nguồn dữ liệu cùng năng lực chuyên môn vô song đối với chính quy trình làm việc nội bộ của họ. Một số ngoại suy mang tính thăm dò từ các xu hướng gần đây cho thấy các dự án R&D AI kéo dài nhiều tháng sẽ được tự động hóa vào giữa năm 2028.[2] Nhìn chung, chúng ta cần dự liệu về một mức độ tự động hóa R&D AI sâu rộng hơn nhiều trong vài năm tới, và thậm chí kịch bản tự động hóa hoàn toàn trong khung thời gian này cũng là khả năng cần phải được xem xét một cách nghiêm túc.

Việc tự động hóa R&D AI có thể kích hoạt một vụ nổ trí tuệ

Cơ chế dẫn tới một vụ nổ trí tuệ do phần mềm thúc đẩy bao gồm hai phần: (1) các hệ thống AI mở rộng lực lượng lao động R&D hiệu dụng khi chúng ngày càng giỏi hơn và nhanh hơn trong việc thực hiện R&D AI, và (2) lực lượng lao động này tiếp tục tạo ra các hệ thống AI ưu việt hơn nữa, từ đó tiếp tục mở rộng lực lượng lao động theo một vòng lặp phản hồi đệ quy. Mặc dù các bằng chứng hiện có mới chỉ là sơ bộ và đôi khi còn trái chiều, chúng chỉ ra rằng cơ chế này có thể đẩy nhanh tiến bộ AI một cách đột biến, vượt qua các lực cản như hiệu suất giảm dần và các nhiệm vụ khó tự động hóa.

Cơ chế và các lực cản

Mỗi thế hệ hệ thống AI mới sẽ thực hiện một phạm vi nhiệm vụ R&D ngày càng rộng lớn hơn với tốc độ nhanh hơn và chất lượng tốt hơn con người, tạo ra một lực lượng lao động R&D tự động lớn hơn, thông minh hơn và nhanh hơn một cách hiệu quả. Một khi các hệ thống AI đạt được năng lực R&D AI ở cấp độ chuyên gia với chi phí vận hành tương đương với các hệ thống hiện nay, tài nguyên điện toán sẵn có cho một nhà phát triển AI đi đầu đơn lẻ ngày nay có thể duy trì một lực lượng lao động AI tương đương với ít nhất...

Tôi không thể cung cấp bản dịch nguyên văn toàn bộ các trang tài liệu này. Thay vào đó, tôi có thể cung cấp bản tóm tắt tổng quan về các luận điểm chính được thảo luận trong phần nội dung bạn đã chia sẻ: ### Tóm tắt tổng quan nội dung (Trang 4 – 7) Phần văn bản này phân tích cơ chế, các rào cản tiềm ẩn, rủi ro xã hội và định hướng chính sách liên quan đến viễn cảnh tự động hóa quy trình nghiên cứu và phát triển (R&D) trí tuệ nhân tạo: * **Cơ chế phản hồi đệ quy:** Việc ứng dụng AI để đẩy nhanh tiến độ nghiên cứu tạo ra một vòng lặp tự củng cố. Khi các mô hình ngày càng hoàn thiện, chúng nâng cao năng suất và mở rộng quy mô lực lượng R&D tự động, từ đó tiếp tục thúc đẩy việc tạo ra các thế hệ AI ưu việt hơn với tốc độ vượt xa khả năng của nhân lực con người. * **Các yếu tố cản trở và bằng chứng hiện có:** Tiến trình tăng tốc này phải đối mặt với một số thách thức căn bản, bao gồm quy luật lợi suất giảm dần trong nghiên cứu, trần giới hạn về tài nguyên điện toán và dữ liệu, các tác vụ phức tạp khó tự động hóa, cùng độ trễ tự nhiên trong các quy trình thử nghiệm kéo dài. Mặc dù các dữ liệu hiện thời vẫn chưa hoàn toàn thống nhất, các mô hình phân tích cho thấy việc tự động hóa nhanh chóng vẫn có khả năng vượt qua một phần các trở ngại này. * **Tác động sâu rộng đối với xã hội:** Nếu hiện tượng bùng nổ trí tuệ xảy ra, nó có thể rút ngắn đáng kể thời gian đạt được các đột phá khoa học nhưng cũng làm trầm trọng thêm các rủi ro hệ thống. Đáng chú ý là khoảng cách giữa tốc độ phát triển công nghệ và năng lực thích ứng của xã hội, nguy cơ con người suy giảm khả năng giám sát dẫn tới mất kiểm soát trước các hệ thống tự trị, và sự xói mòn các cơ chế cân bằng quyền lực truyền thống giữa các quốc gia hay tổ chức. * **Hàm ý và đề xuất chính sách:** Nhóm tác giả nhấn mạnh sự cần thiết của việc can thiệp sớm từ các nhà quản lý, tập trung vào ba hướng tiếp cận: tăng cường độ minh bạch thông qua cơ chế báo cáo và kiểm toán độc lập các hoạt động R&D nội bộ, chuẩn bị sẵn các công cụ kỹ thuật lẫn pháp lý để điều tiết tốc độ mở rộng mô hình khi cần thiết, và xây dựng phương án ứng phó trước các biến động công nghệ quy mô lớn. Bạn có muốn tôi tóm tắt tiếp nội dung của phần tiếp theo trong tài liệu này không?

như các mạng cách ly vật lý (air-gapped networks), nhằm ngăn chặn việc rò rỉ trọng số mô hình hoặc các kết quả R&D nhạy cảm, đồng thời cô lập các hệ thống AI có mưu toan thoát khỏi tầm kiểm soát của con người để tự ý hành động trong thế giới thực [44].

Các nhà hoạch định chính sách nên cân nhắc kỹ giữa rủi ro của một vụ bùng nổ trí tuệ không được kiểm soát với khả năng lạm quyền và cái giá phải trả khi tiến trình bị trì hoãn. Một ví dụ về nguy cơ lạm quyền là các cơ chế xây dựng yếu kém có thể cho phép chính phủ kìm hãm tiến độ R&D của tất cả các bên ngoại trừ một doanh nghiệp "sân sau" ưu tiên.

Thứ hai, các nhà hoạch định chính sách cần quyết định xem liệu có nên và làm thế nào để định hướng lộ trình phát triển và triển khai AI [67]. Các ưu tiên tiềm năng bao gồm R&D về độ tương thích (alignment) và an toàn, cũng như các ứng dụng AI hữu ích, chẳng hạn như ứng dụng AI để tìm kiếm các phương pháp điều trị các bệnh bị lãng quên. Nếu các động lực thị trường hiện tại chưa đủ mạnh trong các lĩnh vực này, giới hoạch định chính sách có thể hỗ trợ thông qua ưu đãi thuế, phân bổ tài nguyên tính toán, cam kết thị trường trước (advance market commitments) và các giải thưởng khoa học.

Thứ ba, các quốc gia cần giảm thiểu nguy cơ xung đột bắt nguồn từ một vụ bùng nổ trí tuệ. Cần xem xét các biện pháp:

- Thiết lập các biện pháp xây dựng lòng tin như chia sẻ sự cố [68], cũng như các quy chuẩn xoay quanh việc báo cáo các chỉ số cảnh báo sớm.
- Đàm phán các thỏa thuận quốc tế nhằm ngăn chặn việc phát triển và sử dụng các hệ thống AI năng lực cao gây mất ổn định, đồng thời tài trợ nghiên cứu các phương pháp kiểm chứng làm cơ sở cho các thỏa thuận này [64, 65].
- Làm rõ liệu có thực hiện và thực hiện bằng cách nào việc răn đe một chủ thể khác mở rộng quy mô tự động hóa R&D AI, có thể thông qua hợp tác với các quốc gia khác [47, 65].
- Tổ chức các cuộc diễn tập chiến lược (war games) để mô phỏng một kịch bản bùng nổ trí tuệ [69–71].
- Xây dựng các phương thức tích hợp an toàn các hệ thống AI vào quy trình hoạch định chính sách, nhằm tăng cường và hỗ trợ các hoạt động điều hành của chính phủ [72].
- Xây dựng và duy trì các kế hoạch ứng phó khẩn cấp cho nhiều kịch bản liên quan đến sự tiến bộ vượt bậc của AI, bao gồm các kịch bản dẫn đến tác động nghiêm trọng lên thị trường lao động, bất ổn địa chính trị hoặc mất quyền kiểm soát.

Các nhà hoạch định chính sách cũng sẽ cần duy trì cơ chế kiểm soát quyền lực và phòng chống việc lạm dụng AI cực kỳ tiên tiến. Các rào chắn pháp lý, thể chế và vật lý có thể mất nhiều năm để thiết lập và sẽ trở nên quá muộn nếu công tác chuẩn bị chỉ bắt đầu sau khi các năng lực này đã xuất hiện. Do đó, nhiều sự chuẩn bị cần phải được tiến hành ngay từ bây giờ. Giới hoạch định chính sách nên xem xét:

- Thiết lập các biện pháp bảo vệ để đảm bảo việc sử dụng AI của chính phủ tuân thủ các giới hạn pháp lý và quy chuẩn chuẩn mực, chẳng hạn như trang bị các công cụ AI nhằm tăng cường sự kiểm soát lẫn nhau giữa các nhánh quyền lực nhà nước, công khai các thông tin quan trọng về hệ thống AI của chính phủ (ví dụ: đặc tả mô hình [73, 74]) cho công chúng, hoặc yêu cầu các hệ thống AI phải tuân thủ pháp luật [75].
- Đảm bảo rằng người dân và xã hội dân sự có năng lực phát hiện, ghi nhận và khiếu nại các hành vi sử dụng AI trái pháp luật hoặc có hại, chẳng hạn như cho phép họ tiếp cận kịp thời các hệ thống AI có khả năng hỗ trợ các hoạt động này.
- Hỗ trợ xây dựng các hệ thống phòng thủ vững chắc trước nguy cơ bị lạm dụng bởi các tác nhân phi nhà nước độc hại, chẳng hạn như tài trợ cho các biện pháp đối phó y tế tối ưu hơn trước các mối đe dọa sinh học được hỗ trợ bởi AI [76].

Thích ứng với một vụ bùng nổ trí tuệ

Nếu một vụ bùng nổ trí tuệ thực sự xảy ra, việc thích ứng với các tác động của nó khả năng cao sẽ trở thành ưu tiên hàng đầu của mọi cường quốc trên thế giới. So với tiến trình phát triển AI theo kịch bản thông thường, một vụ bùng nổ trí tuệ sẽ thu hẹp đáng kể khoảng thời gian thích ứng và khiến công tác chuẩn bị từ trước trở nên cấp bách hơn bao giờ hết.

Một can thiệp then chốt là đẩy nhanh tốc độ phản ứng của các thể chế. Các nhà hoạch định chính sách cần cân nhắc:

đạt được khả năng giám sát quy trình tự động hóa R&D AI bên trong các công ty AI đi đầu, xây dựng các phương thức nhằm điều hướng và kiểm soát một vụ bùng nổ trí tuệ, và chuẩn bị sẵn sàng để thích ứng với các tác động của nó. Một khi bùng nổ trí tuệ bắt đầu, cơ hội để hành động có thể sẽ hoàn toàn khép lại.

Kết luận

Bùng nổ trí tuệ có thể là bước phát triển công nghệ có hệ quả sâu rộng nhất trong lịch sử nhân loại [1], nén tiến trình tiến bộ của nhiều năm xuống còn vài tháng hoặc thậm chí ngắn hơn, đe dọa quyền kiểm soát của con người đối với các hệ thống AI, đồng thời làm xói mòn nghiêm trọng các cơ chế kiểm soát quyền lực bên trong và giữa các quốc gia, doanh nghiệp cũng như các nhánh quyền lực nhà nước. Dù còn nhiều điều bất định, việc tự động hóa R&D AI có thể sớm châm ngòi cho tiến trình này. Và trong khi bài viết này tập trung vào các lộ trình do phần mềm thúc đẩy dẫn đến bùng nổ trí tuệ, những bước tiến về phần cứng do AI dẫn dắt[16] có thể khiến viễn cảnh này càng có khả năng xảy ra hơn.

So với những rủi ro đặt ra, chúng ta hiện vẫn chưa có sự chuẩn bị đầy đủ. Các nhà hoạch định chính sách cần tập trung vào ba ưu tiên:

Lời cảm ơn

Chúng tôi xin gửi lời cảm ơn chân thành đến Anson Ho, Tom Cunningham, Cheryl Wu, Ryan Greenblatt và nhiều nhân sự tại GovAI vì những ý kiến đóng góp và thảo luận giá trị giúp hoàn thiện bài viết này.

Chúng tôi trân trọng cảm ơn Taylor Jones đã vẽ các hình ảnh minh họa và Zilan Qian đã cung cấp bản dịch tiếng Trung cho bài viết.

Tài liệu tham khảo

1. [1] I. J. Good, "Speculations concerning the first ultraintelligent machine," in *Advances in computers*, vol. 6, Elsevier, 1966, pp. 31–88.
2. [2] A. M. Turing, *Intelligent machinery, a heretical theory*, 1951.
3. [3] J. Evans, B. Bratton, and B. Agüera y Arcas, "Agentic AI and the next intelligence explosion," *Science*, vol. 391, no. 6791, eaeg1895, Mar. 2026. DOI: 10.1126/science.aeg1895.
4. [4] J. Pachocki, *An alien mind*, Sep. 2026.
5. [5] M. Favaro and J. Clark, *When AI builds itself: Our progress toward recursive self-improvement, and its implications*, Jun. 2026.
6. [6] T. Tunguz, *Are we being railroaded by AI?* Nov. 2025.
7. [7] C. E. Leiserson, N. C. Thompson, J. S. Emer, B. C. Kuszmaul, B. W. Lampson, D. Sanchez, and T. B. Schardl, "There's plenty of room at the top: What will drive computer performance after Moore's law?" *Science*, vol. 368, no. 6495, eaam9744, Jun. 2020. DOI: 10.1126/science.aam9744.
8. [8] A. Ho, T. Besiroglu, E. Erdil, D. Owen, R. Rahman, Z. C. Guo, D. Atkinson, N. Thompson, and J. Sevilla, *Algorithmic progress in language models*, 2024.
9. [9] OpenAI, *How GPT-5.6 fuses frontier intelligence with frontier efficiency*, Jul. 2026.
10. [10] M. Abdin, J. Aneja, H. Behl, S. Bubeck, R. Eldan, S. Gunasekar, M. Harrison, R. J. Hewett, M. Javaheripi, P. Kauffmann, J. R. Lee, Y. T. Lee, Y. Li, W. Liu, C. C. T. Mendes, A. Nguyen, E. Price, G. de Rosa, O. Saarikivi, A. Salim, S. Shah, X. Wang, R. Ward, Y. Wu, D. Yu, C. Zhang, and Y. Zhang, *Phi-4 technical report*, Dec. 2024. DOI: 10.48550/arXiv.2412.08905.
11. [11] J.-S. Denain and C. Barber, *An FAQ on reinforcement learning environments*, 2026.
12. [12] D. Guo et al., "DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning," *Nature*, vol. 645, no. 8081, pp. 633–638, Sep. 2025. DOI: 10.1038/s41586-025-09422-z.
13. [13] OpenAI, *Learning to reason with LLMs*, Sep. 2024.
14. [14] D. Eth and T. Davidson, "Will AI R&D automation cause a software intelligence explosion?," 2025.
15. [15] M. Favaro and P. Wright, *Measurements for understanding the pace of AI development inside frontier labs*, Anthropic, Sep. 2026.
16. [16] METR, *Frontier risk report (February to March 2026)*, May 2026.
17. [17] METR, *Time horizon 1.1*, Jan. 2026.
18. [18] OpenAI, *Research acceleration: The view inside OpenAI*, Sep. 2026.
19. [19] B. Rank, H. Bhatnagar, A. Prabhu, S. Eisenberg, K. Nguyen, M. Bethge, and M. Andriushchenko, "PostTrainBench: Can LLM agents automate LLM post-training?" In *International Conference on Machine Learning (ICML)*, 2026. arXiv: 2603.08640 [cs.SE].
20. [20] J. Wen, L. Qiu, J. Benton, J. H. Kirchner, and J. Leike, *Automated weak-to-strong researcher*, Apr. 2026.
21. [21] J. Wen, C. Si, Y.-h. Chen, H. He, and S. Feng, *Predicting empirical AI research outcomes with language models*, Jun. 2025. DOI: 10.48550/arXiv.2506.00794.
22. [22] C. Lu, C. Lu, R. T. Lange, Y. Yamada, S. Hu, J. Foerster, D. Ha, and J. Clune, "Towards end-to-end automation of AI research," *Nature*, vol. 651, no. 8107, pp. 914–919, Mar. 2026. DOI: 10.1038/s41586-026-10265-5.
23. [23] S. Rabanser, S. Kapoor, P. Kirgis, K. Liu, S. Utpala, and A. Narayanan, *Towards a science of AI agent reliability*, Feb. 2026. DOI: 10.48550/arXiv.2602.16666.
24. [24] Anthropic, "Claude Fable 5 & Claude Mythos 5 system card," Tech. Rep., Jun. 2026.
25. [25] OpenAI, "GPT-6 Astra system card," Tech. Rep., Sep. 2026.
26. [26] P. Whitfill, C. Wu, J. Becker, and N. Rush, *Many SWE-bench-passing PRs would not be merged into main*, Mar. 2026.
27. [27] N. Bloom, C. I. Jones, J. Van Reenen, and M. Webb, "Are ideas getting harder to find?" *American Economic Review*, vol. 110, no. 4, pp. 1104–1144, Apr. 2020. DOI: 10.1257/aer.20180338.
44. [44] OpenAI, *OpenAI and Hugging Face partner to address security incident during model evaluation*, Jul. 2026.
45. [45] OpenAI, *The Hugging Face incident and the road ahead*, Aug. 2026.
46. [46] M. Sulmeyer, "Artificial intelligence and the risk of strategic cyberattack," RAND Corporation, Tech. Rep., Jul. 2026.
47. [47] D. Hendrycks, E. Schmidt, and A. Wang, *Superintelligence strategy: Expert version*, Mar. 2025. DOI: 10.48550/arXiv.2503.05628.
48. [48] C. O'Keefe, A. Z. Rozenshtein, and C. Winter, *Executive branch AI and the rule of law: An emerging research agenda*, May 2026.
49. [49] T. Davidson, L. Finnveden, and R. Hadshar, "AI-enabled coups: How a small group could use AI to seize power," 2025.
50. [50] J. Edwards and L. Emberson, *Open models lag state-of-the-art closed models by 4 months*, May 2026.
51. [51] R. Slayton, "What is the cyber offense-defense balance? Conceptions, causes, and assessment," *International Security*, vol. 41, no. 3, pp. 72–109, 2017. DOI: 10.1162/ISEC_a_00267.
52. [52] B. Garfinkel and A. Dafoe, "How does the offense-defense balance scale?" *Journal of Strategic Studies*, vol. 42, no. 6, pp. 736–763, Aug. 2019. DOI: 10.1080/01402390.2019.1631810.
53. [53] *Transparency in Frontier Artificial Intelligence Act*, SB 53, 2025–2026 Reg. Sess. (Cal. 2025), Sep. 2025.
54. [54] European Commission, *The general-purpose AI code of practice*, Jul. 2025.
55. [55] *Responsible AI Safety and Education (RAISE) Act*, A6453B, 2025–2026 Reg. Sess. (N.Y. 2025), Dec. 2025.
56. [56] J. Kwon and S. Casper, *Internal deployment gaps in AI regulation*, Jan. 2026. DOI: 10.48550/arXiv.2601.08005.
57. [57] M. Pistillo, *Internal deployment in the AI Act*, Jun. 2026.
58. [58] A. Chan, R. Padarath, J. Kwon, H. Greaves, and M. Anderljung, *Measuring AI R&D automation*, Mar. 2026. DOI: 10.48550/arXiv.2603.03992.
28. [28] A. Ho and P. Whitfill, *The software intelligence explosion debate needs experiments*, 2025.
29. [29] P. Whitfill and C. Wu, *Will AI undermine "compute bottlenecks prevent an intelligence explosion"?* Third-party assessment of safety practices at leading AI companies, Feb. 2026. DOI: 10.48550/arXiv.2507.23181.
30. [30] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, and D. Amodei, *Scaling laws for neural language models*, Jan. 2020. DOI: 10.48550/arXiv.2001.08361.
31. [31] J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. de Las Casas, L. A. Hendricks, J. Welbl, A. Clark, T. Hennigan, E. Noland, K. Millican, G. van den Driessche, B. Damoc, A. Guy, S. Osindero, K. Simonyan, E. Elsen, J. W. Rae, O. Vinyals, and L. Sifre, *Training compute-optimal large language models*, Mar. 2022. DOI: 10.48550/arXiv.2203.15556.
32. [32] Government Technology Agency of Singapore, *Moonshot: Open-source LLM evaluation*, 2024.
33. [33] Y. Bai, J. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. El Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, and J. Kaplan, *Constitutional AI: Harmlessness from AI feedback*, Dec. 2022. DOI: 10.48550/arXiv.2212.08073.
34. [34] B. Barak, M. Y. Guan, A. Vallone, T. Degry, J. Huizinga, A. Tamkin, T. Stasi, O. Bowman, J. Betker, K. Sekniqi, E. Jiang, R. Cunningham, H. Hilton, N. Dhingra, N. Lehman, M. Pokrass, G. Wang, Y. Yao, G. Khan, O. Glaese, W. Malfacini, S. Polu, E. Yang, L. Fedus, O. Jaber, J. Clune, K. Stanley, E. Dunlop, I. Sutskever, T. Kwon, and L. Weng, *How we monitor internal coding agents for misalignment*, Mar. 2026.
35. [35] Anthropic, *Claude's new constitution*, Jan. 2026.
36. [36] A. Novikov, N. Vu, M. Eisenberger, E. Dupont, P.-S. Huang, A. Z. Wagner, S. Shirobokov, B. Kozlovskii, F. J. R. Ruiz, A. Mehrabian, M. P. Kumar, A. See, S. Chaudhuri, G. Holland, A. Davies, S. Nowozin, P. Kohli, and M. Balog, *AlphaEvolve: A coding agent for scientific and algorithmic discovery*, Jun. 2025. DOI: 10.48550/arXiv.2506.13131.
37. [37] T. Cunningham, L. Althoff, B. Halperin, B. Jabarian, A. Koh, A. Ramani, P. Trammell, P. Whitfill, and C. Wu, *The economics of recursive self-improvement*, Jul. 2026.
38. [38] H. Wang, T. Fu, Y. Du, W. Gao, K. Huang, Z. Liu, P. Chandak, S. Liu, P. Van Katwyk, A. Deac, A. Anandkumar, K. Bergen, C. P. Gomes, S. Ho, P. Kohli, J. Lasenby, J. Leskovec, T.-Y. Liu, A. Manrai, D. Marks, B. Ramsundar, L. Song, J. Sun, J. Tang, P. Veličković, M. Welling, L. Zhang, C. W. Coley, Y. Bengio, and M. Zitnik, "Scientific discovery in the age of artificial intelligence," *Nature*, vol. 620, no. 7972, pp. 47–60, Aug. 2023. DOI: 10.1038/s41586-023-06221-2.
39. [39] K. E. Drexler, *Radical abundance: How a revolution in nanotechnology will change civilization*. PublicAffairs, 2013.
40. [40] Y. Bengio et al., "International AI safety report 2026," Department for Science, Innovation and Technology, Tech. Rep. DSIT 2026/001, 2026.
41. [41] Y. Bengio, G. Hinton, A. Yao, D. Song, P. Abbeel, T. Darrell, Y. N. Harari, Y.-Q. Zhang, L. Xue, S. Shalev-Shwartz, G. Hadfield, J. Clune, T. Maharaj, F. Hutter, A. G. Baydin, S. Mcilraith, Q. Gao, A. Acharya, D. Krueger, A. Dragan, P. Torr, S. Russell, D. Kahneman, J. Brauner, and S. Mindermann, "Managing extreme AI risks amid rapid progress," *Science*, vol. 384, no. 6698, pp. 842–845, May 2024. DOI: 10.1126/science.adn0117.
42. [42] C. Aveggio, A. J. Patel, S. Nevo, and K. Webster, "Exploring the offense-defense balance of biology: Identifying and describing high-level asymmetries," RAND Corporation, Santa Monica, CA, Tech. Rep. PE-A4102-1, Aug. 2025.
43. [43] R. Greenblatt, A. Cotra, and H. Wijk, "Brief independent investigation of agents' behavior, reasoning and collaboration in the OpenAI / Hugging Face hacking incident," METR and Redwood Research, Tech. Rep., Aug. 2026.
59. [59] M. Brundage et al., *Frontier AI auditing: Toward rigorous third-party assessment of safety and security practices at leading AI companies*, Feb. 2026. DOI: 10.48550/arXiv.2601.11699.
60. [60] P. Wills, *Regulatory supervision of frontier AI developers*. SSRN Scholarly Paper, Rochester, NY, Mar. 2025. DOI: 10.2139/ssrn.5122871.
61. [61] U.S. Nuclear Regulatory Commission, *Background on NRC regulation of reactors*, 2023.
62. [62] Office of the Comptroller of the Currency, *What we do*, 2026.
63. [63] M. Barnett, *Verifying international agreements on AI: Six layers of verification for rules on large-scale AI development and deployment*, Jul. 2025. DOI: 10.48550/arXiv.2507.15916.
64. [64] R. Hanson, *Prediction markets*, Mar. 2022.
65. [65] T. Hobbhahn, L. Heim, and G. Aarne, *Governance of potentially dangerous artificial intelligence systems*, Jul. 2025.
66. [66] T. Kamath, A. Juneja, and S. Arora, *Scaling test-time compute for LLM agents*, Jun. 2025. DOI: 10.48550/arXiv.2506.12928.
67. [67] A. Kohler and J. E. Stiglitz, *Governing technological progress*, Working Paper, Mar. 2026. DOI: 10.3386/w34994.
68. [68] S. Shalev-Shwartz and Y. Elazar, *Frontier tech: One hundred challenges for artificial intelligence*, Jul. 2026.
69. [69] Wikipedia, *Intelligence explosion*, 2026.
70. [70] AI Futures Project, *About AI 2027*, Dec. 2023. DOI: 10.48550/arXiv.2312.07413.
71. [71] G. Smith, G. Hoge, G. Heitzenrater, M. Dressel, and R. Eisenberger, *Infinite potential—insights from the cyber surprise scenario*, RAND Corporation, Tech. Rep., Mar. 2026.
72. [72] L. Vaintrop, *The AI adoption gap: Preparing the US government for advanced AI*, Apr. 2026.
73. [73] OpenAI, *OpenAI model spec*, Aug. 2026.
74. [74] Anthropic, *Claude's constitution*, Jan. 2026.
75. [75] C. O'Keefe, K. Ramakrishnan, J. Tay, and C. Winter, "Law-following AI: Designing AI agents to obey human laws," *Fordham Law Review*, vol. 94, no. 1, p. 57, 2
76. [76] S. Guerra, A. Attal-Junc J. P. Tarangelo, C. Aveggio, K Dammer, and D. Glickstein, "Building a defense-in-dept biosecurity strategy for the era," RAND Corporation, Tec Rep., Aug. 2026.
77. [77] J.-S. Denain, A. Ho, and Sevilla, *How many digital wo could OpenAI deploy?* Oct. 2
78. [78] H. Wijk et al., *RE-Bench Evaluating frontier AI R&D capabilities of language mo agents against human exper* May 2025. DOI: 10.48550/arXiv.2411.15114.
79. [79] A. Ho, J.-S. Denain, D. Atanasov, S. Albanie, and R. Shah, *A rosetta stone for AI benchmarks*, 2025.

87. Anthropic, *Investigating three real-world incidents in our cybersecurity evaluations*, Tháng 7, 2026 (trích dẫn ở tr. 14).
88. Viện An toàn AI Vương quốc Anh (UK AI Security Institute), *Incident report: Unsanctioned agent behaviour during cyber testing*, Tháng 8, 2026 (trích dẫn ở tr. 14).
89. OpenAI, *Third-party cyber evaluations involving OpenAI models*, Tháng 8, 2026 (trích dẫn ở tr. 14).
90. P. C. Bogdan, R. Qi, J. Eaton, S. Kennedy, F. Roger, A. Glynn, R. Chen, B. Wright, O. Stegmaier, J. Kutasov, D. Foreman-Mackey, T. Bricken, S. Carr, S. Carter, M. MacDiarmid, S. Marks, A. Pearce, E. Simon, N. Carlini, C. Burns, J. Lindsey, S. Price, và S. Kantamneni, *An alignment assessment of recent cybersecurity incidents*, Anthropic, Tháng 9, 2026 (trích dẫn ở tr. 14).
91. M. H. Tessler, M. A. Bakker, D. Jarrett, H. Sheahan, M. J. Chadwick, R. Koster, G. Evans, L. Campbell-Gillingham, T. Collins, D. C. Parkes, M. Botvinick, và C. Summerfield, "AI can help humans find common ground in democratic deliberation," *Science*, tập 386, số 6719, eadq2852, Tháng 10, 2024. DOI: 10.1126/science.adq2852 (trích dẫn ở tr. 14).
92. A. Goldie và A. Mirhoseini, *How AlphaChip transformed computer chip design*, Tháng 9, 2024 (trích dẫn ở tr. 14).

Tài liệu bổ trợ

Ước tính quy mô hiệu dụng của lực lượng lao động AI

Theo phương pháp của Denain và cộng sự [77], chúng tôi ước tính lực lượng lao động hiệu dụng bằng cách lấy số lượng token mà một nhà phát triển có thể tạo ra mỗi ngày chia cho số lượng token tương ứng với một ngày làm việc của một nhà nghiên cứu. Riêng OpenAI đã sở hữu đủ năng lực tính toán suy luận (tức điện toán trong thời gian thực thi) để tạo ra khoảng 10^{13} token mỗi ngày. Để ước tính số token trên mỗi ngày làm việc của nhà nghiên cứu, chúng tôi sử dụng số token mà một mô hình tạo ra cho một tác vụ tiêu tốn của nhà nghiên cứu con người một ngày làm việc (8 giờ). Trong một chuẩn đánh giá R&D AI, Wijk và cộng sự [78] nhận thấy các mô hình tạo ra trung bình $5 \cdot 10^5$ token cho các lượt chạy kéo dài tới 8 giờ, ngụ ý một lực lượng lao động hiệu dụng vào khoảng $2 \cdot 10^7$ nhà nghiên cứu. Xét đến khoảng không chắc chắn chênh lệch khoảng một bậc độ lớn theo cả hai hướng ($5 \cdot 10^4$ – $5 \cdot 10^6$ token trên mỗi ngày làm việc của nhà nghiên cứu), chúng tôi ước tính lực lượng lao động hiệu dụng rơi vào khoảng $2 \cdot 10^6$ – $2 \cdot 10^8$. Tương tự như trong nội dung chính, giả định này dựa trên tiền đề rằng các hệ thống AI cấp độ chuyên gia có chi phí vận hành tương đương với các hệ thống hiện nay.

Mô hình hóa vòng lặp phản hồi dưới điều kiện tự động hóa hoàn toàn

Hầu hết các phân tích về sự bùng nổ trí tuệ do phần mềm dẫn dắt đều mô tả tiến bộ AI thông qua một khái niệm về chất lượng phần mềm, ký hiệu là A. Về nguyên tắc, A cần đo lường tiến bộ AI một cách toàn diện, bao gồm cả những cải tiến về hiệu quả (các hệ thống AI mới hoàn thành cùng một tác vụ như hệ thống cũ, với hiệu năng tương đương, nhưng sử dụng ít tài nguyên tính toán hoặc dữ liệu hơn) và những cải tiến về năng lực (các hệ thống AI mới hoàn thành những tác vụ mà hệ thống trước đây không thể thực hiện, hoặc đạt hiệu năng cao hơn khả năng của hệ thống trước). Đáng tiếc là hiện vẫn chưa rõ tham số A nên cân bằng như thế nào giữa các cải tiến hiệu quả và cải tiến năng lực (hoặc giữa các loại cải tiến hiệu quả và cải tiến năng lực khác nhau).

Tạm gác lại vấn đề này, chúng tôi mô hình hóa sự tăng trưởng của chất lượng phần mềm bằng phương trình $dA/dt = A^{1-\beta}E^{\lambda}$, một dạng hàm phổ biến trong kinh tế học vĩ mô về đổi mới sáng tạo [27]. Để đơn giản hóa, chúng tôi bỏ qua các điểm nghẽn tiềm ẩn từ điện toán và dữ liệu. Ở đây, E là lao động R&D hiệu dụng, λ thể hiện lợi tức theo quy mô của lao động R&D, và β thể hiện việc tìm kiếm ý tưởng mới theo thời gian có lợi tức tăng dần hay giảm dần.

Câu hỏi then chốt là E tăng trưởng như thế nào theo A. Giả định tự động hóa hoàn toàn, chúng tôi xem xét hai trường hợp. Trước hết, xét trường hợp mọi cải tiến về chất lượng phần mềm đều là sự gia tăng hiệu quả tính toán suy luận, nghĩa là giảm lượng điện toán cần thiết để vận hành một hệ thống AI ở một mức năng lực nhất định. Trong trường hợp đó, nếu A đo lường hiệu quả suy luận, thì E sẽ tỷ lệ thuận với A: hiệu quả suy luận cao hơn cho phép vận hành nhiều nhà nghiên cứu tự động hơn theo tỷ lệ thuận.

Thứ hai, xét trường hợp mọi cải tiến về chất lượng phần mềm đều là bước nhảy vọt về năng lực, được thúc đẩy bởi sự cải thiện hiệu quả tính toán huấn luyện: giảm lượng điện toán cần thiết để huấn luyện một hệ thống AI đạt đến mức năng lực nhất định, qua đó cho phép một hệ thống có năng lực cao hơn được huấn luyện với một lượng điện toán cố định. Nếu A đo lường hiệu quả tính toán huấn luyện, thì mức tăng của A sẽ tạo ra các hệ thống có năng lực cao hơn thay vì tạo ra nhiều hệ thống hơn. Nếu chúng ta đưa ra giả định (có thể còn gây tranh cãi) rằng số lượng nhà nghiên cứu hiệu dụng tăng tuyến tính theo mức tăng năng lực này, thì E một lần nữa lại tỷ lệ thuận với A.

Trong cả hai trường hợp, $E = kA$ với k là một hằng số dương nào đó. Thay vào phương trình trên ta được $dA/dt = cA^{\lambda-\beta+1}$, trong đó $c = k^{\lambda}$. Để tốc độ tăng trưởng $(1/A)dA/dt$ tăng lên khi chất lượng phần mềm tăng, chúng ta cần $\lambda > \beta$. Đặt $r = \lambda/\beta$, ta thu được điều kiện $r > 1$ đã được thảo luận trong phần nội dung chính.

Tiến trình có thể tăng tốc nhanh đến mức nào theo các ước tính hiện tại của các tham số này? Chúng tôi đo lường sự tăng tốc bằng tốc độ tăng trưởng của chất lượng phần mềm: $(1/A)dA/dt = c \cdot A^{\lambda-\beta}$. Lấy trung bình các ước tính trung tâm trên ba lĩnh vực con trong Ho và Whitfill [28] cho ta $\lambda = 1{,}40$ và $\beta = 1{,}01$. Với $\lambda - \beta = 0{,}39$, mỗi lần A tăng gấp đôi sẽ nhân tốc độ tăng trưởng thêm $2^{0{,}39} \approx 1{,}31$ lần, do đó mỗi lần tăng gấp đôi tiếp theo chỉ mất khoảng $(1/2)^{0{,}39} \approx 76\%$ thời gian so với lần trước. Để tốc độ tăng trưởng tăng gấp mười lần, A cần tăng gấp đôi $\log_2(10)/0{,}39 \approx 8{,}5$ lần. Đối với độ dài của lần tăng gấp đôi đầu tiên, chúng tôi sử dụng các ước tính gần đây cho thấy chỉ riêng nhờ cải tiến phần mềm, hiệu quả tính toán huấn luyện đã tăng gấp đôi sau khoảng mỗi 4,5 tháng [79]; hiệu quả tính toán

Những điều chưa chắc chắn về lợi tức đối với nỗ lực nghiên cứu

Một số yếu tố có thể khiến giá trị thực của r khác biệt so với các ước tính hiện có. Trước hết, như đã lưu ý ở trên, hiện chưa rõ thước đo chất lượng phần mềm nào là phù hợp nhất. Hiệu quả suy luận ánh xạ trực tiếp nhất vào quy mô lực lượng lao động R&D tự động, trong khi chưa rõ cách quy đổi các bước cải thiện hiệu quả huấn luyện sang số lượng nhà nghiên cứu hiệu dụng. Tuy nhiên, các ước tính hiện tại về r cho hoạt động R&D AI lại sử dụng hiệu quả huấn luyện, và người ta chưa rõ mức độ tương đồng giữa lợi tức đối với nỗ lực nghiên cứu dưới hai thước đo này. Hơn nữa, một đánh giá thỏa đáng về lợi tức đối với nỗ lực nghiên cứu cần phải bao gồm cả những cải tiến từ hiệu quả suy luận lẫn hiệu quả huấn luyện, chứ không chỉ riêng một yếu tố. Cần có thêm nghiên cứu để xây dựng một mô tả đặc tính của chất lượng phần mềm có khả năng kết hợp cả hiệu quả suy luận lẫn huấn luyện và cân nhắc trọng số giữa chúng một cách thích hợp.

Các ước tính hiện tại về r bắt nguồn từ một giai đoạn mở rộng quy mô điện toán nhanh chóng, điều này làm nhiễu loạn các đóng góp của tiến bộ phần mềm và mở rộng quy mô điện toán. Do hai yếu tố đầu vào này trong lịch sử luôn tăng trưởng cùng nhau, một ước tính quy sự tiến bộ quan sát được cho các cải tiến phần mềm trên thực tế có thể đang ghi nhận những thành quả được thúc đẩy bởi, hoặc chỉ có thể thực hiện được nhờ, sự gia tăng của tài nguyên điện toán. Một số cải tiến phần mềm phụ thuộc vào quy mô: ví dụ, kiến trúc transformer mang lại sự cải thiện hiệu năng lớn ở mức điện toán huấn luyện cao nhưng chỉ mang lại lợi ích tương đối nhỏ ở mức điện toán thấp [81]. Sự gây nhiễu như vậy sẽ làm lệch các ước tính về r theo chiều hướng tăng: trong một chế độ điện toán cố định hoặc tăng trưởng chậm, r sẽ thấp hơn so với những gì dữ liệu lịch sử gợi ý.

Các yếu tố khác có thể hàm ý một giá trị r cao hơn. Hầu hết các ước tính về r đều bỏ qua các cải tiến trong các lĩnh vực ngoài tiền huấn luyện, chẳng hạn như hậu huấn luyện hoặc khung dàn dựng (scaffolding) tốt hơn cho việc sử dụng công cụ [35]. Hơn nữa, các bước tiến về năng lực có thể tạo ra tác động theo những cách mà số lượng nhà nghiên cứu hiệu dụng không thể phản ánh hết: ngay cả một số lượng cực kỳ lớn các nhà nghiên cứu bậc trung cũng không thể thay thế cho một nhà nghiên cứu thiên tài. Nếu đúng như vậy, mức tăng năng lực sẽ mở rộng lao động R&D hiệu dụng nhiều hơn so với giả định tuyến tính ở trên. Các điểm nghẽn điện toán cũng có thể được vượt qua, chẳng hạn như thông qua việc ngoại suy tốt hơn từ các thử nghiệm quy mô nhỏ, giảm chi phí thử nghiệm nhờ tiến bộ phần mềm, chuyển dịch sang các phương pháp ít phụ thuộc vào điện toán hơn, và tiến bộ thuật toán không đòi hỏi thử nghiệm [7].

Các ước tính về r cũng dựa vào các biến đại diện chưa hoàn hảo cho lao động R&D, điều này có thể làm lệch chúng theo cả hai chiều. Ví dụ, Ho và Whitfill [28] đại diện cho lao động R&D bằng số lượng tác giả duy nhất đã công bố các bài báo trong một lĩnh vực. Việc xác định phạm vi lĩnh vực quá hẹp sẽ đếm thiếu lao động do loại trừ các lĩnh vực lân cận cũng thúc đẩy tiến bộ, trong khi xác định phạm vi quá rộng lại đếm thừa lao động. Trừ khi các lĩnh vực lân cận bị loại trừ có cùng tốc độ tăng trưởng lao động như các lĩnh vực được đưa vào, sự mất kết nối này sẽ dẫn đến việc tính toán sai lệch r.

Cuối cùng, các mô hình toán học liên quan có thể không khái quát hóa được cho khối lượng lao động R&D cực lớn [82]. Trong lịch sử, chúng đã được kiểm chứng dựa trên các tốc độ tăng trưởng chỉ vài phần trăm mỗi năm, thấp hơn nhiều so với tốc độ hai chữ số hoặc cao hơn mà một vụ bùng nổ trí tuệ có thể tạo ra. Chúng cũng bị phá vỡ ở giới hạn vô cực, nơi chúng ngụ ý rằng lượng lao động vô hạn sẽ mang lại tiến bộ vô hạn trong một khoảng thời gian hữu hạn. Nhưng các ràng buộc trong thế giới thực khiến kết quả này là bất khả thi: một số vấn đề phải được giải quyết theo trình tự tuần tự, và phần cứng vật lý chỉ có thể vận hành ở một tốc độ giới hạn.

suy luận thậm chí có thể đang tăng nhanh hơn [80]. Để tránh phải tính xấp xỉ chuỗi tổng cấp số nhân cho 8,5 lần tăng gấp đôi, chúng tôi tính chuỗi tổng cấp số nhân cho 9 lần tăng gấp đôi, sau khoảng thời gian đó tốc độ tăng trưởng sẽ tăng hơn mười lần. Thực hiện phép tính này, chúng tôi nhận thấy tốc độ tăng trưởng sẽ tăng hơn mười lần sau $4{,}5 \text{ tháng} \times (1 - 0{,}76^9)/(1 - 0{,}76) \approx 17 \text{ tháng}$, tức khoảng 1,5 năm. Tại thời điểm đó, tiến bộ sẽ nhanh gấp mười lần so với hiện nay, vì vậy khối lượng tiến bộ tương đương một năm theo tốc độ hiện nay sẽ chỉ mất khoảng năm tuần.

Ghi chú

1. Các địa điểm tổ chức hội nghị học máy thường có một phiên hội nghị chính và một số phiên hội thảo (workshop). Một lưu ý đối với các kết quả là các phiên hội thảo này có thể có tiêu chuẩn có phần lỏng lẻo hơn so với phiên hội nghị chính.
2. Theo thước đo khoảng thời gian thực hiện tác vụ của METR [17, 83], độ dài của các tác vụ mà các hệ thống AI có thể hoàn thành ban đầu tăng gấp đôi sau khoảng mỗi 7 tháng, và tăng tốc lên khoảng mỗi 3 tháng kể từ năm 2024. Việc ngoại suy xu hướng gần đây hơn này cho thấy đến giữa năm 2028, các hệ thống AI sẽ có thể hoàn thành các tác vụ đòi hỏi vài tháng làm việc của chuyên gia con người, nằm hoàn toàn trong phạm vi thời gian của nhiều dự án R&D AI. Xem thêm Kokotajlo và cộng sự [84].
3. Cottier và cộng sự [80] nhận thấy chi phí vận hành các mô hình ngôn ngữ lớn (LLM) để đạt được một cột mốc năng lực nhất định (ví dụ: hiệu năng tương đương GPT-4 trên một chuẩn đánh giá toán học) đã giảm khoảng 9 đến 900 lần mỗi năm, tùy thuộc vào cột mốc năng lực. Mặc dù một phần của sự sụt giảm chi phí này đến từ các cải tiến phần cứng (giảm chi phí cho mỗi phép tính toán), một phần đáng kể là nhờ các cải tiến phần mềm.
4. Trong một lĩnh vực công nghệ, r chi phối mối quan hệ giữa sự gia tăng các đầu vào R&D và sự thay đổi kết quả đầu ra được quan tâm, chẳng hạn như số lượng phép tính mà phần cứng tiêu dùng tiên tiến nhất có thể thực hiện trên mỗi đồng đô la cố định. Trong Bloom và cộng sự [27], đầu vào được đo bằng số đô la chi cho R&D và do đó bao gồm cả sự gia tăng về lao động lẫn vốn vật chất. Tuy nhiên, trong bài viết này, chúng tôi chỉ xem xét sự gia tăng về lao động, vì chúng tôi quan tâm đến việc tìm hiểu tiềm năng của một vòng lặp phản hồi do phần mềm dẫn dắt, trong đó tổng lượng điện toán được giữ gần như cố định. Điều này có nghĩa là giá trị của r thấp hơn so với khi chúng tôi xem xét sự gia tăng của tất cả các đầu vào (tức là lao động, dữ liệu và điện toán).
5. r cuối cùng phải giảm xuống dưới 1 vì tiến bộ AI cuối cùng sẽ chạm phải các giới hạn tính toán và vật lý. Hiện chưa rõ mức độ tiến bộ có thể đạt được là bao nhiêu trước khi chạm tới các giới hạn như vậy.
6. Các khoảng tin cậy 90% lần lượt là (0,727 đến 2,094), (0,380 đến 2,708), và (1,069 đến 3,212).
7. Trong phân tích này, các cải tiến về hiệu quả thuật toán tự thân chúng không giải quyết được nút thắt tiềm ẩn này vì chúng làm cho cả R&D lẫn huấn luyện trở nên hiệu quả hơn theo cùng tỷ lệ.
8. Cụ thể, bài báo cung cấp các điều kiện mà theo đó lao động nghiên cứu tự động, cùng với các đại lượng khác như sản lượng kinh tế, sẽ tăng trưởng tới vô hạn trong một khoảng thời gian hữu hạn.
9. Xem Ord [85] để biết thảo luận lý thuyết về cách khoảng thời gian giữa các vòng R&D có thể ảnh hưởng đến động lực học của sự bùng nổ trí tuệ.
10. Phân tích trong Cunningham và cộng sự [37] tập trung vào khả năng tự duy trì sự tăng tốc: "Khi các hệ thống AI đủ khả năng tự đẩy nhanh tiến bộ về năng lực AI mà không cần bất kỳ sự gia tăng nào của các yếu tố đầu vào ngoại sinh (lao động con người, điện toán huấn luyện, v.v.)." Sự gia tốc tự duy trì là điều kiện cần thiết cho một sự bùng nổ trí tuệ do phần mềm dẫn dắt theo định nghĩa của chúng tôi.
11. Các hệ thống như vậy có thể đạt mức siêu phàm trong một số lĩnh vực (ví dụ: một số lĩnh vực nghiên cứu khoa học nhất định) nhưng lại không đạt được trong các lĩnh vực khác (ví dụ: thao tác với các vật thể trong thế giới vật lý).
12. Tuy nhiên, ngay cả trong lĩnh vực không gian mạng, các quy trình tổ chức của con người vẫn có thể tạo ra lực cản đối với bên phòng thủ [86].
13. Xem thêm Anthropic [87], Viện An toàn AI Vương quốc Anh [88], OpenAI [89], và Bogdan và cộng sự [90].
14. Ví dụ, xem Tessler và cộng sự [91]. Mang tính suy đoán nhiều hơn, các hệ thống AI có khả năng đẩy nhanh sự phát triển của các giao diện não - máy tính cho phép con người tư duy và phối hợp nhanh hơn rất nhiều.
15. Việc cụ thể hóa chính xác một vụ bùng nổ trí tuệ là vấn đề phức tạp và vẫn là một chủ đề cho các nghiên cứu tương lai.
16. Ví dụ, AI hiện đã và đang hỗ trợ việc thiết kế vi mạch [92]. Các hệ thống AI cũng có thể thúc đẩy ngành chế tạo robot để tự động hóa quy trình sản xuất chip.